

分类号 TP393

学号 14063020

U D C

密级 公开

工学硕士学位论文

基于智能手机传感器数据的用户关系计算研究

硕士生姓名 王峰

学科专业 计算机科学与技术

研究方向 移动感知

指导教师 刘东波 副研究员

国防科学技术大学研究生院

二〇一六年九月

Users Relationship Strength Measurements Based on the Mutuilayer Hybird Model

Candidate: Feng Wang

Advisor: Professor Dongbo Liu

A dissertation

**Submitted in partial fulfillment of the requirements
for the degree of Master of Engineering
in Computer Science and Technology**

Graduate School of National University of Defense Technology

Changsha, Hunan, P. R. China

September 1, 2016

独 创 性 声 明

本人声明所呈交的学位论文是我本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表和撰写过的研究成果，也不包含为获得国防科学技术大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文题目： 基于智能手机传感器数据的用户关系计算研究

学位论文作者签名： _____ 日期： 年 月 日

学 位 论 文 版 权 使 用 授 权 书

本人完全了解国防科学技术大学有关保留、使用学位论文的规定。本人授权国防科学技术大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档，允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密学位论文在解密后适用本授权书。)

学位论文题目： 基于智能手机传感器数据的用户关系计算研究

学位论文作者签名： _____ 日期： 年 月 日

作者指导教师签名： _____ 日期： 年 月 日

目 录

摘要	i
ABSTRACT	iii
第一章 绪论	1
1.1 研究背景	1
1.2 研究现状	2
1.2.1 社会关系强度的研究现状	2
1.2.2 基于移动数据的社会关系研究现状	2
1.2.3 基于移动轨迹数据关系强度的研究现状	2
1.3 研究内容	3
1.4 论文结构	5
第二章 相关技术研究	7
2.1 轨迹数据预处理	7
2.1.1 滤波算法	7
2.1.2 聚类算法	9
2.2 时间序列相似度度量方法及序列熵值	11
2.2.1 编辑距离	12
2.2.2 Dynamic Time Warping	12
2.2.3 序列熵值	13
2.3 自然语言处理模型	15
2.3.1 Latent Dirichlet Allocation	16
2.3.2 word2vec	16
2.4 小结	18
第三章 用户关系强度层级投票模型框架	19
3.1 模型框架描述	19
3.1.1 SASLL 系统概述	19
3.1.2 用户关系强度计算模型概述	20
3.2 模型完整流程描述	21
第四章 GPS 数据处理及语义标签标注技术	23
4.1 SASLL 标注技术	23
4.2 计算对应语义位置	23
4.2.1 降低数据噪声	24
4.2.2 剔除路上的点	28
4.2.3 聚类得到语义位置	30

4.3 对语义位置标语义标签	39
4.3.1 发现新位置	40
4.3.2 新位置语义标签提示	41
4.4 小结	43
第五章 用户关系强度计算方法	45
5.1 用户关系强度计算方法概述	45
5.2 输入数据准备	45
5.2.1 轨迹数据的处理与准备	46
5.2.2 语义位置数据的处理与准备	47
5.2.3 语义标签数据的处理与准备	47
5.3 关系强度计算	48
5.3.1 基于原始轨迹数据的关系强度计算	48
5.3.2 基于主题模型的关系强度计算	49
5.3.3 结果投票	50
5.4 小结	51
第六章 数据集、评估方法及实验结果	53
6.1 数据集	53
6.2 评估方法	57
6.2.1 构造真实结果	58
6.2.2 评估方法	59
6.3 实验结果与分析	61
6.4 小结	71
第七章 结束语	73
7.1 工作总结	73
7.2 工作展望	74
致谢	77
参考文献	79
作者在学期间取得的学术成果	83

表 目 录

表 6.1 调查问卷 ^[1]	54
表 6.2 基站区域号与对应的语义标签	57
表 6.3 真实结果	60
表 6.4 无优化 DTW 方法得到好友列表	63
表 6.5 优化 DTW 方法得到好友列表	64
表 6.6 基于语义位置行为模式相似度得到好友列表	67
表 6.7 LDA 模型学习到的主题	68
表 6.8 基于语义标签行为模式相似度得到好友列表	69
表 6.9 三层结果投票得到好友列表	70

图 目 录

图 2.1 K-MEANS 算法原理示意图	10
图 2.2 DJ-cluster 聚类算法原理示意 ^[24]	10
图 2.3 按密度排序 ^[20]	11
图 2.4 按距离排序, 1、10 为聚类中心 ^[20]	11
图 2.5 引自文献 [32]DTW 原理示意图。	13
图 2.6 LDA 的图模型表示 ^[38]	16
图 2.7 word2vec 神经网络结构图 ^[40]	17
图 3.1 用户关系强度层级投票模型框架图	20
图 4.1 SASLL 系统框架图	23
图 4.2 均值滤波实验结果 3-1	24
图 4.3 均值滤波实验结果 3-2	24
图 4.4 均值滤波实验结果 3-3	25
图 4.5 中值滤波实验结果 3-1	25
图 4.6 中值滤波实验结果 3-2	25
图 4.7 中值滤波实验结果 3-3	26
图 4.8 卡尔曼滤波实验结果 3-1	26
图 4.9 卡尔曼滤波实验结果 3-2	26
图 4.10 卡尔曼滤波实验结果 3-3	27
图 4.11 分段卡尔曼滤波实验结果 3-1	27
图 4.12 分段卡尔曼滤波实验结果 3-2	27
图 4.13 分段卡尔曼滤波实验结果 3-3	28
图 4.14 绿色表示正常点, 红色表示路上的点	29
图 4.15 平均距离收敛	30
图 4.16 K-MEANS 聚类实验结果 3-1	31
图 4.17 K-MEANS 聚类实验结果地图展示 3-1	32
图 4.18 K-MEANS 聚类实验结果 3-2	32
图 4.19 K-MEANS 聚类实验结果地图展示 3-2	33
图 4.20 K-MEANS 聚类实验结果 3-3	33
图 4.21 K-MEANS 聚类实验结果地图展示 3-3	34
图 4.22 DJ-Cluster 实验结果 3-1	34
图 4.23 DJ-Cluster 实验结果地图表示 3-1	34
图 4.24 DJ-Cluster 实验结果 3-2	35

图 4.25 DJ-Cluster 实验结果地图表示 3-2	35
图 4.26 DJ-Cluster 实验结果 3-3	35
图 4.27 DJ-Cluster 实验结果地图表示 3-3	36
图 4.28 Science 发表算法实验结果 3-1	37
图 4.29 Science 发表算法实验结果地图表示 3-1	37
图 4.30 Science 发表算法实验结果 3-2	37
图 4.31 Science 发表算法实验结果地图表示 3-2	38
图 4.32 Science 发表算法实验结果 3-3	38
图 4.33 Science 发表算法实验结果地图表示 3-3	38
图 4.34 语义标签推断结果示意	42
图 4.35 语义标签推断结果示意	43
图 5.1 URSHV 模型框架	45
图 6.1 志愿者采集基站数据可视化	56
图 6.2 朋友关系可视化	58
图 6.3 DTW 实验结果	65
图 6.4 加权前后实验结果对比	65
图 6.5 基于语义位置实验结果	66
图 6.6 基于语义标签实验结果	68
图 6.7 投票结果	71

摘要

最近几年，随着传统手机逐渐被智能手机所取代，搭载了智能操作系统(如 iOS、Android 和 Windows Phone)的智能手机已经成为了人们生活中集日常通信、娱乐游戏、商务办公、感知计算等于一体的移动掌上终端平台。通过搭载了更多传感器设备的智能手机能够随时随地的获取到用户的位置、通信记录、短信记录、日常轨迹分布情况等各种体现用户与用户之间的隐藏社会关系的感知信息。人们之间的轨迹相似性、日常轨迹的共现频率和时长，用户连接 Wi-Fi 的共现使用情况以及用户蓝牙之间的交互信息都能够分析得出人与人之间的交互关系以及他们之间的关系强度。通过对用户之间的相似性和关系强度的探究和计算有利于进一步发展个人的社交网络和探究社会群体结构的发展以及演变过程等。

传统的度量用户之间的社交关系大多采用的是基于社交关系数据来分析用户之间的社会关系(社交关系数据如通话记录，短信记录，社交软件的交互等)，本文基于智能手机所采集的非社交关系数据针对如何使用非社交关系数据来分析度量人们社交活动之间的相似性以及关系强度问题展开了进一步的深入研究。设计并且实现了一个基于用户轨迹数据、Wi-Fi 感知数据、蓝牙感知数据抽象出的多个层次的度量人与人之间在社交活动中相似性以及关系强度的计算模型 RSMHD(Relationship Strength based on Multiple Hierarchy Dimension)。整个计算模型的主要涵括的内容如下：

为了便于研究的顺利开展，我们假设陌生人之间的关系强度应该是无限趋近于零的，同时我们为了便于对计算结果的准确性进行判断和数据的采集，本文研究对象主要限于在校学生群体。社会心理的理论支持以及研究成果指出：相似的人更容易产生交集成为朋友，现实生活中人们也更加倾向于同自己相似的人做朋友，也就是说相似导致喜欢，从而发展为友情或者爱情。这也就预示着相似度人与人之间的关系强度要高于非相似着，这也就为我们的研究提供了理论依据。

首先，针对用户日常轨迹数据我们分别从空间移动轨迹和现实语义轨迹出发，对用户之间的相似性进行计算，本文采用位置漂移修正算法对部分因无信号原因导致的 GPS 位置缺失的轨迹进行预测补全；针对补全后的用户轨迹，采用时间片式的卡尔曼滤波算法剔除用户 GPS 轨迹中的异常点；采用基于时间 - 密度的聚类算法得到用户空间轨迹中的停留点，在此基础上，采用基于语义规则的语义标签标注机制，通过用户参与，反地理编码等手段对停留点进行现实语义标注，将用户的空间轨迹转变为符合现实意义的日常语义轨迹，为利用位置

感知数据来计算用户的关系强度做好准备。然后针对用户空间语义轨迹，本文采用了快速 DTW 计算方法来计算用户空间轨迹之间的相似性，并采用动态加权算法对计算结果进行加权处理；针对日常语义轨迹，我们分别从两个层次出发，一方面采用了 Word2vec 来计算用户在切片时间内的语义轨迹的相似性；另一方面，根据用户的语义轨迹挖掘出用户的轨迹运动模式，通过快速计算相似度算法 Simhash 来计算出用户的日常轨迹运动模式之间的相似性并对结果采取加权处理得出用户之间的关系强度，最后对计算结果进行融合来得出用户的关系强度。

其次，针对用户 WiFi 感知数据，采用关联拓扑图表示某个时刻的用户 WiFi 上下文环境信息，然后提取出用户 WiFi 的交互情况作为计算用户关系强度的特征之一；针对时间片上的拓扑图创新的提出了通过计算图与节点之间的相似性作为某时刻 WiFi 上下文环境信息之间的相似性。针对用户的蓝牙感知数据，通过结合脸呀交互时长、交互频率、蓝牙上下文环境相似性等来计算出用户之间的关系强度。

最后，利用集成学习的思想对以上三种不同感知数据源计算结果进行融合处理，得到基于不同非社交数据源所计算得到的最终用户关系强度。在该模型算法研究的基础上，本文基于自主开发的用户上下文信息收集系统 StarLog 收集了多名学生成长时间的智能手机感知数据，利用该数据源来计算出用户之间的关系强度，并结合用户的相似度问卷调查表对结果进行有效性验证，表明该模型能够有效地利用非社交关系度量出用户之间的关系强度。

关键词: 关系强度；轨迹相似度；DTW；熵；LDA；投票

ABSTRACT

Smart phones have become an integral part of daily life communication tools, we can collect intelligently location, call logs, text messages, WeChat anywhere which reflect a variety of information daily interactions and social relations between people. People interaction frequency, time, location, distance and the similarity of trajectory information reflects the strength of the relationship and the relationship between people. Relationship strength reflects the degree of intimacy between two different persons, which is of great importance in analyzing human's social relationship as well as social network.

In this paper, we propose a URSHV(User Relationship Strength Hierarchy Vote), which can measure the relationship between people in daily life through GPS data from three levels, namely: daily trajectory, semantic locations and semantic labels. To sum up, the main research contents and contributions are as follows:

First of all, the strength of the relationship between users and semantic location with semantic labels are closely related, this paper uses segmented kalman filtering algorithm on GPS trajectory data to de-noising; using the clustering algorithm based on density of position trajectory data clustering, and form a semantic position; on this basis, the semantic annotation mechanism based on Rules, the semantic annotation of semantic encoding, geographic location by anti semantic label inference and input auto completion etc; the GPS position trajectory data sequence clustering into meaningful semantic position and semantic labels, which laid the foundation for the semantic location and semantic labels based on the strength calculation of the relationship between users.

Secondly, in order to calculate the strength of the relationship between users from the three levels of trajectory data, semantic location and semantic labels, using DTW model of spatial distance calculation between users to measure the similarity between the users, the use of trajectory sequence similarity of users every day to track the entropy weighting processing, and the strength of relationship between users the LDA were calculated using the topic model; semantic locations similarity and semantic labels based on behavior patterns among users, as the strength of the relationship between users; measurement results of three levels of the ensemble learning theory to vote, to vote as the strength of relationship between end users.

Finally, on the basis of the above study, based on the MIT reality mining project of publicly available data sets, similarity between users by using the data set of the questionnaire, users construct between a real relationship strength as a benchmark for testing proposed an inverse logarithmic induced score measurement method to measure the strength of the relationship between users based on, and effectiveness model of URSHV for experiments, the results show that the model can effectively measure the strength of the relationship between users.

Key Words: relationship strength; trajectory similarity; DTW; entropy; LDA; vote

第一章 绪论

本章主要介绍本课题的研究背景、研究现状、主要研究内容以及论文结构。

1.1 研究背景

目前，内嵌了各种各样功能丰富的传感器的智能手机已经成为人们日常生活中集通信、感知及计算于一体的移动平台。通过内嵌的各种传感器如 GPS、加速度、麦克风、光线以及磁力传感器等可以随时随地感知和获取人们自身及其周围环境的各种信息，通过对这些信息的处理可以了解人们的日常交互关系^[1]、情绪^[2]、行为模式^[3]、活动状况^[4]、交通状况^[5]以及环境噪音^[6]等。其中，通过智能手机所收集各种数据研究人们之间的日常交互行为和人们之间的社会关系成为普适计算领域的一个重点研究的问题，针对这一问题，研究人员开展了大量的研究工作，并取得了一系列的研究成果。RealityMining^[1] 基于手机所收集的各种数据推理人们之间的社会交互关系以及群组的活动韵律，从而洞察个人和组织的行为模式；CenceMe^[3] 利用智能手机获取的 GPS 位置以及加速度等感知数据推理用户的当前状态包括行为活动、情绪、习惯以及朋友之间的交互情况，并将当前的状态发布到社交网站 Facebook 上与朋友进行共享；fMRI^[7] 重点研究分析了家庭和朋友圈对个体行为在社交网络中所受的影响；StudentLife^[8] 重点研究了在校学生的日常活动、交互情况与学生的精神健康以及学业成绩之间的关系；文献 [9] 则从多渠道、细粒度地收集各种反映在校学生日常活动和交互情况的各种数据，从多个层面真实、全面地反映学生日常活动以及他们之间的交互行为和交互关系。但是，这些研究重点关注的是人们之间的日常交互行为和交互关系，并没有涉及人们之间的关系强度。关系强度度量的是人们之间的亲密程度，通过关系强度，我们可以更好地了解人们之间的关系的强弱，了解人们之间的亲密程度，进而可以更好地预测社会关系的演变、社交结构的变化、促进信息传播以及传染病的预防与控制等。

目前，智能手机已经成为人们日常生活当中不可或缺的通信交流工具，通过智能收集可以随身随地的获取位置、通话记录、短信、微信等体现人们之间日常交互和社会关系的各种信息，人们之间的交互频率、时间、位置、地点、距离以及轨迹相似性等信息能够直接体现人们之间的交互关系以及关系强度，因为关系密切的人们之间更愿意面对面地进行交流，而且朋友之间尤其是好友之间会经常碰面如聚合、去餐馆、一起游览等等，通过对这些信息的分析处理，可以更好地度量朋友之间的关系强度。

1.2 研究现状

1.2.1 社会关系强度的研究现状

社会关系强度理论从 Mark Granovetter 对弱关系的研究^[10] 开始, Burt 在弱关系理论的基础上提出了结构洞理论^[11]。Granovetter 等^[10] 认为弱关系和强关系的测量应该考虑四个维度, 即两个用户之间的互动频率、用户感情的投入程度、两个用户之间的关系亲密程度以及两个用户在互惠互利上的交换程度; Wegner 等^[12] 指标化了这四个维度, 从而可以使用数值来度量强关系和弱关系; Muncer 等^[13] 认为关系的数量和交往的频率对关系强度有重要的影响; Paolillo 等^[14] 发现亲密程度和语言交流中非正式称呼出现的次数有直接关系。随着众多学者对关系强度的研究不断深入, 逐渐形成了从互动频率、联系次数和亲密程度这三方面作为关系强度核心测量指标的主流研究观点^[15]。

1.2.2 基于移动数据的社会关系研究现状

Eagle 等^[16] 招募了 100 名志愿者, 记录他们手机上的蓝牙信息, 以此为基础, 通过分析志愿者之间的相遇次数来研究志愿者之间是同事关系或朋友关系。Miluzzo 等^[3] 使用诺基亚智能手机 N95 开发了一款名为 Cenceme 的应用, 该应用能够实时采集手机中传感器产生的数据, 通过对采集的传感器数据的分析, 研究用户所处的状态以及任意两个用户之间的关系。Mtibaa 等^[17] 收集了 28 个参加同一个计算机会议的参会者的蓝牙数据, 并利用对这些数据的分析结果构建了社会网络关系图。Crandall 等^[18] 尝试利用不同用户同时在相同地理位置的出现次数来推断社交链接。他们研究发现即使两个用户在同一地理位置的同时出现次数比较少, 这两个用户也有很大可能相互认识。

1.2.3 基于移动轨迹数据关系强度的研究现状

物理层次的交互, 比如面对面的交流更有可能反映社会关系的真实状态。但是到目前为止, 这方面研究还比较少, 文献 [19] 首次使用移动轨迹数据来度量用户之间的关系强度。文献 [19] 提出了一个层级熵关系度量方法 HERMA(Hierarchical Entropy-based Relationship Measurement Approach)。HERMA 利用对从轨迹中抽取的位置共现记录的分析来推断用户之间的物理交互, 进而使用用户之间的物理交互来度量用户之间的社会关系强度。HERMA 设计了一个层级区域结构来对用户的位置共现记录建模。并在此基础上, HERMA 进一步提出用户熵和区域熵分别来度量用户的活跃性和区域开放性。最后在仿真数据集上对该方法进行了实验验证。

1.3 研究内容

本课题针对如何通过轨迹数据度量用户之间的关系强度问题展开研究，力求设计一个能够同时处理基站数据和 GPS 数据的通用框架模型。希望能从多个角度利用轨迹数据来度量用户之间的关系强度，经过调研和研究，决定从轨迹空间距离和基于主题模型的行为模式相似度两方面来度量用户之间的关系强度。课题中，为了达到所期望的目标，从以下三个方面展开研究。

(1) 如何对 GPS 数据进行处理以及标记语义标签

GPS 原始数据存在较大误差，且用户日常活动存在大量路上的点，而实际只需要考虑用户停留在宿舍、实验室等语义位置相关的点，故需要对 GPS 数据进行降噪并剔除路上的点。在此基础上，需要通过一些方法发现与 GPS 原始数据对应的如宿舍、实验室等语义位置，进而对每个语义位置标记对应的语义标签。在本课题中，通过对各种滤波算法进行试验，发现分段卡尔曼滤波有非常好的降噪效果；通过对 GPS 数据的进一步分析，发现路上点的密度远小于用户处于语义位置时的点的密度，因此采用基于密度的异常点剔除方法，且该方法可以自动学习参数；当前该领域用来发现语义位置的聚类算法存在一些问题，比如需要预先知道类别的个数或者对参数比较敏感，本科题决定采用最新提出的一个基于密度的聚类算法^[20] 来发现语义位置，该方法对参数更鲁棒，且不需要预先知道类别个数；在得到语义位置的基础上，需要通过一些方法匹配语义位置对应的语义标签，目前通用的方法是人工手动标注，经过分析发现可以通过反地理编码，语义标签推断以及输入自动补全来减少用户和语义标签标注系统的交互。

(2) 如何使用轨迹数据来度量用户之间的关系强度

a) 基于轨迹空间距离的关系强度度量方法

用户轨迹的相似程度在一定程度上反映了两个用户之间的亲密程度，本文尝试使用基于轨迹空间距离的方法来度量用户之间的关系强度。以往的研究中较多学者使用欧氏距离，编辑距离，DTW 等方法来研究轨迹之间的相似度。但是，存在的一个问题，欧氏距离只能用来度量两个长度相等的轨迹序列的相似度，通过实验发现使用编辑距离计算得到的相似度效果不是很理想，而 DTW 更偏向于序列长度较长的序列。在此基础上，对 DTW 的相似度度量结果使用三种方法归一化。并且发现用户每天活动的多样性不同使得该天轨迹数据的相似度对最终的相似度贡献不同，因此，使用用户每天轨迹序列的熵值对用户每天的相似度加权，实验证明该方法确实能够得到一个更好的结果。

b) 基于主题模型的行为模式相似度度量方法

通过分析研究发现，用户语义位置、语义标签均可以视为自然语言处理中的单词，而用户每天的语义位置序列和语义标签序列均可以视为自然语言处理中的

句子，进而每个用户全部的语义位置序列和语义标签序列均可视为自然语言处理中的文档。因此可以从语义位置和语义标签这两个层次使用自然语言处理中一些度量文档相似度的方法来度量用户在不同层次行为模式的相似度。本课题使用 LDA 主题模型和 word2vec 模型分别来度量用户行为模式的相似度。并分析了不同的主题个数和不同的向量长度对实验结果的影响。

c) 如何对三层实验结果进行融合

前文分别研究了如何通过轨迹空间距离的方法度量用户之间的关系强度，如何通过基于语义位置的用户行为模式相似度度量用户之间的关系强度，以及如何通过基于语义标签的用户行为模式相似度度量用户之间的关系强度。在三层实验结果的基础上，如何对三层实验结果进行融合是一个很重要的问题。轨迹空间距离计算结果为两个用户轨迹的距离，距离越小说明两个用户关系强度越强，而基于行为模式的方法计算用户行为模式的相似度，相似度越大说明两个用户关系强度越强，因此不能通过简单的加权求和作为最终的关系强度，且因为数据量太少，无法通过训练来确定加权的权值。参考集成学习的思想，首先对三层方法的计算结果按关系强度进行排序，然后对和该用户关系第 k 强的朋友进行投票，若某个朋友出现两次及以上则认为该朋友与该用户关系第 k 强，否则取基于轨迹空间距离的方法度量的结果作为最终结果。通过实验证明，该投票方法进一步改善了该模型的效果。

本课题针对如何度量日常生活中人们之间的关系强度问题展开研究，提出了一个既可以对 GPS 数据进行处理又可以对基站数据进行处理，从日常轨迹、语义位置以及语义标签三个层次度量人们之间关系强度的层级模型 URSHV(User Relationship Strength Hierarchy Vote)。该模型首先采用 DTW 模型通过计算用户之间的空间距离来度量用户轨迹之间的相似度，进而使用轨迹序列熵值对用户每天轨迹的相似度进行加权处理，并将其作为用户之间的关系强度；其次，采用主题模型 LDA 分别计算用户之间的基于语义位置和语义标签的行为模式的相似性，将其作为用户之间的关系强度；最后，采用集成学习的思想对三个层次的度量结果进行投票，以投票结果作为最终的用户之间的关系强度。用户和陌生人之间的关系强度因为互相不认识应该为 0，即用户和朋友之间的关系强度应该大于用户和陌生人之间的关系强度。但是对用户来说，虽然一些陌生人不认识，但是经常在一些地方同时出现，因此使用轨迹不能完全反映用户和所有人的关系强度，只考虑用户和其好友之间的关系强度。

(3) 如何对实验结果进行评估以及不同参数对模型的影响

本课题实验结果为用户的全部朋友按计算得到的关系强度由强到弱组成的朋友序列，实际结果是用户的全部朋友按实际关系强度由强到弱组成的朋友序列，

如何度量两个包含相同元素的有序序列的一致性是本课题很重要的一个问题。本课题设计的模型中包含大量的参数，而这些参数究竟对模型有什么样的影响也是本课题很重要的一个问题。所以，在本课题中，首先基于有序序列逆序对的概念提出一种称为一致性评分的度量方法来度量两个包含相同元素的有序序列的一致性；在此基础上，通过实验观察并分析本课题设计的模型中包含的每一个参数对一致性评分的影响来研究不同参数对模型的影响。

1.4 论文结构

本文的论文结构由六章组成，各章内容概述如下：

第一章为绪论，主要描述了课题的研究背景引出本文主要研究动因，然后从社会关系强度、基于移动数据的社会关系、基于移动轨迹数据关系强度的研究现状进行了分别描述，在此基础上，提出了课题的三个主要研究内容，最后给出了论文的组织结构。

第二章的主要内容为相关技术研究，描述了三方面与课题工作密切相关的技术。首先从滤波算法和聚类算法两方面描述了轨迹数据预处理的主要技术，并对其进行分析；其次分析了时间序列相似度能够在一定程度上反映用户之间的关系强度，并描述了时间序列相似度度量方法中的两种主流算法，编辑距离和 DTW，以及序列熵值的计算方法；最后分析了自然语言处理方法对轨迹数据处理的有效性以及主题模型和用户行为模式之间的关系，并描述了两种常用的自然语言处理模型，LDA 主题模型和 word2vec 神经语言模型。

第三章描述了用户关系强度层级投票模型的整体框架图，主要包括 SASLL 系统，该系统包括对 GPS 数据的处理以及语义标签标注技术；用户关系强度计算方法。这两个模块将在第四章和第五章分别进行描述。

第四章主要描述了如何处理 GPS 数据以及语义标签标注技术。首先描述了 SASLL (System Annotating Semantic Label of Location) 系统框架；其次从降低数据噪声、剔除异常点、聚类得到语义位置三个方面描述了如何计算得到对应语义位置；最后描述了如何发现新位置以及如何计算新位置的语义标签提示。

第五章描述了用户关系强度的计算方法。首先描述了模型框架；其次分别描述了轨迹数据的处理与准备、语义位置数据的处理与准备以及语义标签数据的处理与准备三种方法；最后分别描述了基于轨迹数据的关系强度计算、基于主题模型的关系强度计算以及结果投票三个方法。

第六章首先描述了实验用到的数据集；其次描述了对实验结果的评估方法；最后展示了实验结果并进行分析。

第七章对本课题作出总结，并对接下来的工作作出展望。

第二章 相关技术研究

上一章详细描述了课题的研究背景，并深入分析了相关工作和研究现状，最后给出了课题主要研究的四部分内容。本章将详细分析与课题研究内容相关的一些关键技术，包括轨迹数据预处理技术、时间序列相似度度量方法及序列熵值和自然语言处理模型。

2.1 轨迹数据预处理

轨迹数据存在大量噪声，通过对轨迹数据的来源进行分析，可以将其视为数字信号，而滤波是对数字信号降噪非常实用的方法。对于采集的轨迹数据，需要通过一些处理得到这些数据对应的语义位置，通常使用各种聚类算法来达到这一目的。因此本节将首先描述各种常用滤波算法，然后描述各种常用聚类算法。

2.1.1 滤波算法

滤波是将信号中特定波段频率滤除的操作，是抑制和防止干扰的一项重要措施。因为人类移动是连续的，所以 GPS 采样结果也应该是连续的，但因为采样过程中存在误差，从而使得采样结果有可能发生跳变，因此需要通过滤波算法估算出跳变点的实际值。下文主要描述均值滤波，中值滤波和卡尔曼滤波这三种滤波方法。

均值滤波：均值滤波也称为线性滤波，通常采用领域平均法，即考虑以当前采样点为中心，前 k 个采样点和后 k 个采样点的平均值作为当前采样点对应的值，计算公式见公式2.1。

$$g(i) = \frac{1}{2k} * \sum_{j=i-k, j \neq i}^{i+k} g(j) \quad (2.1)$$

中值滤波：中值滤波是一种非线性平滑技术，将当前采样点某邻域窗口内所有采样点的中值作为当前采样点对应的值，计算公式见公式2.2。其中 $median(A)$ 表示计算序列 A 的中值。

$$g(i) = median(g(i - k), ..., g(i - 1), g(i), g(i + 1), ..., g(i + k)) \quad (2.2)$$

卡尔曼滤波：卡尔曼滤波是卡尔曼于 1960 年提出的^[21]，简而言之，卡尔曼滤波是一个最优化自回归数据处理算法。下文将简要描述卡尔曼滤波器算法的原理。

首先，引入一个离散控制过程系统。该系统可以使用一个线性随机微分方程来描述，见公式2.3。在此基础上，再加上系统的测量值，见公式2.4。 $X(k)$ 是 k 时

刻的系统状态， $U(k)$ 是 k 时刻对系统的控制量。 A 和 B 是系统参数，用于多模型系统，都是矩阵。 $Z(k)$ 是 k 时刻的测量值， H 是测量系统的参数，对于多测量系统， H 为矩阵。 $W(k)$ 和 $V(k)$ 分别表示过程噪声和测量噪声。通常认为是高斯白噪声，协方差分别是 Q 和 R ，假设噪声协方差不随系统状态变化而改变。

$$X(k) = A * X(k - 1) + B * U(k) + W(k) \quad (2.3)$$

$$Z(k) = H * X(k) + V(k) \quad (2.4)$$

如果满足上述条件（线性随机微分系统，过程和测量相关的噪声都是高斯白噪声），卡尔曼滤波器是最优的信息处理器。下文给出如何估算系统的最优化输出。

首先利用系统的过程模型，预测下一系统状态。假设当前的系统状态为 k ，根据系统模型，基于系统的上一状态可以预测出当前的状态，见公式2.5。其中 $X(k|k-1)$ 是基于上一状态预测的结果， $X(k-1|k-1)$ 是上一状态最优的结果， $U(k)$ 为当前状态的控制量，如果没有控制量，则为0。

$$X(k|k-1) = A * X(k-1|k-1) + B * U(k) \quad (2.5)$$

更新系统结果后，下一步更新 $X(k|k-1)$ 对应协方差（用 P 来表示），更新见公式2.6。其中 $P(k|k-1)$ 是 $X(k|k-1)$ 对应的协方差， $P(k-1|k-1)$ 是 $X(k-1|k-1)$ 对应的协方差。 A' 表示 A 的转置矩阵， Q 是系统过程的协方差。

$$P(k|k-1) = A * P(k-1|k-1) * A' + Q \quad (2.6)$$

在当前状态的预测结果的基础上，收集当前状态的测量值。结合预测值和测量值，可以得到现在状态 k 的最优化估算值 $X(k|k)$ ，见公式2.7。其中 $Kg(k)$ 为状态 k 的卡尔曼增益，见公式2.8。

$$X(k|k) = X(k|k-1) + Kg(k)(Z(k) - H * X(k|k-1)) \quad (2.7)$$

$$Kg(k) = P(k|k-1) * H' / (H * P(k|k-1) * H' + R) \quad (2.8)$$

得到 k 状态下最优的估算值 $X(k|k)$ 后，需要更新 k 状态下 $X(k|k)$ 对应的协方差，见公式2.9。其中 I 为1的矩阵，对于单模型单测量， $I = 1$ ，按照上文所述的全部公式即可以通过迭代的方法计算得到最优的估算值。

$$P(k|k) = (I - Kg(k) * H)P(k|k-1) \quad (2.9)$$

对于均值滤波，中值滤波以及卡尔曼滤波三种滤波算法而言，均值滤波比较容易受跳变的影响，中值滤波比均值滤波更鲁棒，卡尔曼滤波效果会更好一些，但是模型也更复杂，运算复杂度相较前两种滤波算法来说也会大一些。

2.1.2 聚类算法

聚类算法是无监督学习中非常重要的方法之一。文献 [22] 聚类分析仅根据在数据中发现的描述对象及其关系的信息，将数据对象分组。其目标是，组内的对象相互之间是相似的（相关的），而不同组中的对象是不同的（不相关的）。组内相似性越大，组间差别越大，聚类就越好。聚类算法主要分为以下几种，划分的聚类算法，如 K 均值算法；层次聚类算法；基于密度的聚类算法，如 DBSCAN；基于原型的聚类算法，如模糊聚类；基于网格的聚类算法以及基于图的聚类算法。本节主要介绍 K-MEANS 聚类算法，DJ-Cluster 聚类算法以及 14 年发表在 Science 上的聚类算法。

K-means 是由 J.MacQUEEN 在 1967 提出的一种非常简单、高效的聚类算法^[23]。其算法基本思想是：随机初始化 K 个点，作为 K 个类别的中心，计算每个点到每个类别中心的距离，将该点划分到距离最近的类别中，对每个类别，将属于该类别的所有点的平均值作为该类别新的聚类中心，不断执行该步骤直到每个类别的聚类中心收敛。其原理示意图见图2.1。该算法优点为思想简单，易于实现，且算法复杂度低，故而对于处理大数据集，该算法是相对可伸缩和高效率的；若待分类的簇是密集的、球状或团装的，而簇与簇之间有明显区别，则能得到非常好的聚类效果。该算法缺点是用户必须事先知道类别的个数；而且该算法对初始值敏感，对于不同的初始值，可能产生不同的聚类结果；不能适用于簇是非凸面形状或者大小差别很大的情况；最后该算法对噪声和孤立点数据敏感，这些数据容易对聚类中心产生极大的影响，从而影响聚类的结果。

DJ-Cluster 是 Zhou C 在 2007 年提出的一种基于 DBSCAN 的聚类算法^[24]。DJ-Cluster 算法的基本思想是计算每个点的密度，若密度值小于某给定值 *MinPts*，且其所有邻居密度都小于给定值，则该点为异常点；否则，若该点所有邻居都不属于一个存在类别，则新建一个类别；否则与邻居中存在的类别合并。算法原理示意图见图2.2。密度的定义见公式2.10。点 p 的密度是 $N(p)$ 中元素的个数， $N(p)$ 是点 p 所有邻居组成的集合。 $dist(p, q)$ 指 p 和 q 之间的欧氏距离。该算法聚类效果依赖 *Eps* 和 *MinPts* 两个常量的设置，且对这两个参数比较敏感。

$$N(p) = \{q \in S | dist(p, q) \leq Eps\} \quad (2.10)$$

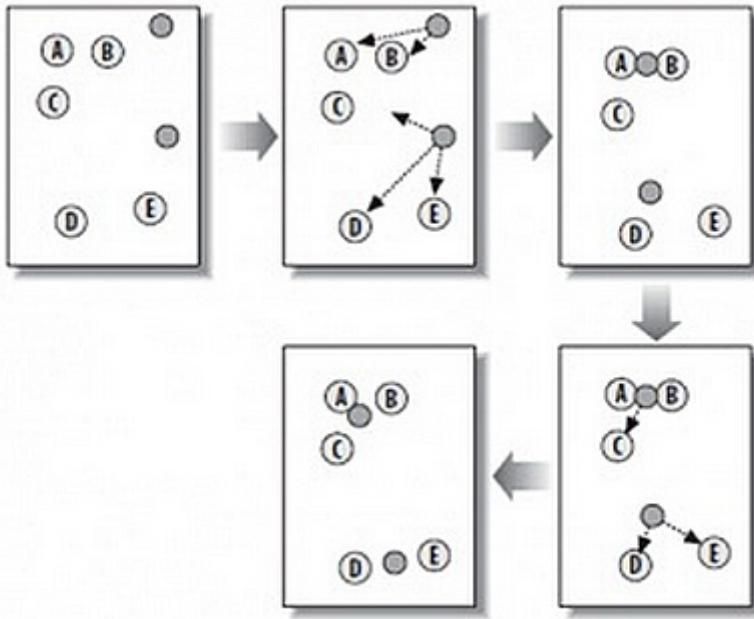
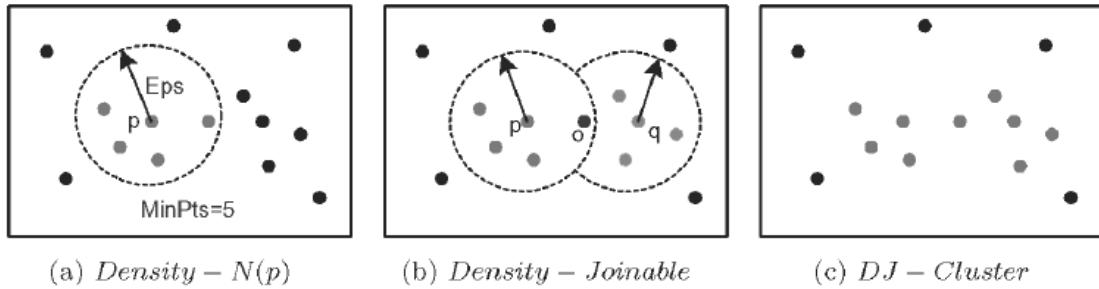
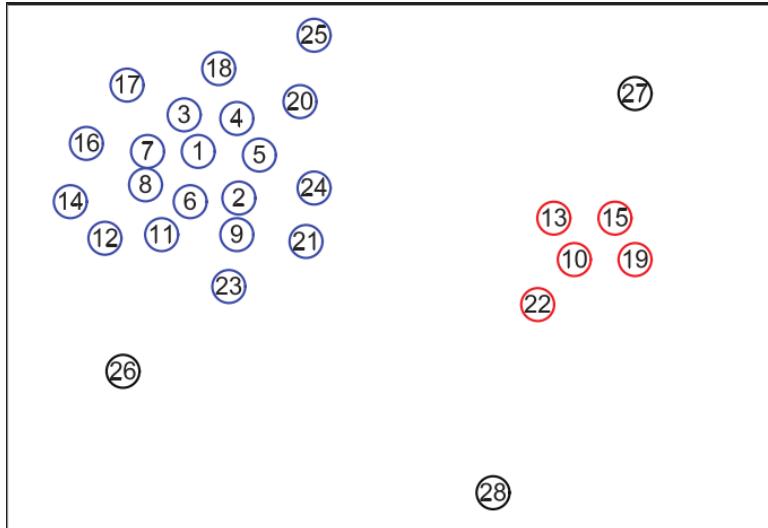
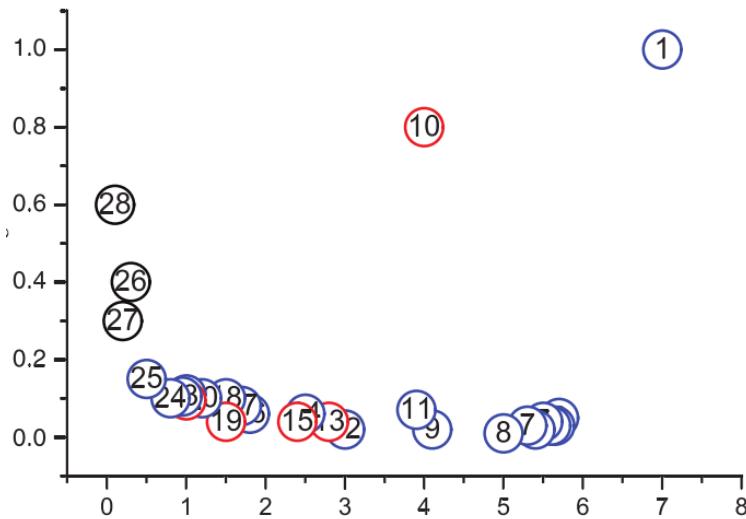


图 2.1 K-MEANS 算法原理示意图

图 2.2 DJ-cluster 聚类算法原理示意^[24]

Rodriguez A 等人 2014 年在 Science 上发表了一种新的基于密度的聚类算法^[20]。该算法不需要类别个数的先验知识，对参数也不敏感。该算法的基本思想是：计算每个点的密度（定义见公式2.10）；计算每个点的距离，定义为该点与密度大于该点的所有点中距离最近的点之间的距离，若该点密度最大，则距离为所有点中与该点距离最远的点之间的距离；按距离对所有点排序，取前面若干个点作为聚类中心（若相邻两个点值差别非常大则以较大点作为聚类中心最后一个点）；每个点的类别与密度大于自己且距离最近的点的类别一致。算法原理示意见图2.3和图2.4。

总的来说，上述三种聚类算法通过精心调整参数都能取得非常好的聚类效果。不同的算法拥有不同的优缺点，在第四章我们将通过实验来展示各种算法在不同参数下的聚类结果。

图 2.3 按密度排序^[20]图 2.4 按距离排序, 1、10 为聚类中心^[20]

2.2 时间序列相似度度量方法及序列熵值

空间距离能够直观反映用户在物理世界的距离。根据社会心理学的研究成果, 文献^[25]在一个大型住宅区研究了接近性效应 (接近性效应指两个人住的越近越可能是朋友), 结果表明人们居住得越近, 不管这种近是物理距离还是功能性距离, 人们越容易称为朋友。文献^[26]用实验证实了单纯接触效应, 即熟悉性能够促进好感, 实验结果表明接触频率越高喜欢程度越大。而空间距离非常接近的用户在现实生活中会有更多的面对面的交互, 从而增强两个人之间的关系强度。通过日常生活体验我们也很容易发现, 如果两个人在晚上等休息时间经常一起出去, 则其关系可能更亲密, 因而他们之间的轨迹越可能相似。因此, 我们可以使

用熵值来度量用户每天活动的多样性，若某天活动越多样，则该天轨迹的相似度对总体轨迹的相似度贡献越大，进而对用户之间的关系强度贡献越大。

用户的轨迹序列由带有时间戳的位置数据构成，位置数据可能是 GPS 也可能是基站号。因此我们可以将轨迹序列看作时间序列，从而使用一些时间序列相似度度量模型来度量轨迹的相似度，下面依次描述编辑距离和 DTW 这两种相似度度量方法以及序列熵值的计算方法。

2.2.1 编辑距离

编辑距离是 Levenshtein 于 1965 年提出的一种度量两个字符串之间距离大小的方法^[27]，又称为 Levenshtein 距离。其定义为一个字符串通过插入，删除，改变这三种操作转变为另一个字符串所需要的最少的操作的步数。插入操作是指在某个位置添加一个字符；删除操作是指删除某位置的字符；改变操作是指把某个字符变成另外一个字符。

若直接计算编辑距离会发现其时间复杂度为指数级别从而使得实际不可计算。通过深入分析发现该问题存在重叠子问题和最优子结构，因此可以用动态规划的思想把算法复杂度降低到多项式级别。其递推公式见公式2.11，其中 $s1, s2$ 表示两个字符串， $M[i, j]$ 表示字符串 $s1[0 : i]$ 和字符串 $s2[0 : j]$ 之间的编辑距离。 $E[i, j]$ 指 $s1[i]$ 和 $s2[j]$ 之间的距离，若两个字符相同，则距离为 0，否则距离为 1。

$$M[i, j] = \min(M[i1, j], M[i, j1], M[i1, j1] + E[i, j]) \quad (2.11)$$

编辑距离的计算对象是字符串，因此，经过一些学者的研究，将其扩展到实数域^[28]，称为 EDR (Edit Distance on Real sequence)，并对每个操作附加权重^[29]，称为 ERP (Edit distance with Real Penalty)。在实数域中，若两个实数非常接近，则认为这两个数相等，否则认为不相等。ERP 对两个相等的数用这两个数的差作为实数惩罚值，否则用其中一个数与一个常量的差做为实数惩罚值。其计算过程与原始编辑距离计算过程类似。

2.2.2 Dynamic Time Warping

DTW(Dynamic Time Warping) 是 Itakura 于 1987 年提出的距离度量方法^[30]，主要用于识别两个读音是否表示同一个单词，Berndt^[31] 使用 DTW 方法来度量时间序列的相似度，从而发现时间序列中的模式。

假设有两个时间序列，序列 Q 长度为 n （见公式2.12），序列 C 长度为 m （见公式2.13）。为了计算两个序列之间的 DTW 距离，需要构造一个 $n * m$ 矩阵 d ，其中 $d[i, j]$ 表示序列 Q 第 i 个元素 q_i 和序列 C 第 j 个元素 c_j 之间的距离，通常使用欧氏距离作为两个元素之间的距离度量。构造 $n * m$ 矩阵 γ 。为了寻找这两个序列

之间的最佳匹配，需要寻找一条路径使得累积距离 $\gamma[i, j]$ 最小化，可以通过使用动态规划的方法来找到这条路径， $\gamma[n, m]$ 为最终的 DTW 距离，其递推公式见公式2.14。 $d[i, j]$ 指 q_i 和 c_j 之间的欧式距离。 $\gamma[i, j]$ 是指当前的累积距离，路径及矩阵可视化见图2.5。其中：A) 两个异相的相似序列 Q 和 C；B) 为了匹配这两个序列，构造了一个变形矩阵，并搜索最佳的变形路径即红色所示路径，且将搜索局限到一个窗口中；C) 匹配结果

$$Q = q_1, q_2, \dots, q_i, \dots, q_n \quad (2.12)$$

$$C = c_1, c_2, \dots, c_j, \dots, c_m \quad (2.13)$$

$$\gamma[i, j] = d[i, j] + \min\{\gamma[i - 1, j - 1], \gamma[i - 1, j], \gamma[i, j - 1]\} \quad (2.14)$$

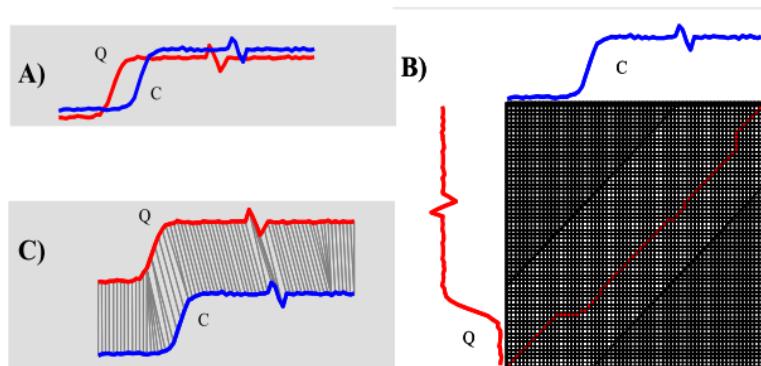


图 2.5 引自文献 [32]DTW 原理示意图。

通过深入分析 DTW 算法可知，序列的长度越长，则距离可能越大。因此，采用文献 [32] 中的三种归一化方法对 DTW 的计算结果进行进一步的处理和优化，即 DTW 结果除以最优变形路径的长度、DTW 结果除以两个序列中较短序列的长度以及 DTW 结果除以两个序列中较长序列的长度等三种方法对 DTW 计算结果进行归一化，以便获得最优结果。

2.2.3 序列熵值

通过对用户每天产生的轨迹序列的分析，可以将其看作一个由一系列随机变量 X_n 构成的随机过程序列 $X = \{X_1, X_2, \dots, X_n\}$ ， X_n 表示用户在时刻 n 所在的物理位置。熵通常用来度量一个系统的无序程度，熵越大表示该系统越混乱。若用户每天活动单一，则熵值会很小，若活动多样，则熵值会很大。因此，可以用熵值来

度量用户每天活动的多样性程度，香农熵的定义见公式如公式2.15，其中 $P(x_i)$ 是 $x_i = X_i$ 的概率。

$$H = - \sum_i p(x_i) \log_2 p(x_i) \quad (2.15)$$

对于一个长度为 n 的随机变量序列，需要考虑该序列的熵值如何随 n 增长，这个增长率称为熵率，熵率定义见公式2.16。同时，熵率存在一个相关的量，定义见公式2.17。对于平稳随机过程，这两种定义的极限均存在且相等^[33]。

$$H(\mathbf{X}) = \lim_{n \rightarrow \infty} \frac{1}{n} H(X_1, X_2, \dots, X_n) \quad (2.16)$$

$$H'(\mathbf{X}) = \lim_{n \rightarrow \infty} H(X_n | X_{n-1}, X_{n-2}, \dots, X_1) \quad (2.17)$$

由于条件熵值（公式2.17）难以直接计算，因此通常使用估量值来计算熵率，常用的估量值主要包括 LZ (Lempel-Ziv) 估量值^[34] 以及实时 LZ 估量值^[35] 等。LZ 估量值的定义见公式2.18，其中 γ_i 定义为从位置 i 开始，不在序列 $(X_1, X_2, \dots, X_{i-1})$ 中出现的最短的子序列的长度。实时 LZ 估量值的定义见公式2.19 和 公式2.20，其中 δ_i 定义为以位置 i 结尾，不在序列 $(X_1, X_2, \dots, X_{i-\delta_i})$ 中出现的最短的子序列的长度。这两种度量实际上是等价的，在本文中我们使用实时 LZ 估量值，该估量值只利用当前已知的信息。

$$\hat{H}_N = \left(\frac{1}{N-1} \sum_{i=2}^N \frac{\gamma_i}{\log_2(i)} \right)^{-1} \quad (2.18)$$

$$\tilde{H}_i = \frac{\log_2(i)}{\delta_i} \quad (2.19)$$

$$\hat{H}_N = \frac{N}{\sum_{i=2}^n \tilde{H}_i^{-1}} \quad (2.20)$$

计算轨迹序列的熵值的目的是为了对 DTW 计算结果进行加权，因为用户每天的轨迹序列的相似度对其总体相似度的贡献是不一样的，如果某一天用户的轨迹序列的熵值越大，则这一天对总的相似度贡献越大，因此，使用用户当天轨迹序列熵值对用户与朋友之间每天的轨迹相似度进行加权，能够更真实地反应用户之间的关系强度（如何使用轨迹序列熵值对 DTW 的计算结果进行加权详见第五章第三小节）。

编辑距离和 DTW 都是非常常用的两种时间序列相似度度量方法，在第六章我们将通过实验展示这两种方法以及用序列熵值加权后的两种方法用来度量用户关系强度的效果

2.3 自然语言处理模型

在日常生活当中，用户之间尤其是好友之间其行为模式之间具有一定的相似性，如经常去某些地方、经常在某些时间段（晚上）去一些地方（餐馆、酒吧）等等。基于位置的用户行为模式一方面能够反映用户在物理层次的相遇，另一方面能够在一定程度上体现用户的相似性，前文已经从社会心理学的角度阐述了相遇次数与用户关系强度的关系，Singelis^[36]认为人们倾向于喜欢在态度、兴趣、价值观、背景和人格上和其相似的人，因此，在日常生活当中行为相似的人之间更可能成为朋友，而根据社会心理学的研究成果，用户的相似性对用户的关系强度也有一定的影响，为此，在通过基于用户轨迹度量用户之间关系强度的基础上，进一步通过基于位置的用户日常行为来对度量用户之间的关系强度。

通过将位置序列和自然语言中的句子进行类比，能够发现，自然语言处理中的这些方法可以很自然的用来处理位置轨迹数据。位置序列是用户轨迹语义层次的一种表示，例如一个学生一天的位置轨迹可以表示为宿舍、实验室、食堂、宿舍，实验室、食堂、宿舍。通过深入分析，认为自然语言中的每个句子受两方面的约束，即主观约束和客观约束。客观约束指句子的构造受到对应语言语法的约束；主观约束指在句子的构造过程中，部分词的使用和构造者的个人喜好相关。再来分析一下位置序列，位置序列的构成也受主观和客观这两方面的约束，客观约束指用户自身的社会角色限制了用户每天可能的位置序列；主观约束指用户在客观约束下，对于一些位置具有选择性，如用户可以自己决定去什么地方吃饭等。

文献 [37] 最先使用 LDA 主题模型发现用户的行为模式，在使用 LDA 模型发现用户基于位置的行为模式基础上，本课题进一步使用 LDA 主题模型来度量用户之间的关系强度，其核心思想如下：把每个用户每天参观过的位置（物理位置或语义位置）序列视为一个句子，每个用户所有天的位置序列视为一篇文档，对所有用户所有天的位置序列使用 LDA 主题模型训练得到若干个主题。在计算两个用户之间的关系强度时，将这两个用户同一天的数据按固定长度的时间片划分，对于每个时间片内用户参观过的位置，用训练好的 LDA 主题模型推断这些位置对应的主题分布，以同一时间片内，两个用户分别参观过的位置对应的主题分布的余弦相似度，作为这两个用户之间的关系强度（详细的计算过程见第五章第三节）。

word2vec 模型主要通过考虑当前词语的上下文环境来得到当前词语对应的实数值向量表示。而对应向量的相似度从一定程度上反映了两个词语义的相似度。因此在计算出每个语义位置对应的实数值向量后，希望对应向量的相似度能够从一定程度上反应两个语义位置功能的相似性。

2.3.1 Latent Dirichlet Allocation

LDA(Latent Dirichlet Allocation)^[38] 是 Blei 等人 2003 年提出的一个针对离散数据集合的产生式概率模型。LDA 是一个三层的层级贝叶斯模型（其结构如图2.6 所示），LDA 模型作为一个文本模型，每个文档由多个主题的概率分布来表示，每个主题由多个单词的分布来表示，图2.6 中每个方框表示执行，外框表示文档，内框表示文档内主题和单词的重复选取。假设有 K 个主题， W 个不同单词，一个给定词 ω_t 的概率见公式2.21，其中 z_t 表示产生第 t 个词的主题对应的隐变量。

$$p(\omega_t) = \sum_{k=1}^K p(\omega_t|z_t = k)p(z_t = k) \quad (2.21)$$

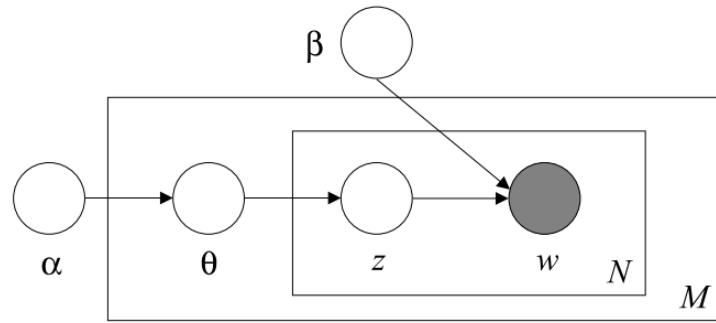


图 2.6 LDA 的图模型表示^[38]

LDA 推断的目的是计算每个主题的词分布 $P(w|z = k) = \varphi_w^{(k)}$ 和每个文档的主题分布 $P(z = k) = \theta_k^{(d)}$ 。在 LDA 中， $P(\theta)$ 服从 $Dirichlet(\alpha)$ 分布， $p(\varphi)$ 服从 $Dirichlet(\beta)$ 分布，其中 α 和 β 是超参数。LDA 模型的估计问题等同于求公式2.22 的最优化问题，但其计算非常复杂，故使用 MCMC(Markov Chain Monte Carlo) 方法求得近似解，其采样公式见公式2.23，其中 $n_k^{(\omega)}$ 和 $n_k^{(d)}$ 是单词 ω 和文档 d 分配给主题 k 的次数。

$$p(\omega|\varphi, \alpha) = \int p(\omega|\varphi, \theta)p(\theta|\alpha)d\theta \quad (2.22)$$

$$\varphi_k^{(\omega)} = \frac{n_k^{(\omega)} + \beta}{n_k^{(\cdot)} + W\beta}, \theta_k^{(d)} = \frac{n_k^{(d)} + \alpha}{n_k^{(k)} + K\alpha} \quad (2.23)$$

2.3.2 word2vec

随着深度学习的提出，概率语言模型也有了新的发展。当前已经有很多深度学习框架的自然语言处理模型，word2vec^[39] 是应用最广泛的一种。word2vec

共有四种模型，主要描述第一种使用 Hierarchical Softmax 的 CBOW(Continuous Bag-of-Words Model) 模型。该模型主要思想是依据已知当前词 w_t 的上下文 w_{t-2} , w_{t-1} , w_{t+1} , w_{t+2} 的前提下预测当前词 w_t 。该模型包括输入层，投影层和输出层。其网络结构^[40]如图2.7 所示。

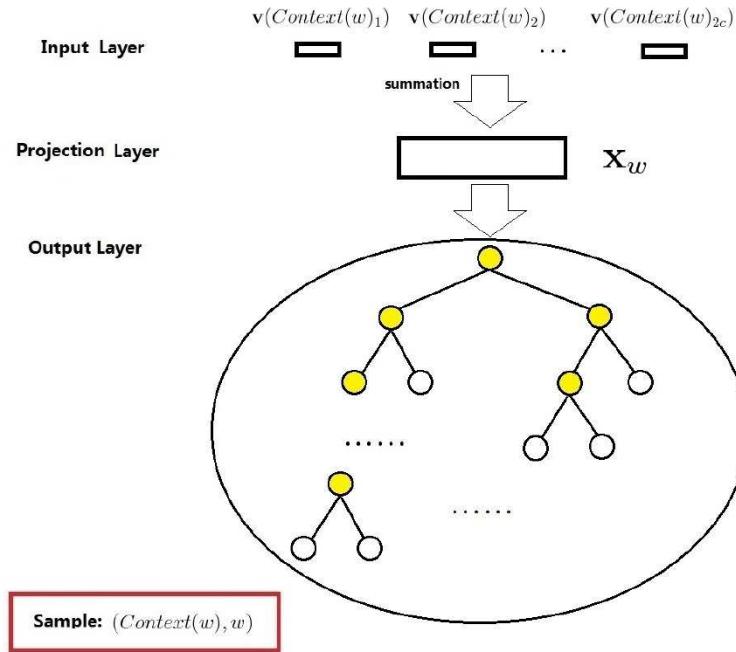


图 2.7 word2vec 神经网络结构图^[40]

输入层：由 $Context(w)$ 中 $2c$ 个词的词向量组成，每个词向量长度为 m ；投影层：对输入层的 $2c$ 个词向量按分量累加求和；输出层：输出层对应一棵二叉树，它以语料中出现过的词作为叶子节点，且以其出现次数为权值构造出来的 Huffman 树。

对词典 D 中的任意一个词 w ，Huffman 树中必存在一条从根节点到词 w （该词对应一个叶子节点）对应节点的路径（且这条路径是唯一的）。路径上存在大量分支，而每个分支可以看做一次二次分类，每一次分类产生一个概率，将这些概率全部乘起来，就是所需的 $p(w|Context(w))$ 。条件概率的一般公式可以写成公式2.24 和2.25。

$$p(w|Context(w)) = \prod_{j=2}^{1^w} p(d_j^w | x_w, \theta_{j-1}^w) \quad (2.24)$$

$$p(d_j^w | x_w, \theta_{j-1}^w) = [\sigma(x_w^T \theta_{j-1}^w)]^{1-d_j^w} * [1 - \sigma(x_w^T \theta_{j-1}^w)]^{d_j^w} \quad (2.25)$$

l^w 表示从根节点到节点 w 路径上所有节点的个数, d_j^w 表示路径上第 j 个词, x_w 表示词 w 对应的词向量, θ_{j-1}^w 表示路径上第 j 个非叶节点对应的向量。 σ 表示 SIGMOID 函数。

故该神经网络的目标函数见公式2.26。

$$L = \sum_{w \in C} \sum_{j=2}^{l^w} \{(1 - d_j^w) \log[\sigma(x_w^T \theta_{j-1}^w)] + d_j^w \log[1 - \sigma(x_w^T \theta_{j-1}^w)]\} \quad (2.26)$$

使用随机梯度上升法求得该目标函数局部最大值, 即可得到每个词对应词向量。

LDA 和 word2vec 在自然语言处理相关的应用中都得到了非常好的结果, 因此使用这两个算法度量用户之间的关系强度, 在第五章详细描述如何使用这两种方法度量用户之间的关系强度, 在第六章将通过实验展示这两个模型在不同的参数下对实验结果的影响。

2.4 小结

本章对与课题密切相关的三方面技术进行的详细的描述、分析和研究。2.1 节描述了 GPS 预处理中遇到的两个主要问题降噪和聚类。2.2 节描述了度量时间序列相似度的两种常见方法以及序列熵值的计算方法, 前两种方法用于计算轨迹序列的相似度, 并以此相似度作为用户之间的关系强度, 在此基础上用序列熵值对对轨迹序列的相似度加权。2.3 节描述了 LDA 和 word2vec 两种常见的自然语言处理模型, 这两种模型能够从不同的角度反映用户基于轨迹的行为模式。

第三章 用户关系强度层级投票模型框架

上一章描述了与本课题密切相关的三方面技术，这一章我们主要描述本课题的整体模型框架。

3.1 模型框架描述

本课题主要目标是利用用户的轨迹数据度量用户之间的关系强度。轨迹数据分为 **GPS** 数据和基站数据两种，本课题尝试提出一个通用的关系强度计算模型框架，希望能够使用同一个框架处理 **GPS** 数据和基站数据，见图3.1。但是 **GPS** 数据和基站数据在数据特性上有非常大的区别，**GPS** 是连续实数值，且有实际物理意义，而基站数据只是一个标号，数值本身没有实际物理意义，需要分别对 **GPS** 数据和基站数据进行处理，**GPS** 数据相较于基站数据而言，表示的物理位置更加精确，故需要一些额外的方法获取 **GPS** 数据的高层信息，比如物理位置、语义标签等。**GPS** 采样本身仍然存在误差，需要使用一定的方法来降低采样数据的误差。**GPS** 数据相较基站数据而言，需要更多的处理，一方面降低自身的误差，另一方面获取更高层信息。第四章将主要描述如何处理 **GPS** 数据以及如何获取更高层信息，对该模型框架左边的 SASLL 系统。第五章将主要描述如何使用轨迹数据度量用户之间的关系强度，本课题主要从原始轨迹数据、语义位置、语义标签三个层次来度量用户之间的关系强度，每一层输入数据的准备过程将在第四章第二节详细描述，**GPS** 数据的准备过程基于第四章提出的相关的处理技术。同样基站数据作为模型三层输入数据的准备过程也将在第四章第二节详细描述，基站数据的处理非常简单，不需要额外的技术，该模型右边相关模块简要说明了基站数据对应的三层模型输入数据的处理过程。

3.1.1 SASLL 系统概述

SASLL 是一个语义标签标注系统，使用传感器数据采集软件记录手机传感器数据，**GPS** 数据模块通过访问本地传感器数据存储文件，读入 **GPS** 数据相关的数据文件，并对文件数据进行 JSON 解析，得到原始 **GPS** 数据记录，每条记录格式为由经度、维度、时间戳组成的三元组 (**Lat,Lng,timestamp**)。预处理模块在本系统第一次执行时自动学习剔除路上点需要的参数，并使用基于密度的方法剔除路上的点，之后对于每天的数据使用分段卡尔曼滤波对原始 **GPS** 数据进行滤波，以降低数据的噪声。聚类模块对每天采集的数据使用文献 [20] 提出的聚类算法对预处理后的数据进行聚类，该算法在第一次运行时需要根据数据的特性设置阈值参数，然后得到每天参观过的位置，并与已标记表进行对比，计算得到新的位置。

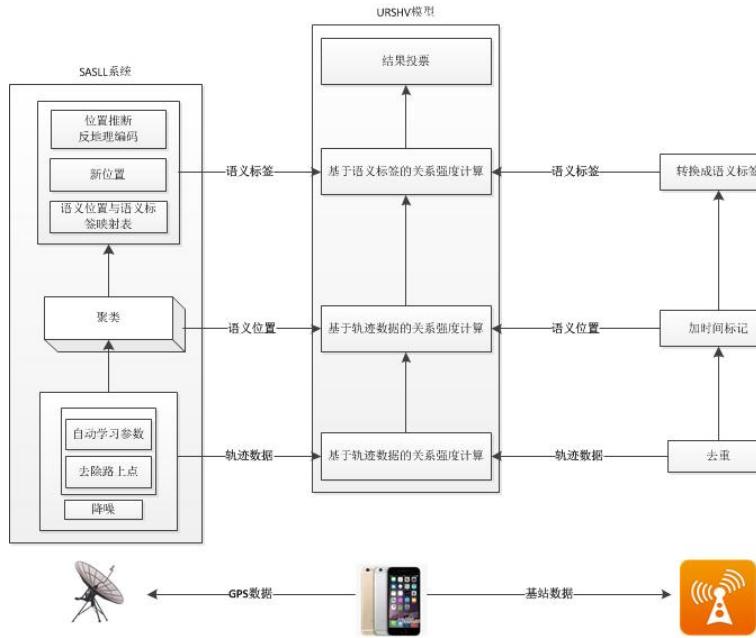


图 3.1 用户关系强度层级投票模型框架图

位置提示模块对新位置使用基于规则的推断方法推断新位置是否是家或办公室，如果都不是则调用地图接口计算反地理编码的方法计算其可能的语义标签，如果无对应反地理编码结果，则由用户手动输入新位置的语义标签。最后由交互模块和用户交互，展示位置提示模块计算的提示以及记录用户的标注。

3.1.2 用户关系强度计算模型概述

要真实全面反映人们之间的关系强度，需要从不同角度和不同层次对人们之间的关系强度进行度量，为此，我们提出了一个层次化的、对用户关系强度进行度量、并对度量结果进行投票的模型 URSHV，其框架结构如图3.1中间部分所示。URSHV 模型是一个三层的、能够对通过 GPS 和基站这两种方式采集的数据进行处理的度量模型，从轨迹、语义位置以及语义标签三个层次对人们之间的关系强度进行度量，并使用集成学习的思想对三个层次度量结果进行投票，最终以投票结果作为人们之间的关系强度。第一层度量主要针对用户的轨迹序列数据，考虑真实生活中，用户和用户之间的共同出现情况以及用户和用户之间错时出现情况（用户轨迹序列相似，但相同地方出现时间具有相同的滞后或超前），根据不同用户轨迹序列的相似度来度量用户之间的关系强度；第二层度量主要针对用户的语义位置序列数据，考虑用户个人的基于位置的行为模式如经常在什么时间出现在哪些位置等，根据不同用户行为模式的相似度来度量用户之间的关系强度；第三层度量主要针对用户的语义标签序列数据，物理上不同的位置可能拥有相同的语义标签，“办公室”、“家” 等语义概念在每个用户轨迹中都可能出现，而这些语

义概念在原始数据中会表现为不同的基站号和区域号或不同的 GPS 经纬度，因此用户的语义位置数据更能体现用户群体的日常习惯，因此本层考虑的行为模式更倾向于群体的行为模式，从而根据不同用户在群体中表现出的行为模式来度量用户之间的关系强度。

3.2 模型完整流程描述

首先使用采集应用记录手机传感器数据，包括 GPS 数据和基站数据。其次，对采集的 GPS 数据和基站数据分别进行处理。处理 GPS 数据：对 GPS 数据使用分段卡尔曼滤波算法进行降噪处理，对每天的 GPS 数据进行划分，等时间均分为若干份，对每份数据计算其 GPS 经纬度均值作为这段时间的 GPS 数据，通过这样处理以后，可以把每天的 GPS 序列降到一个比较小的维度，其长度等于按时间均分的份数。处理基站数据：对每天的基站数据进行划分，等时间均分为若干份，对每份数据进行集合操作，使得该份数据内，基站不重复，把每一份数据重新拼成一个基站序列。计算两个用户的关系强度时，对每个用户每天的数据按前文所述进行处理，处理完后，对两个用户每天处理完成的 GPS 序列或者基站序列计算其 DTW 距离，计算处理完成的 GPS 序列或基站序列对应的序列熵值，用该熵值对前面计算的 DTW 距离进行加权，对每天加权后的距离计算加权平均值，以此作为两个用户关系强度的度量。再次，对降噪后的 GPS 数据剔除路上的点，使用聚类算法得到对应的语义位置，将 GPS 序列转换成对应的语义位置序列，对每个语义位置添加时间标记；对基站数据添加时间标记。训练对应的 LDA 主题模型。计算两个用户的关系强度时，将前文得到的语义位置序列按等时间间隔划分成若干份，基站数据采用同样的处理，对每一份数据推断其对应的 LDA 主题分布，得到一个若干维的实数值向量。计算两个用户每天同一时间段的两份数据对应的主题分布的余弦相似度，计算全天的平均相似度，以及全部数据的平均相似度，以此作为两个用户关系强度的度量。

再次，对聚类后得到的语义位置标记其对应的语义标签，将语义位置序列转换成对应的语义标签序列，对每个语义标签添加时间标记；将每个基站转换成对应的语义标签，对每个语义标签添加时间标记。训练对应的 LDA 主题模型。计算用户关系强度的方法与前文基于语义位置计算关系强度的方法相同。

最后，在前面三层计算结果的基础上，对三层关系强度的计算结果进行投票，将投票结果作为最终的关系强度。

第四章 GPS 数据处理及语义标签标注技术

上一章主要描述了本课题的整体模型框架。本章描述该整体模型框架的第一部分 GPS 数据处理及语义标签标注技术，包括 SASLL 系统框架、如何计算 GPS 数据对应的语义位置以及如何对语义位置标语义标签。

4.1 SASLL 标注技术

SASLL(A System Annotating Semantic Label of Location) 标注技术原理如图 4.1，GPS 数据模块访问本地传感器数据存储文件，对文件数据进行解析，得到 GPS 原始数据，其格式为由经度、维度、时间戳组成的三元组 (Lat,Lng,timestamp)。预处理模块在本系统第一次执行时自动学习剔除路上点需要的参数，并使用基于密度的方法剔除异常点。聚类模块对当天采集的数据使用^[20] 提出的算法对预处理后的数据进行聚类，得到当天参观过的位置，并与匹配表进行对比，计算得到新的位置。位置提示模块对新位置使用基于规则的推断方法和调用地图接口计算反地理编码的方法计算其可能的语义标签。最后由交互模块和用户交互，展示位置提示模块计算的提示以及记录用户的标注。

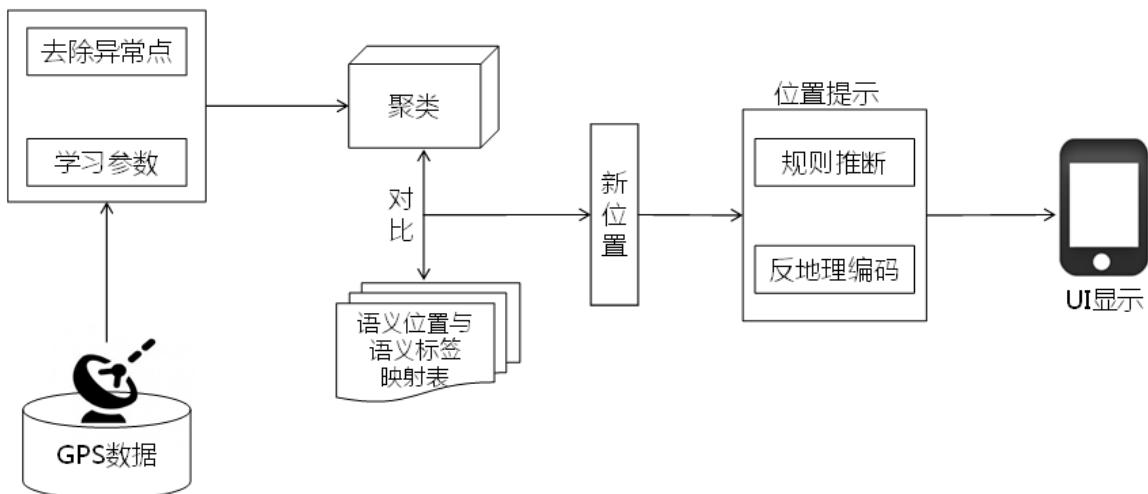


图 4.1 SASLL 系统框架图

4.2 计算对应语义位置

本节主要描述如何通过 GPS 发现语义位置，包括如何降低数据噪声、如何剔除异常点以及如何通过聚类得到语义位置。

4.2.1 降低数据噪声

根据自己的日常活动发现，用户会经常停留在某一固定位置很长时间，在这段时间内，其实用户本身位置是不变的，但是 GPS 采样值会包含一些随机误差，从而使得虽然实际上用户一直呆在同一个位置，采样得到的经纬度会在实际经纬度上下震荡。因此需要对 GPS 数据进行滤波使得采样值经过处理后更加接近实际值。第二章描述了常用的三种降噪方法，即均值滤波、中值滤波和卡尔曼滤波。算法原理不再赘述，这一小节主要通过实验来观察各种滤波算法的效果以及在实验的基础上提出分层卡尔曼滤波的方法。

首先使用自己日常采集的某几天的数据来观察均值滤波的降噪效果，数据采集软件使用^[41]。如图4.2、4.3、4.4所示。

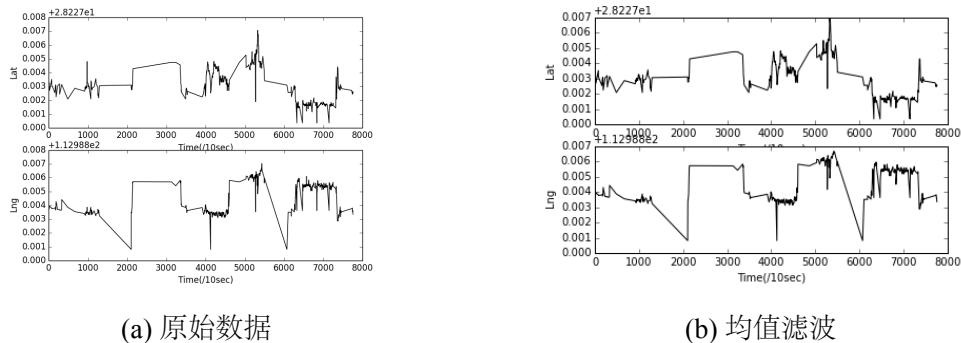


图 4.2 均值滤波实验结果 3-1

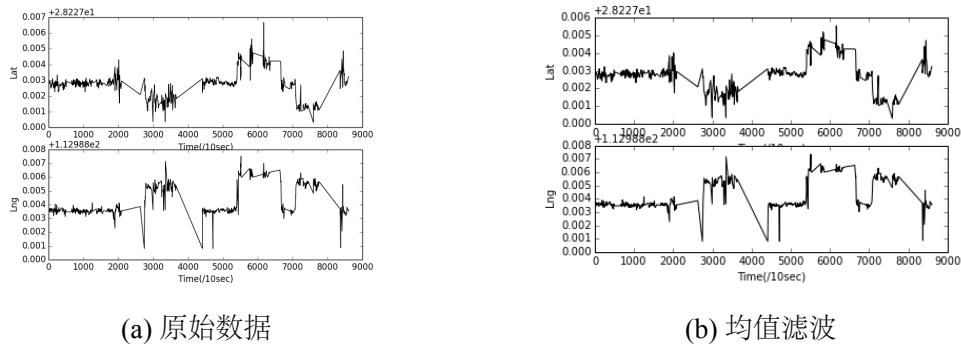


图 4.3 均值滤波实验结果 3-2

仔细分析实验结果发现，虽然滤掉一部分跳变点，但是对于非常明显的几个跳变点，均值滤波并没有滤掉。

下文展示中值滤波的实验结果。实验结果见图4.5、4.6、4.7。

仔细分析实验结果，中值滤波的结果明显好于均值滤波，滤除掉了大部分跳跃点。

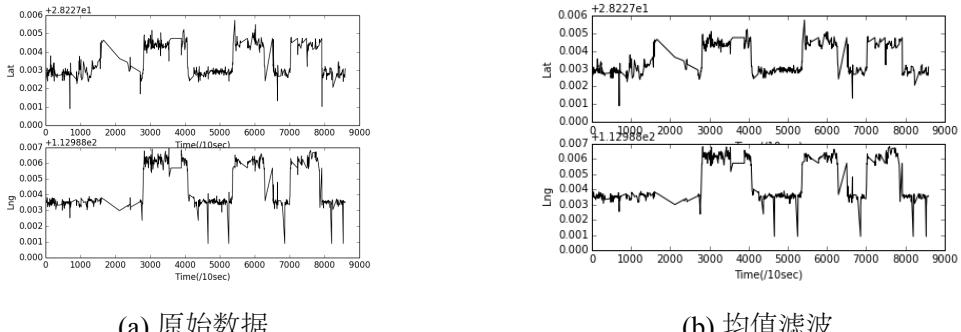


图 4.4 均值滤波实验结果 3-3

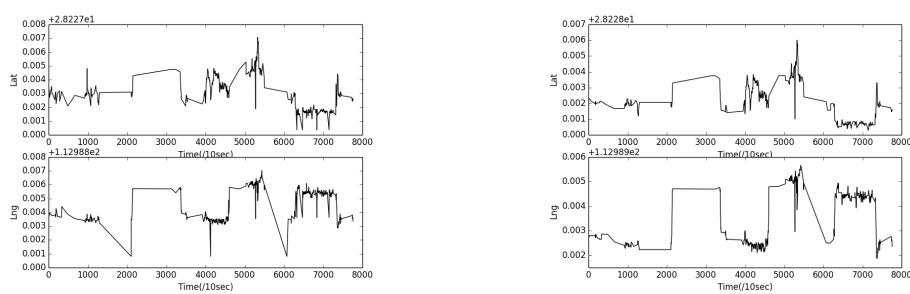


图 4.5 中值滤波实验结果 3-1

下文展示卡尔曼滤波的实验结果, 实验结果见图4.8、4.9、4.10。

卡尔曼滤波的结果虽然更加平滑, 但是通过分析实验结果发现, 滤波结果严重损坏了原来的信息, 使得整个轨迹曲线趋于常数值。经过更深一步的分析发现, 用户每天的轨迹只有在某些固定位置(即后文所说的语义位置)时会在一段时间内保持不变, 因此采用一些简单的方法对每天的轨迹进行划分, 尽可能使每段轨迹中的点都采样自某一个固定位置, 然后对这一段轨迹进行卡尔曼滤波, 肯定能够得到一个更好的滤波结果。

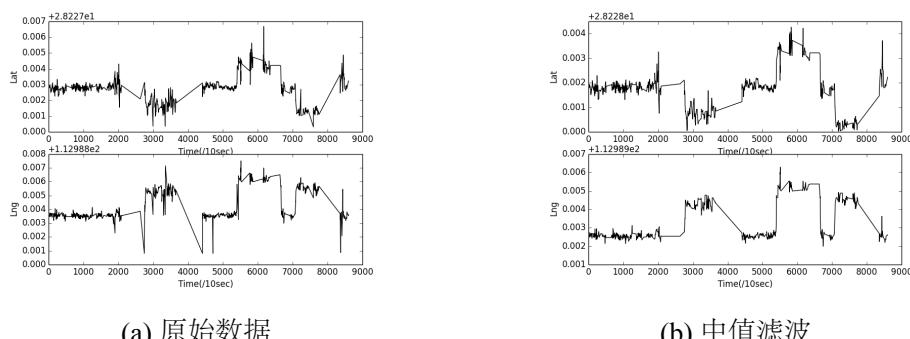
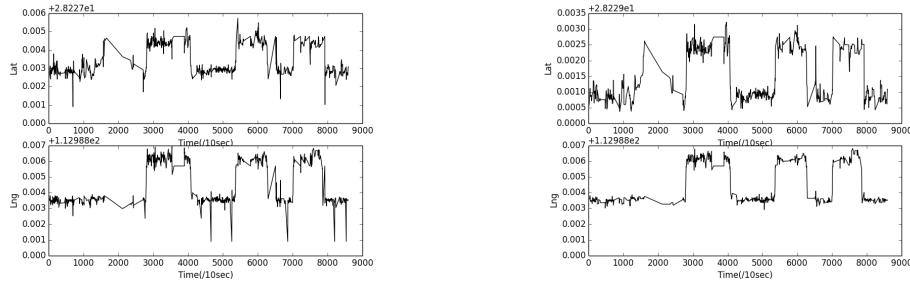


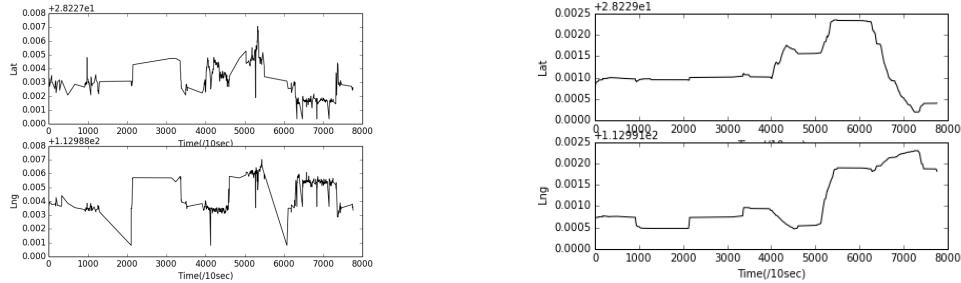
图 4.6 中值滤波实验结果 3-2



(a) 原始数据

(b) 中值滤波

图 4.7 中值滤波实验结果 3-3

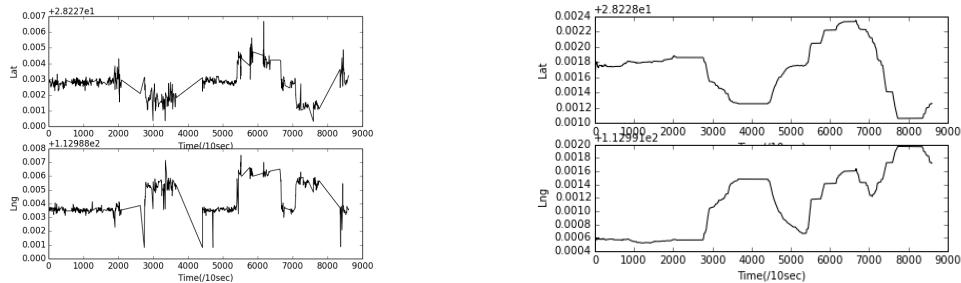


(a) 原始数据

(b) 卡尔曼滤波

图 4.8 卡尔曼滤波实验结果 3-1

本课题采用一些非常简单且容易实现的方法对轨迹进行分段。如果在一段时间内，任意相邻两个采样点之间时间间隔不超过十分钟（超过十分钟用户位置就很可能发生变化，十分钟是一个参数值，也可以根据实际情况进行调节），任意两个采样点之间真实距离不超过 20 米，则认为这段时间内所有的采样点属于一个片段。采用贪心的思想寻找满足上述两个条件的序列，即如果加入下一个点，不破坏上述两个条件，则当前序列应该包含下一个点，如果加入下一个点后，上述



(a) 原始数据

(b) 卡尔曼滤波

图 4.9 卡尔曼滤波实验结果 3-2

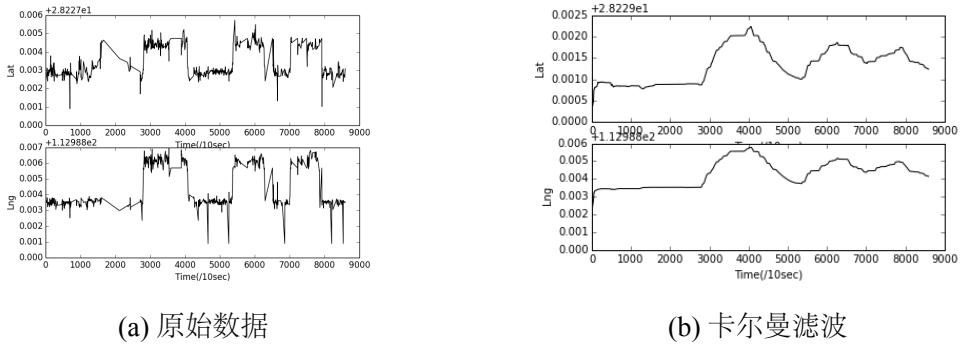


图 4.10 卡尔曼滤波实验结果 3-3

两个条件之一或全部被破坏，则当前序列为当天轨迹的一个片段，且不包含下一个点。下文展示分段处理后卡尔曼滤波的结果，见图4.11、4.12、4.13。

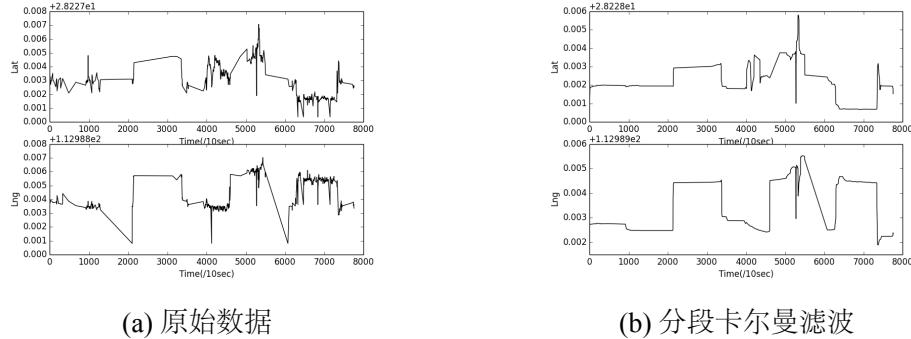


图 4.11 分段卡尔曼滤波实验结果 3-1

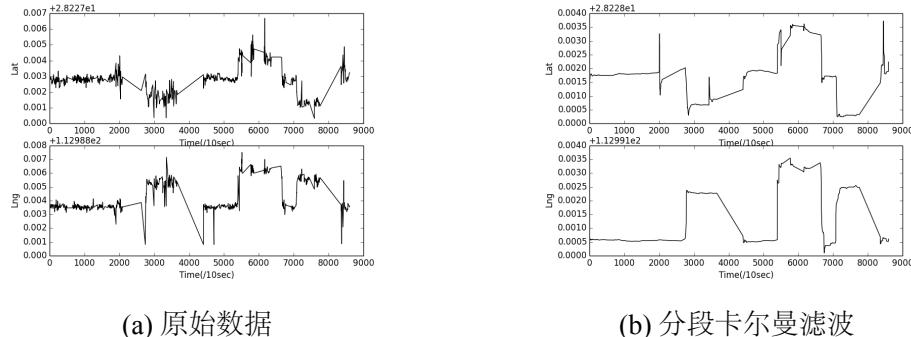


图 4.12 分段卡尔曼滤波实验结果 3-2

这一小节主要描述了均值滤波、中值滤波、卡尔曼滤波以及分段卡尔曼滤波的实验结果，通过实验发现分段卡尔曼滤波的结果更加平滑，更符合实际情况。下一小节将描述如何剔除路上的点。

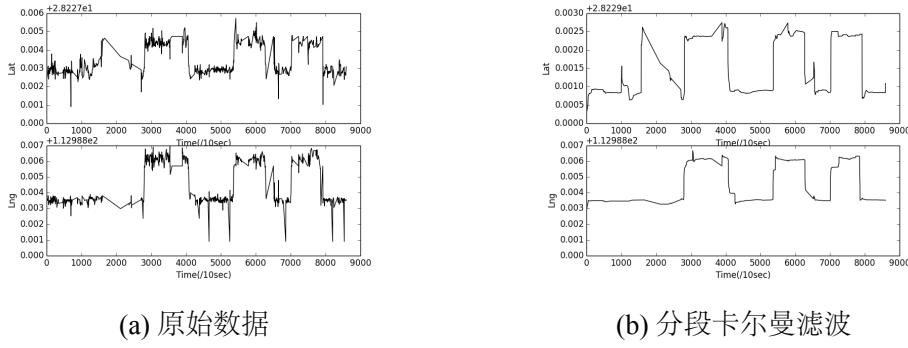


图 4.13 分段卡尔曼滤波实验结果 3-3

4.2.2 剔除路上的点

在现实生活中，人们从一个位置行进到另一个位置是连续的，即采集的数据必然存在很多路上的点。而这些路上的点不属于任何一个语义位置。且在分析关系强度时，如果两个人同时来到同一个语义位置，但是一个从某一个方向过来，而另一个从相反方向过来，虽然这两个人其实在这段时间内待在同一个地方，如果不剔除路上的点，则这两个人的物理位置会受到路上的点的影响，从而使得这两个人轨迹的空间距离反而比较大。在上文讨论的降噪过程中，已经处理了误差比较大的点，因此本节主要讨论如何剔除路上的点。

仔细分析路上的点的特性，发现人们通常在语义位置停留时间比较长，而在路上一直处于移动状态，所以路上点密度通常远远小于语义位置的点的密度。密度定义见公式2.10。且在实际生活中，在路上时通常处于移动状态，设速度为 v ，且每条路每天走的次数也存在上限，设每条路每天最多走 N 次，计算密度时采用的半径参数为 R ，设 GPS 采样频率为 f 。因为半径参数很小，故可视为在该半径对应圆形区域中行走路线为直线。路上点的密度 D 存在最大值，计算方法见公式4.1。因此本文采用基于密度的方法剔除异常点。该方法的基本思想为若某个点的密度小于给定阈值，则该点为异常点。通过对日常数据的分析发现，路上点的密度确实远远小于处于语义位置点的密度，见图??。

$$D = N * \frac{2R}{v} * f \quad (4.1)$$

根据上下文的分析，可以计算出密度的上限值，假设计算密度时的半径设为 10 米，每天经过这条路 4 次，步行速度约为 80 米每分钟，这样每个点的密度的上限值大概是 60。同时本课题研究发现有一种方法可以自动学习参数，后文将会对比学到的密度上限值和计算值的异同。

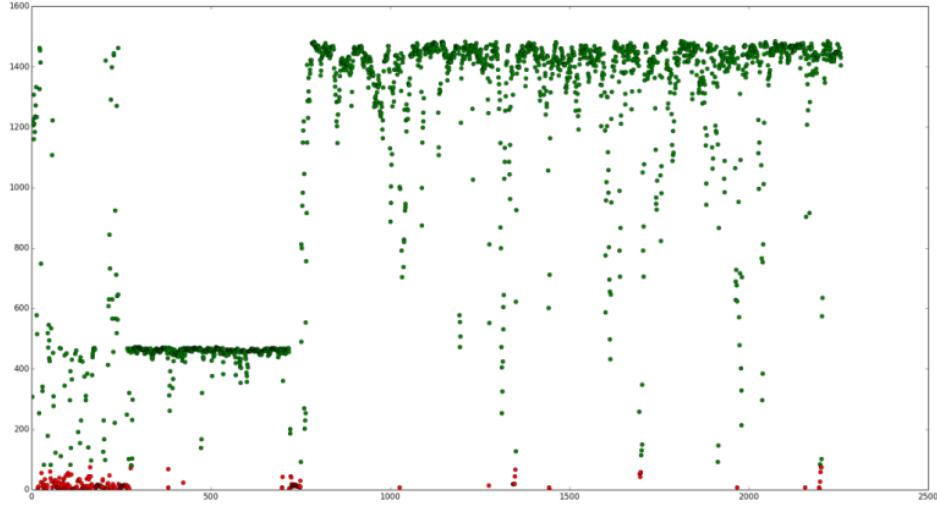


图 4.14 绿色表示正常点，红色表示路上的点

假设对于某一天的数据，已经聚好类，即我们知道哪一个点属于哪一个类别，仔细分析每个路上的点对类别中心的影响，假设用户在某个地方时处于某一个固定的位置，GPS 采样因为采样误差服从高斯分布，因此大多数点都处在该固定位置对应实际点（可能是类别中心，非常有可能在类别中心附近）的周围。而路上的点会距离实际点比较远，因此，该类别所有点到类别中心的距离的平均值会被路上的点拉大，如果逐渐提高密度的上限值，从而有更多的点因为密度小而被删除，讨论一种理想情况，如果路上的点完全被剔除，剩下的点都是实际点加高斯误差，因为实际点大量存在，使得即使我们剔除一小部分实际点，对该类别所有点到类别中心的距离的平均值也不会产生太大的影响。所以可以从一个很小的密度上限值逐渐增加，剔除小于该密度的点之后计算对应的平均距离，若平均距离收敛，则认为这个密度值是路上的点的密度的上限值。平均距离的定义见公式4.2，其中 p_{ij} 为第 i 类第 j 个点， c_i 为第 i 类的类别中心， $dis(a, b)$ 表示 a 和 b 之间的距离， n_i 为第 i 类点的个数， k 为类别的个数， N 为所有点的个数。使用连续四天采集的数据做了实验，计算其平均距离，见图4.15。

$$AvgDis = \frac{\sum_{i=1}^k \sum_{j=1}^{n_i} dis(p_{ij}, c_i)}{N} \quad (4.2)$$

通过观察图4.15，发现密度上限值大概是 40 到 50 之间，前文计算的密度上限值是 60 左右，一方面因为两种计算方法都存在一定的误差，另一方面是在实际过程中，手机并不是持续高频采样，经常会因为各种各样的原因而丢失一些采样

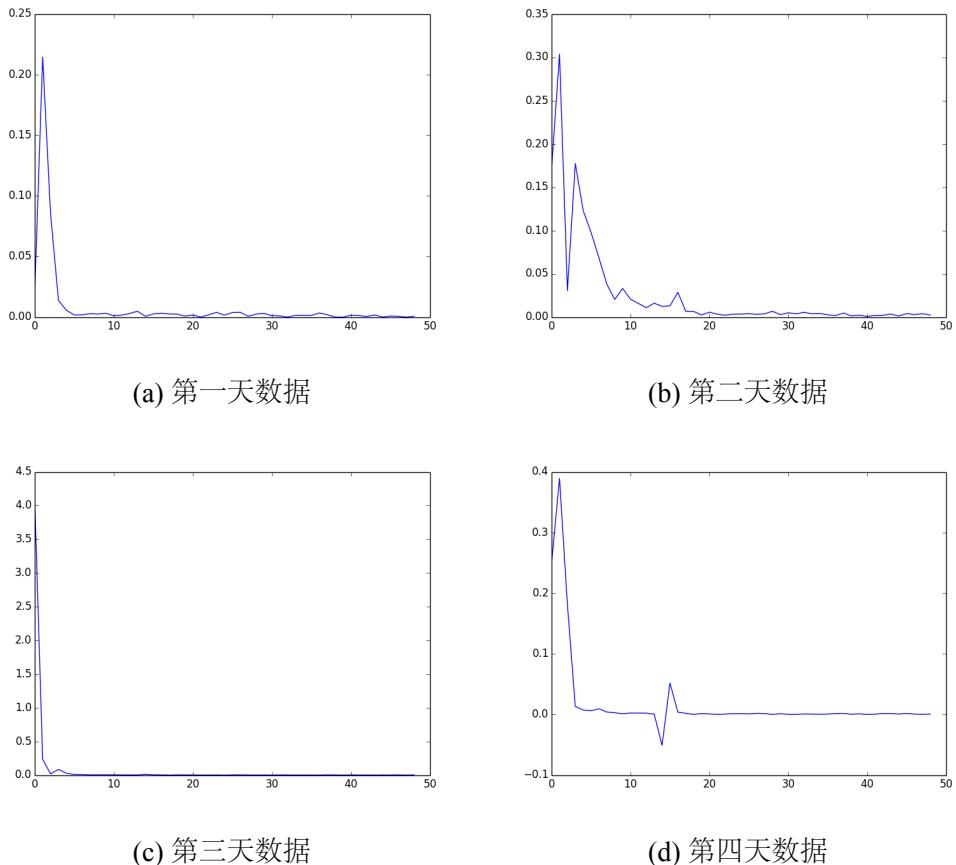


图 4.15 平均距离收敛

点。在实际应用中，可以先手动处理某一天的数据，然后使用该自动学习的算法学习到密度的上限值，从而用作其他天数据处理的参数。

这一小节主要讨论了如何剔除路上的点，以及如何学习路上点的密度的上限值，下一小节将通过实验讨论 K-MEANS、DJ-cluster、以及 Science 上发表算法三种聚类算法的优缺点，以及在实际数据上应用的效果。

4.2.3 聚类得到语义位置

这一小节将重点描述使用聚类算法得到语义位置时，不同算法以及不同参数对结果产生的影响。K-MEANS、DJ-Cluster 以及 Science 上发表的三个算法算法原理在第二章已经描述过了，下文将通过实验依次展示三个算法对相同数据聚类得到的结果。数据使用文献 [41] 中的采集工具采集。

首先展示 K-MEANS 聚类算法的实验结果，K-MEANS 聚类算法的主要缺点有两个：一个是需要预知类别的个数；另一个是同一类别的数据最好是团状或簇状。对于本课题研究的问题而言，通常遇到的建筑都是每栋楼占单独的一块地方，相邻建筑一般都会有一定的间隔，因此 K-MEANS 聚类算法的第二个缺点

因为本课题研究的具体问题而不复存在，故主要考虑不同类别个数对实验结果的影响。图4.16、4.18、4.20 主要展示了不同参数对 K-MEANS 聚类结果的影响。图4.17、4.19、4.21在地图上标记了不同参数聚类得到的聚类中心。

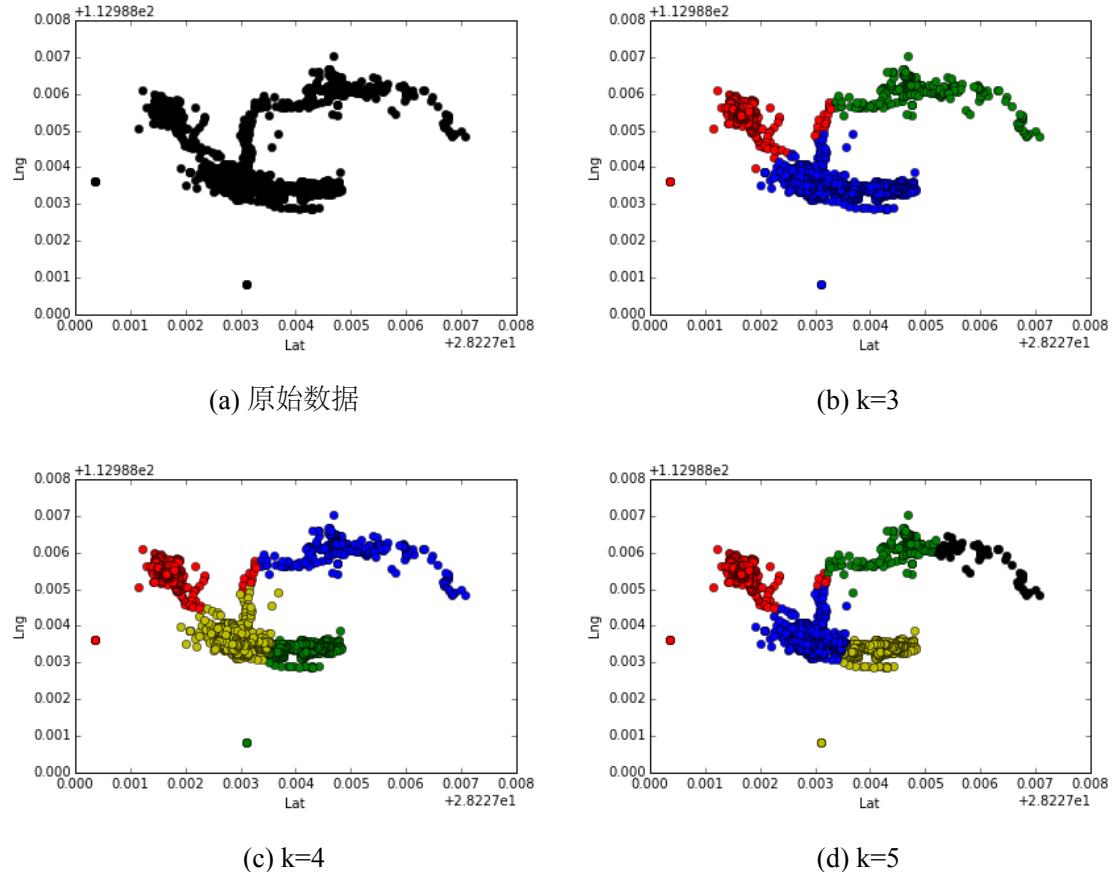


图 4.16 K-MEANS 聚类实验结果 3-1

仔细分析这三组数据的实验结果发现，如果能够预先知道类别的个数，K-MEANS 算法确实能够得到一个非常好的结果，特别对于图4.19，仔细观察 (a) 对应的原始数据，地图右下角白色点群表明其实去了两个教学楼，但是两个教学楼距离太近以及 GPS 本身存在的采样误差使得采样点混合在一起。如果假设去了三个地方时，该聚类算法将两个教学楼识别成了一个位置，如果假设去了四个地方时，聚类算法成功的区分了这两个实验楼，在另外两个算法的实验中将发现，另外两个算法无法区分这两个实验楼。对于图4.17，其实只参观了三个地方，但是如果假设去了四个地方，该聚类算法也能将数据分成四类，仔细观察得到第四个类别其实是两条路的交叉点，从另一个角度证明前文论述应该剔除路上的点是非常合理的，而后文的实验也证明剔除路上的点之后，聚类算法就不会再把路上的点识别成聚类中心。

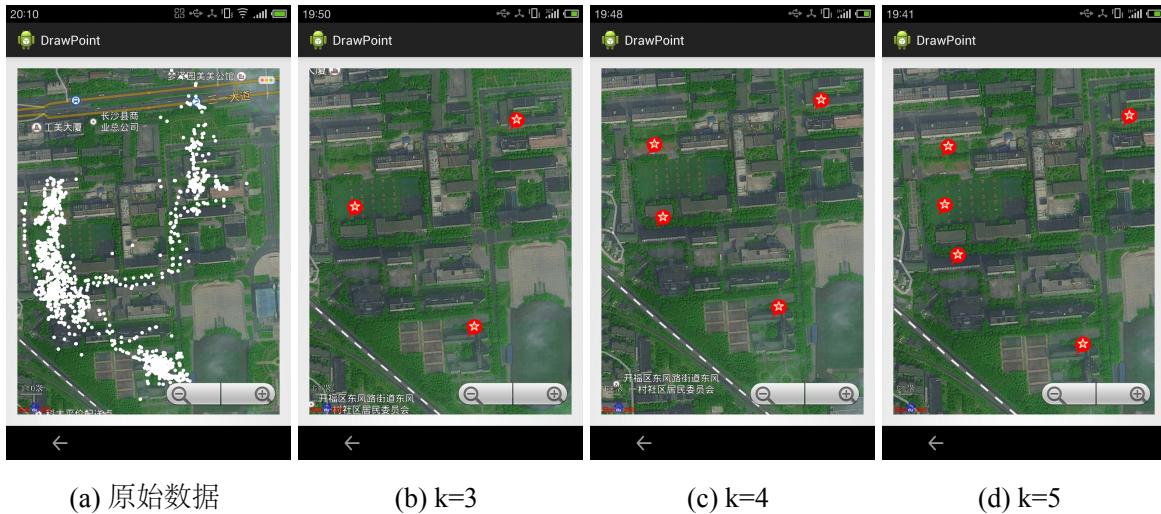


图 4.17 K-MEANS 聚类实验结果地图展示 3-1

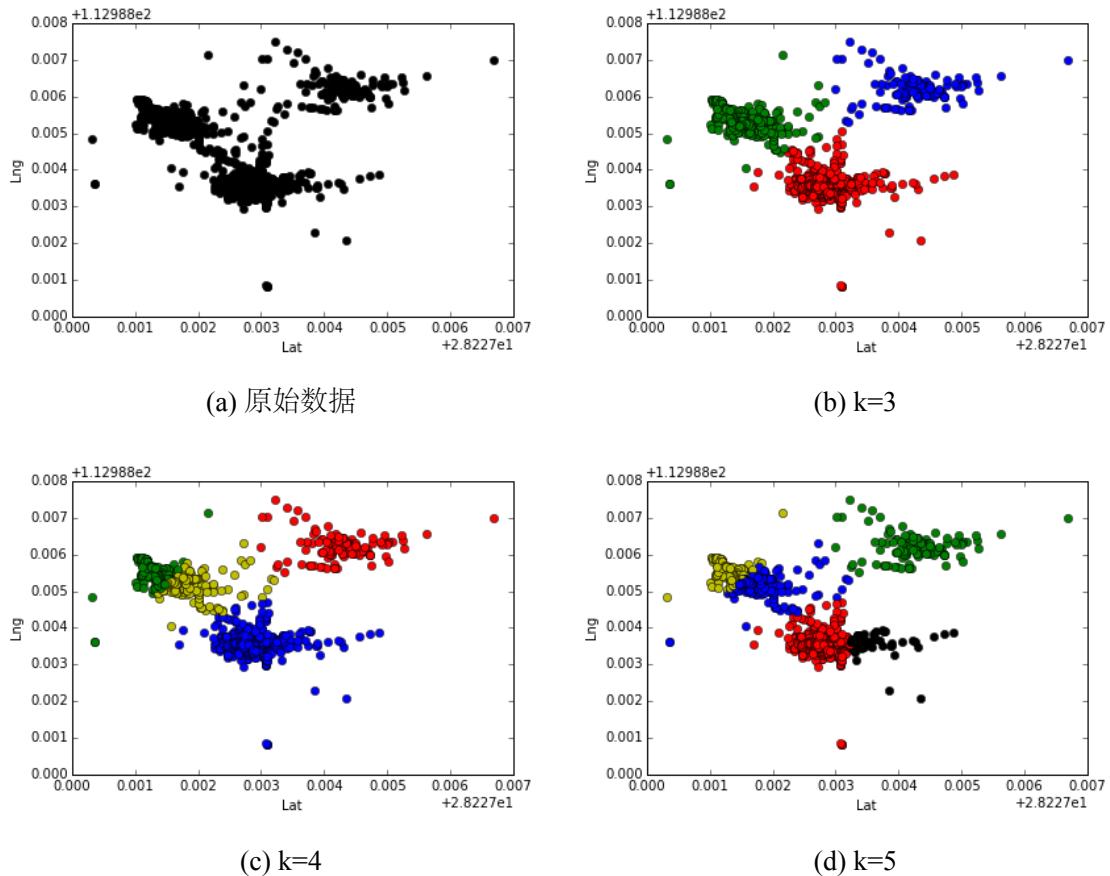


图 4.18 K-MEANS 聚类实验结果 3-2

下文将展示 DJ-Cluster 算法的实验结果，DJ-Cluster 是基于 DBSCAN 算法的一种基于密度的聚类算法，通过边界点将相邻类别合并从而使得算法对参数更加鲁棒。但是算法本身仍然严重依赖半径值和密度值这两个参数，在实际应用过程

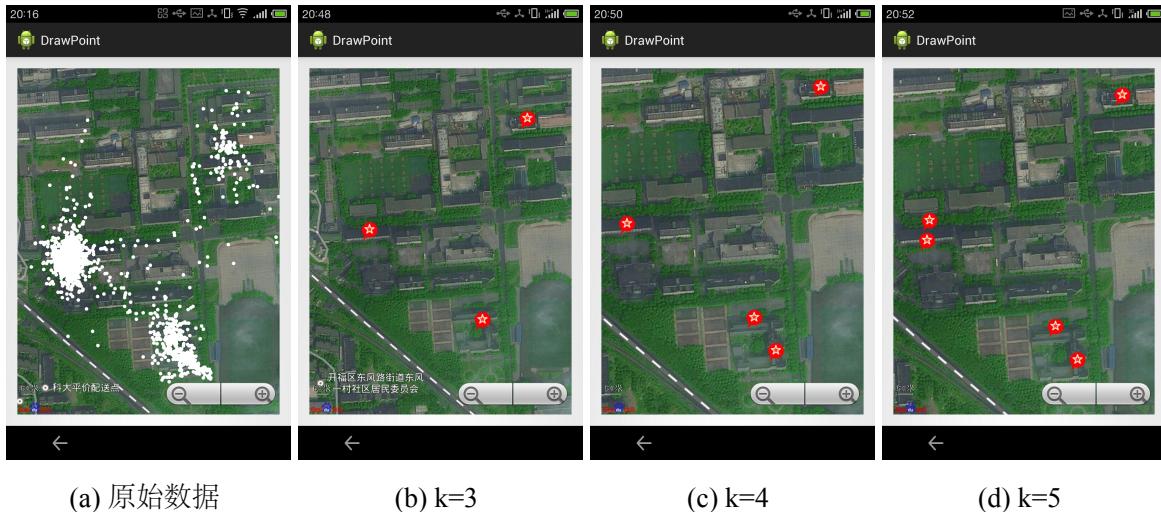


图 4.19 K-MEANS 聚类实验结果地图展示 3-2

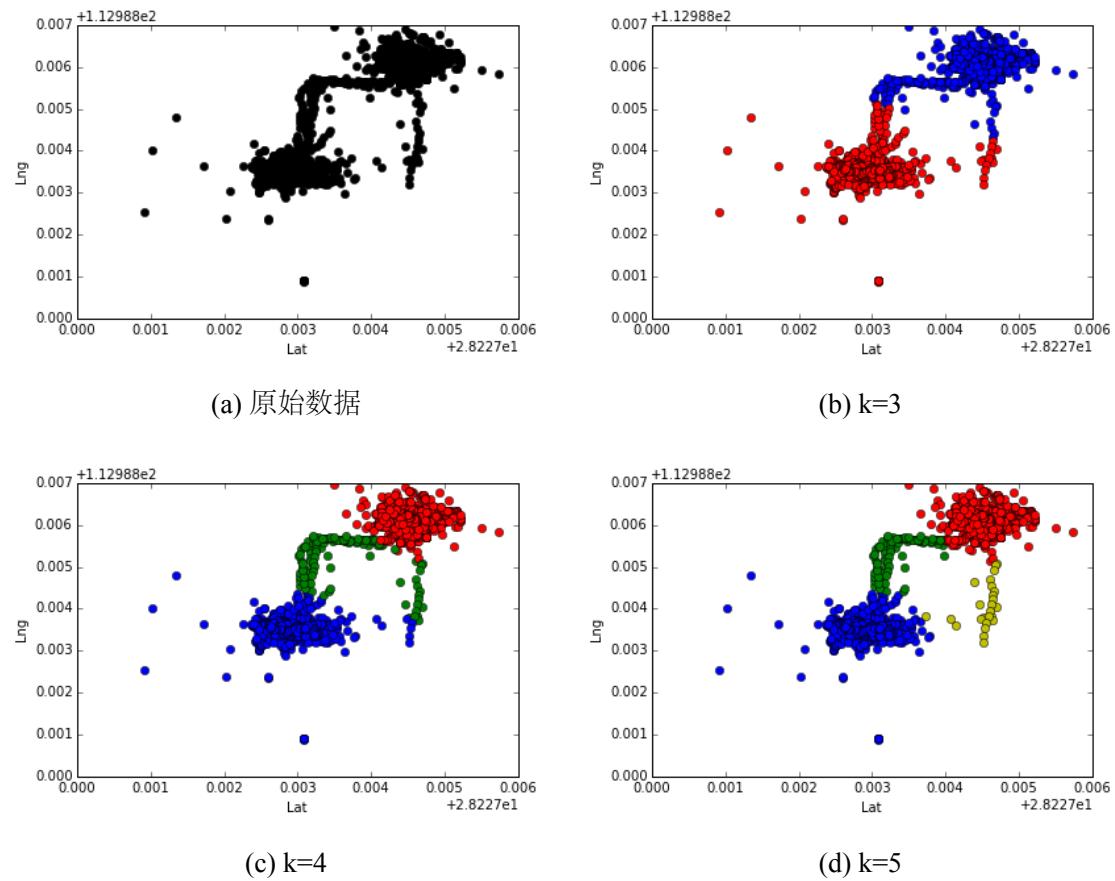


图 4.20 K-MEANS 聚类实验结果 3-3

中，仍然需要仔细调节参数，在参数设置理想的情况下，仍然能够得到非常理想的结果，见图4.22、4.24、4.26，其地图表示见图4.23、4.25、4.27。

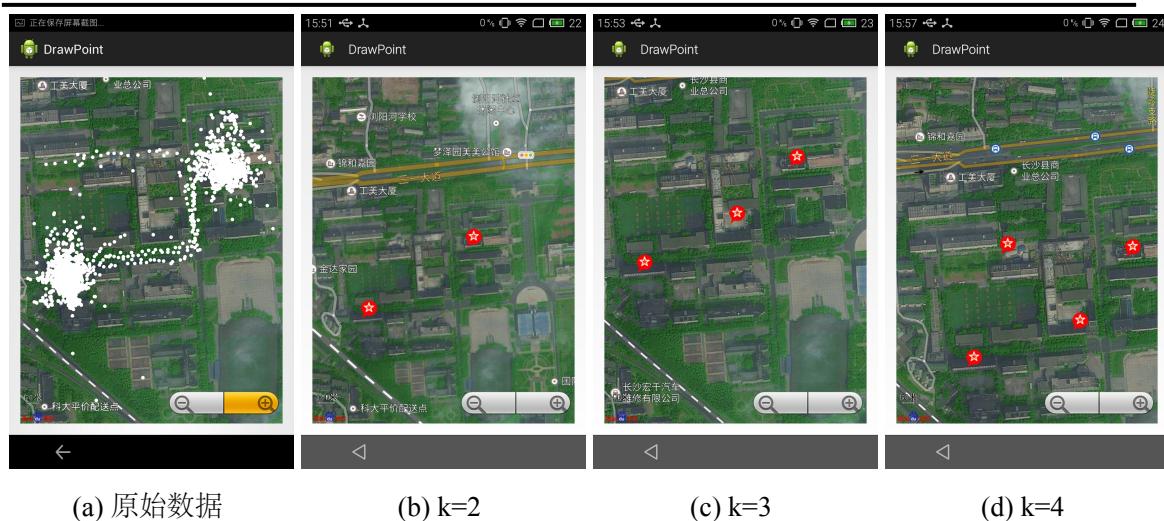


图 4.21 K-MEANS 聚类实验结果地图展示 3-3

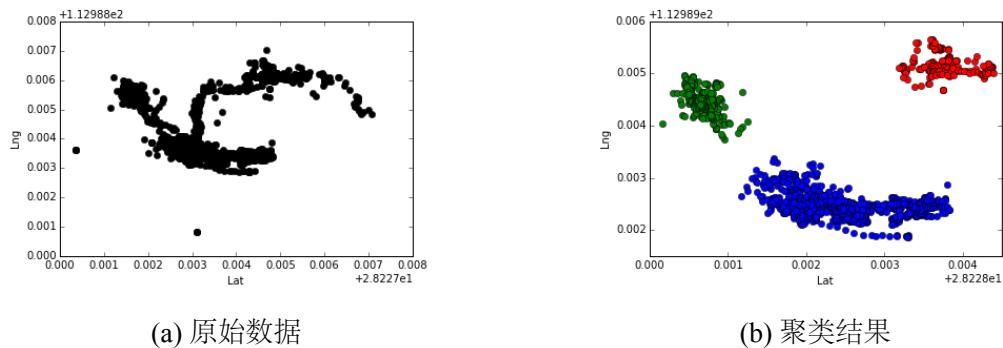


图 4.22 DJ-Cluster 实验结果 3-1

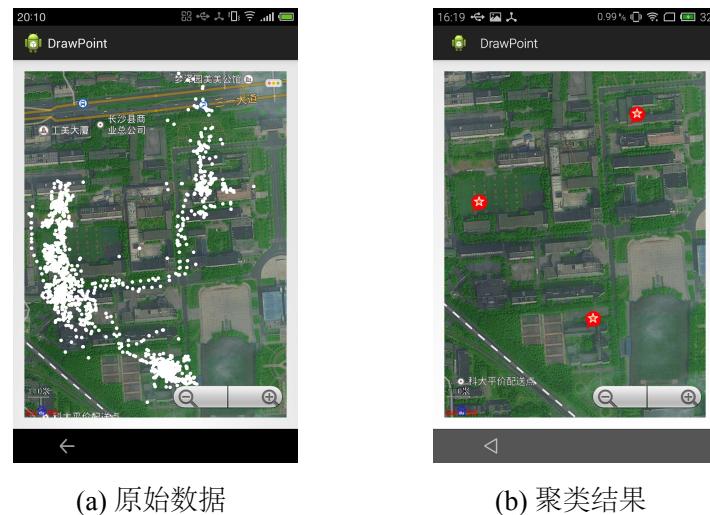


图 4.23 DJ-Cluster 实验结果地图表示 3-1

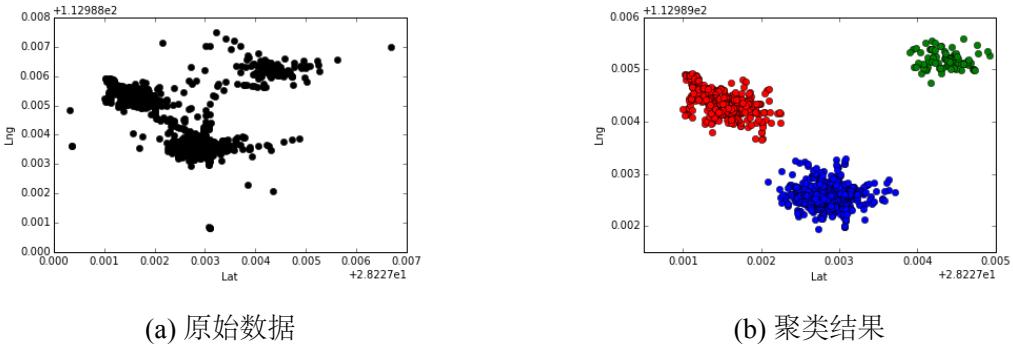


图 4.24 DJ-Cluster 实验结果 3-2

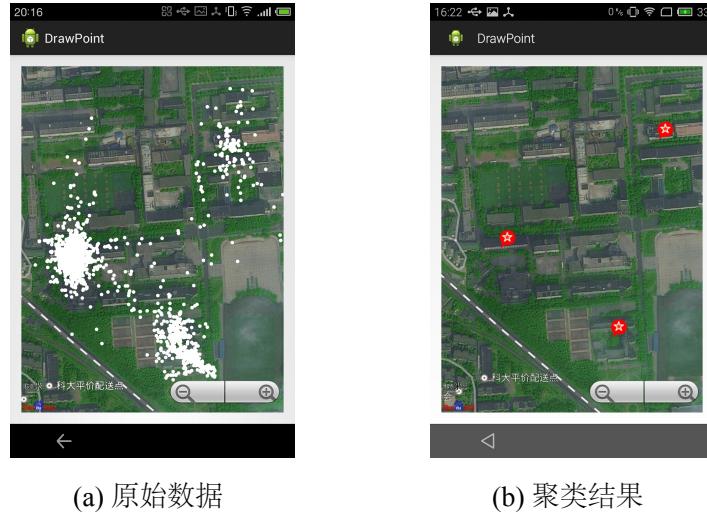


图 4.25 DJ-Cluster 实验结果地图表示 3-2

通过对实验结果的分析能够发现，DJ-Cluster 基本上能够得到一个令人满意的结果，在仔细调节参数后，基本上识别出了所有的位置，但是图4.25右下角其实是两个教学楼，前文已经论述过，DJ-Cluster 将其识别为一个位置，主要是因为这两个教学楼本身距离太小，且 GPS 采样误差比较大使得本来分属于两栋楼的

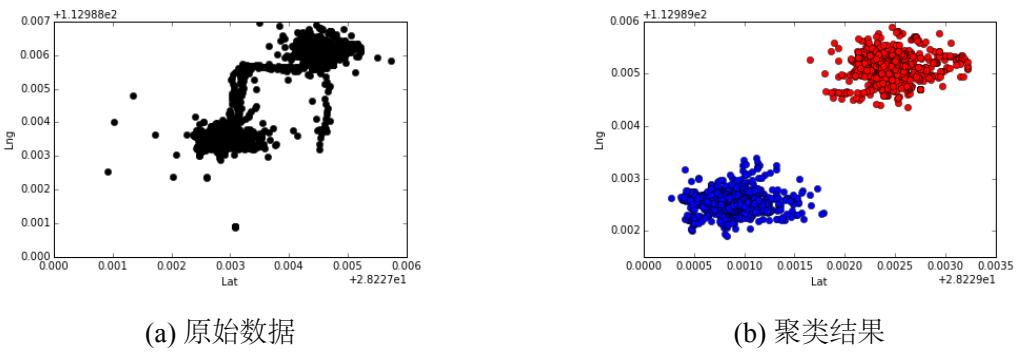


图 4.26 DJ-Cluster 实验结果 3-3

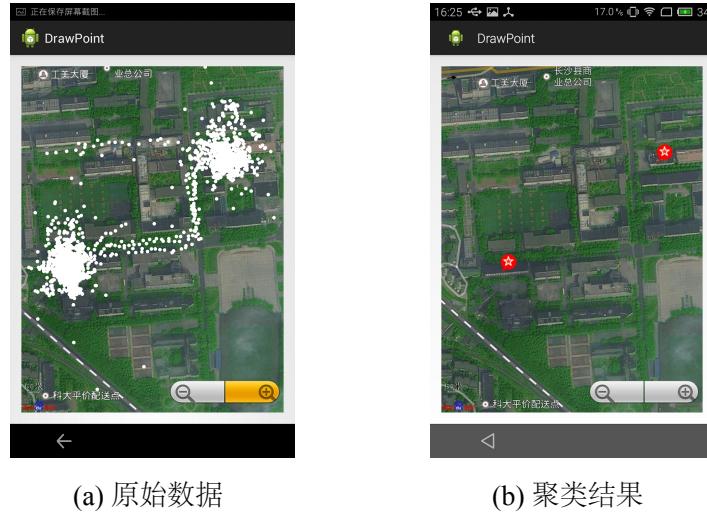


图 4.27 DJ-Cluster 实验结果地图表示 3-3

采样点有重合，从而使得基于密度的方法无法区分。除此情况外，对于另外两天的数据，该算法都表现出了非常好的识别结果。该算法最大的缺陷还是对参数比较敏感，下文将介绍 Science 发表的聚类算法的实验结果，同时会从算法原理上简要论述其对参数的鲁棒性确实优于 DJ-Cluster。

下文描述 Science 发表的聚类算法对应的实验结果，在描述具体实验之前，首先分析该算法的原理：该算法对每个点计算对应的密度（密度定义见前文），对所有点按密度排序；然后计算每个点的距离，再对每个点按距离和密度的乘积排序得到最终的聚类结果。DJ-Cluster 算法之所以对参数敏感是因为不同的半径值就需要对应不同的密度值（半径大了，此半径对应的圆形区域内其他点的数目肯定会更多），而 Science 发表的算法会对所有点按密度排序，这样在很大程度上降低了半径值对算法本身的影响，通常情况下半径越大点密度越大，如果随着半径的增长，密度的相对顺序保持不变，则半径对该算法基本没有影响，本课题收集的 GPS 采样点基本满足这一条件，若某个点在小半径时密度小，则在大半径时其密度依然相对较小。所以 Science 发表的算法对当前问题而言有非常好的鲁棒性。具体的实验结果见图4.28、4.30、4.32。实验结果地图表示见图4.29、4.31、4.33。

仔细分析由 Science 发表算法对应的实验结果发现，其结果和 DJ-Cluster 的结果基本完全一致，图4.31、其实有四个地方，该算法也只识别出来三个，未能正识别的原因如前文所述，其对另外两天的数据都能全部识别出来。其算法的鲁棒性在前文已经论述过了，在此讨论与该算法相关的另外一个参数，即密度和距离乘积的阈值。原论文中声明他们的算法不需要任何手动设置任何参数，但是经过实验发现该阈值仍然需要通过观察具体数据集的特性来确定。虽然不能完全不

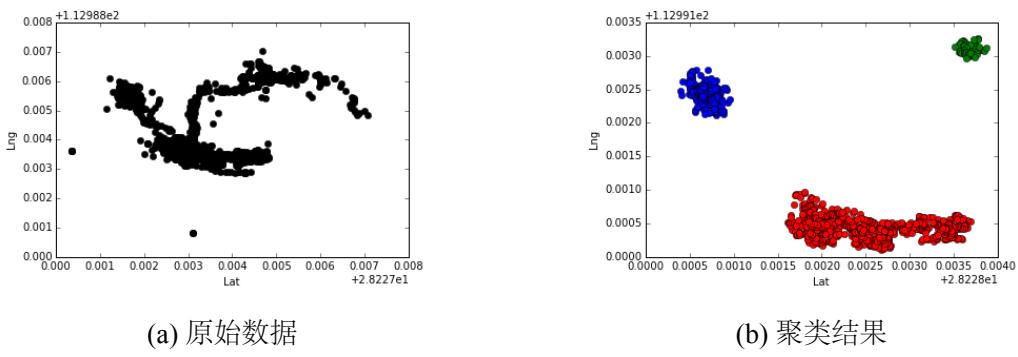


图 4.28 Science 发表算法实验结果 3-1



图 4.29 Science 发表算法实验结果地图表示 3-1

需要人的参与，通过实验发现对于特定的数据集，比如采集的校园内的 GPS 数据，通过对第一天数据的分析，能够得到一个密度和距离乘积的阈值，通过实验发现该阈值对后面采集的数据依然有效，即只需要在刚开始使用该算法时确定该

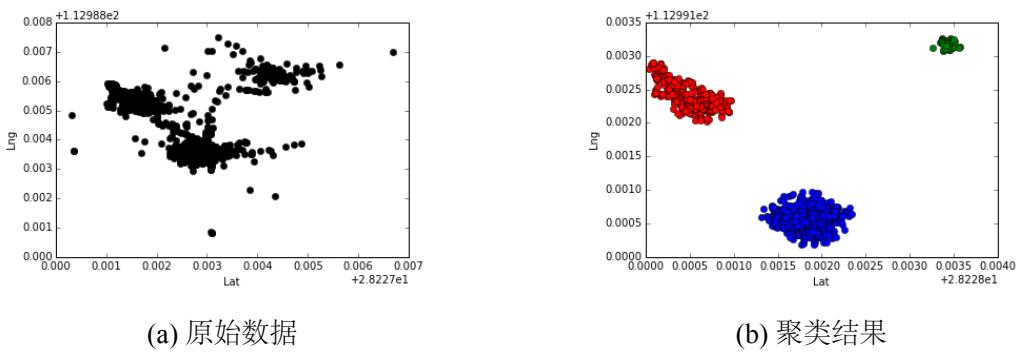


图 4.30 Science 发表算法实验结果 3-2

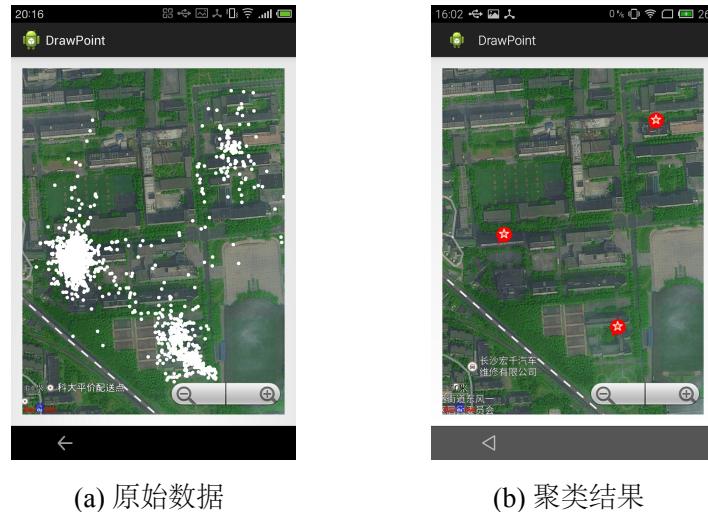


图 4.31 Science 发表算法实验结果地图表示 3-2

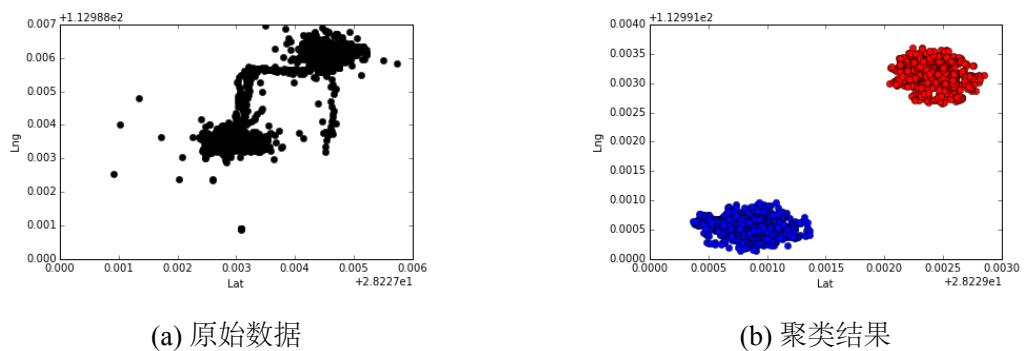


图 4.32 Science 发表算法实验结果 3-3

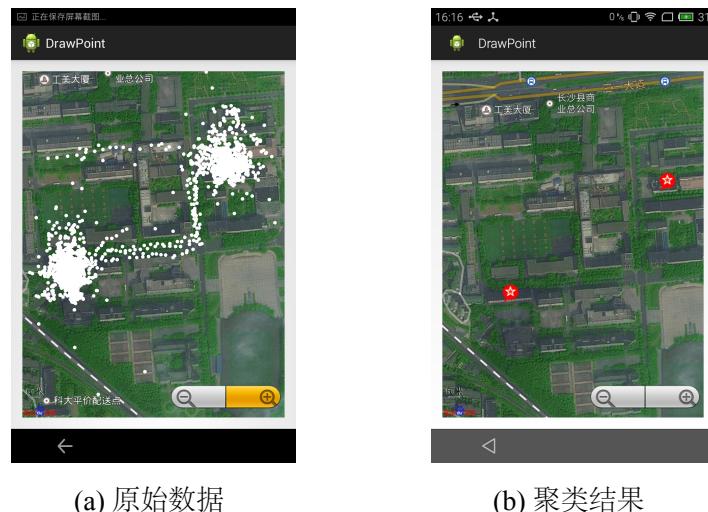


图 4.33 Science 发表算法实验结果地图表示 3-3

参数，就可以使用该参数处理其他剩余的数据。这样在很大程度上减少了人与机器的交互，使得该算法更加实用。

这一小节主要讨论了三种聚类算法以及不同的参数对实验结果的影响。最后讨论对每天数据进行聚类的优缺点。以前的工作都是采集一段时间的数据，把所有数据合并到一起，然后用这些聚类算法来计算对应的语义位置。最明显的一个问题是如果聚类结果表明这些数据总共产生了 1000 个位置（如果是 K-MEANS 算法需要预先设定类别的个数），那么这些数据是否恰好对应 1000 个语义位置。这样做的优点是处理方便，只需要一次交互，缺点是计算结果无法验证。当然，主要是因为移动感知这个领域目前对结果精度要求也不是很高，但是有没有什么办法在不明显增加处理复杂度的同时使得结果更加精确？因此本课题决定对每天的数据进行聚类，一方面小数据更容易精识别，如果用户总共去了三个地方，可能识别出来两个，则只有一个没有识别出来，而没识别出来的那个可能因为下文论述的原因被重新发现，如果把所有数据一起处理，假设总共参观了 100 个地方，可能只识别出来 70 几个，另外 20 多个无法被识别；另一方面如果每个地方因为当天采集数据太少而未被识别，用户下一次去这个地方且采集数据较多时就会被重新识别出来，对最终结果来说，仍然正确识别了这个地方。而且小数据量使得在移动端计算成为可能，可以将整个过程全部放在手机上，而不影响用户体验。在识别出这些位置后下一步需要标记其语义标签，将大量的数据分散到每天，且通过识别新的位置以及对新位置计算可能的语义标签在很大程度上降低了用户与手机的交互，下一节将详细讨论如何在发现语义位置后对其标记对应的语义标签。

4.3 对语义位置标语义标签

在上一节主要描述了如何对 GPS 数据进行滤波以达到降噪的目的、如何剔除路上的点以及如何使用聚类算法得到语义位置。仅仅得到语义位置的信息是不够的，如果只是知道这个用户在什么时候去了一个地方，但是并不知道这个地方是什么（一般指该地方的功名称）。如果能够得到这个地方的语义信息，则能够解决更多的问题。如果知道一个人从早到晚一整天都在实验室，只使用这些信息就可以确定，这个人很大可能是博士。而且根据用户经常停留的位置也可以从健康角度提一些建议，如果某用户整天在室内办公，就可以提醒他应该抽出一定的时间去室外锻炼。因此，确定语义位置对应的语义标签是非常重要的一个问题。本节主要介绍如何确定语义位置对应的语义标签。

4.3.1 发现新位置

一般通过两种方法来得到语义位置对应的语义标签。一种方法是预先定义几种语义标签，使用监督学习的方法学习出一个分类器模型，然后对未知标签的数据通过用分类器分类得到其对应的语义标签。该方法的优点是结果比较准确，有坚实的理论基础做支撑，而且只有在收集数据时需要用户参与；缺点是需要大量的数据来训练模型，训练模型需要大量的时间，且只能识别预定义的几种语义标签，对新的语义标签无能为力。另外一种方法是首先通过聚类算法识别出用户参观过的所有的语义位置，然后在地图上标记出来，人工标记语义位置对应的语义标签。该方法的优点是可以不断处理新的位置；缺点是需要用户的参与，影响用户体验。

无法预先确定全部的语义标签，只能采用第二种方法来获取可能的语义标签。但是在处理过程中仍然采取了很多措施来降低用户和手机的交互。前文已经论述了对每天采集数据进行处理的原因。在每天用户睡觉前（这种情况下通常手机充电且已连接 WIFI）对当天采集的数据进行处理，聚类得到当天去过的语义位置，为了减少用户和手机的交互，在得到语义位置之后会判断今天有没有新的位置，用户只需要对新去过的位置标记语义标签，这一小节将主要描述如何发现新的语义位置。在得到新的语义位置后会通过一定的方法来计算可能的语义标签以减少用户与手机的交互，下一小节将重点描述如何计算可能的语义标签。

为了减少用户与手机的交互，在用户标记语义标签时，只标记新位置的语义标签，如果某个位置已经标记了对应的语义标签，则当该位置再次出现时，将直接忽略该位置。

发现新位置最重要的问题在于，即使对于同一个语义位置，因为采样的误差使得计算得到的聚类中心不一定完全相同。首先设计一个已标记表，记录用户已经参观过的语义位置及其对应的语义标签，以及该位置参观过的次数。每次计算得到一个语义位置时，计算该位置与已标记表中每一个位置之间的距离，若该位置和与其最近的位置之间的距离小于某一个给定阈值比如说 20 米，则认为该位置和与其最近的位置是一个位置。虽然这两个位置是同一个位置，但是这两个位置在数值上并非完全相同，因此尝试通过一定 的方法来修正该实际位置的数值。把与该实际位置是同一个位置的所有已经参观过的位置的平均值作为该实际位置新的数值表示，见公式4.3。这也是在已标记表中需要记录参观该位置次数的原因。

$$\text{avgLat} = (\text{avgLat} * n + \text{newLat}) / (n + 1), \text{avgLng} = (\text{avgLng} * n + \text{newLng}) / (n + 1) \quad (4.3)$$

然而并未完全解决该问题，最主要问题是两个位置到底距离多近才可以将其视为一个位置。发现新位置的实验会在下一节和计算可能的语义标

签一起展示，在实际应用过程中，对于小数据量，相对来说还是可以得到一个比较精确的结果，但是对于大数据量，可靠性很难得到保证。而且该方法非常依赖聚类算法的结果，而聚类算法的结果又非常依赖实际采集到的数据，实际采数据的过程无法控制，因此聚类算法的结果也很难控制。猜想每天同一个位置采集的数据聚类得到的聚类中心是不是也服从一定的分布，如果通过实验数据能够确定该分布，通过参数估计就可以得到实际位置一个更可靠的估计值。这也是下一步的工作之一。

4.3.2 新位置语义标签提示

上一小节讨论了如何发现新位置，这一节将详细讨论如何计算新位置可能的语义标签。本课题主要通过三种方式来减少用户和手机之间的交互：第一种方法是采用简单的推断方法来推断该新位置可能的语义标签；第二种方法是利用当前电子地图提供的获取反地理编码的接口来获取当前位置对应的反地理编码作为当前位置的语义标签；第三种方法是在用户输入时提供自动补全功能，减少用户的参与。

首先描述简单推断方法。综合考虑手机的计算能力以及算法的可靠性，决定采用基于规则的方法来推断新位置可能的语义标签，这也意味着只能得到一些比较简单的结果，而不能像常用的分类算法那样可以处理很多种语义标签的情况，可以视为性能和精确度之间的一个权衡。

考虑最简单的两种语义标签家和办公室（实验室）。之所以称其为最简单的语义标签是因为这两个语义标签对应的语义位置有着非常明显的特点，比如家通常是夜间停留一整晚的地方，而办公室通常是白天停留一整天的地方，这些特点使得这两个地方和其他地方有非常大的区别，从而可以使用一些很简单的规则把他们和其他地方区分开。具体处理方法如下。

先描述如何推断家这个语义标签。对零点到早上七点这段时间内出现的语义位置分别计算在其对应的地方停留的时间，并计算该时间相对于七个半小时占的百分比。若这段时间内只有一个语义位置，且其时间占到了总时间 93% 以上（之所以不是 100% 是因为采样存在误差，若误差比较大被视为异常点从而使得对停留时间的统计出现偏差，选择 93% 是因为可以有半个小时的偏差）则认为这个语义位置对应的语义标签是家，否则把这个语义位置当做一个新的位置用剩下的方法去猜测可能的语义标签。

然后描述如何推断办公室这个语义标签。按照一般情况下朝九晚五的规定，对早上九点到中午十二点，下午一点到下午五点这七个半小时内出现的语义位置分别计算在其对应的地方停留的时间，并计算该时间相对于七个半小时所占的百分比。中间有一个小时被忽略掉是因为猜测通常情况下这一个小时大家应该是出去

吃午饭。剩下处理步骤与推断家这个语义标签的处理完全相同。这样就能够很简单的得到新位置是不是家或者实验室。该方法一般情况下都能取得比较理想的结果，见图4.34。该方法可能存在一个问题，第一天的数据中，用户晚上并未睡在自己家里，这样就可能导致一个误判，但是仔细分析我们的处理过程，这一步只是计算可能的语义标签，最后仍然需要用户的确认，所以即使推断错了也不会影响最终的语义标签。



图 4.34 语义标签推断结果示意

下面主要描述通过反地理编码获取语义位置对应的语义标签。在此之前需要先描述一下诸如百度地图、高德地图之类的电子地图以及这些地图提供的接口。百度地图是百度提供的一项网络地图搜索服务，覆盖了国内近 400 个城市、数千个区县。同时百度地图提供编程接口，我们通过对地图接口的调用得到全景图展现，热力图展示，定制个性地图，地图 2D、3D、卫星图的展示，本地检索，周边检索，区域检索，公交检索，驾车检索、覆盖物，反地理编码，实时交通等功能。本课题主要使用反地理编码功能。反地理编码实现地址解析服务，具体是指从已知的经纬度坐标到对应的地址描述（如省市、街区、楼层、房间等）的转换服务。

反地理编码只能返回一些比较大的地方的语义标签，对于实验室、教学楼、图书馆这种地方依然无能为力，这时候就需要用户手动输入来标记这些地方的语义标签。手动输入时为了减少用户的交互采用了安卓自己提供的文本框输入自动补全功能。见图4.35。

到目前为止展示了计算可能语义标签的三种方法，也得到了一个相对理想的结果，但是这个处理过程仍然太简单，还有很多问题需要解决，这也是下一步的工作。

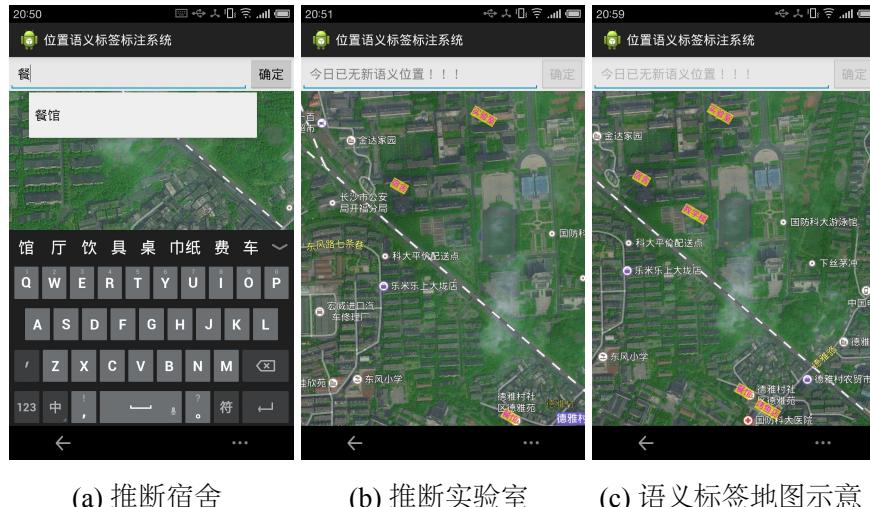


图 4.35 语义标签推断结果示意

4.4 小结

本章主要描述了一些对 GPS 数据额外的处理，这些处理方法在第五章准备轨迹数据时有用。本章首先描述了使用均值滤波、中值滤波、卡尔曼滤波以及分段卡尔曼滤波的实验结果，发现分段卡尔曼滤波能够获得一个更理想的结果；之后描述了使用 K-MEANS、DJ-Cluster 以及 Science 发表聚类算法三种聚类算法发现语义位置的实验结果以及分析了各种算法的优缺点；在获得语义位置的基础上描述了如何对语义位置标记对应的语义标签，先计算新的位置，然后计算新位置可能的语义标签，并且展示了实验结果。下一章将描述提出的度量用户关系强度的URSHV 计算方法以及实验验证。

第五章 用户关系强度计算方法

在上一章详细描述了面向 GPS 数据的语义标签标注技术，这一章重点描述我们自己提出的 URSHV 用户关系强度计算方法。将从计算方法概述、输入数据准备以及关系强度计算三方面来描述 URSHV 计算方法。

5.1 用户关系强度计算方法概述

层级用户关系度量计算方法 URSHV 从三个不同的抽象层次，从不同角度采用不同的方法来度量用户之间的关系强度。第一层基于用户日常的原始轨迹数据度量用户日常轨迹之间的相似度；第二层度量的是基于语义位置的用户行为模式之间的相似度，其抽象层次比第一层更高，其含义比第一层更加丰富；第三层度量的是基于语义标签的用户行为模式之间的相似度，其抽象层次比第二层更高，语义更加精确。URSHV 模型从轨迹、物理位置以及语义位置等三个由低到高的抽象层次，从三个反映人们日常活动和行为模式的方面来度量人们之间的关系强度，并基于这三个层次的度量结果，采用集成学习的思想进行投票，以投票结果作为人们之间的关系强度，因而能够全面真实地反映日常生活当中人们之间的关系强度。

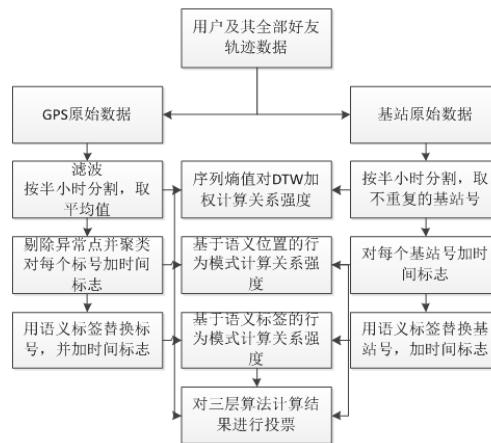


图 5.1 URSHV 模型框架

5.2 输入数据准备

上一节概述了计算方法，这一节将具体描述如何对 GPS 数据和基站数据进行预处理以得到需要的输入，下一节将具体描述如何计算用户之间的关系强度。

在日常生活中，用户的位置既可以通过智能手机内嵌的 GPS 传感器获取其位置信息，又可以通过用户所处区域内的通信基站进行定位。通过 GPS 获取的位置

信息相对与通过基站获取的位置信息要精确，但是长时间通过 GPS 传感器采集用户的位置信息将消耗大量的电量，会对用户手机的日常使用造成一定的影响。虽然基于基站的定位方式相对于 GPS 定位方式获取的位置信息精度要低，但其更有利于用户隐私的保护。因此，为了满足不同用户的不同需求，URSHV 模型既能够对 GPS 位置数据进行处理，同时又能够对基站位置数据进行处理。但是，无论是基于 GPS 的位置数据还是基于通信基站的位置数据都包含着大量的噪音，因此，为了更加精确地度量用户之间的关系强度，我们首先对这些数据进行去噪处理，而后采用不同方法来计算用户之间的关系强度。

设用户集合为 U , $U = \{u_1, u_2, \dots, u_n\}$, 其中 n 表示用户个数, D_i 表示用户 u_i 采集数据的日期的集合, 表示为 $D_i = \{d_1, d_2, \dots, d_{m_i}\}$, 其中 m_i 表示用户 u_i 采集数据的总天数。 F_i 表示用户 u_i 的全部朋友组成的集合, 表示为 $F_i = \{u_{k_1}, u_{k_2}, \dots, u_{k_{f_i}}\}$, 其中 f_i 表示用户 u_i 的好友的个数。 $Trace$ 表示所有用户所有天的轨迹数据的集合, 表示 $Trace = \{Trace_1, Trace_2, \dots, Trace_n\}$, 其中 $Trace_i$ 表示用户 u_i 所有天采集的轨迹序列的集合, 表示为 $Trace_i = \{Trace_{i,k} | k \in D_i\}$ 。 $Trace_{i,k}$ 表示用户 u_i 在 k 这一天的轨迹序列, 表示为 $Trace_{i,k} = \{l_1, l_2, \dots, l_{n_{i,k}}\}$, 其中 $n_{i,k}$ 表示用户 u_i 在 k 这一天采集的轨迹数据的条数, l_b 表示 b 时刻采集的位置数据记录, 可以为 GPS 经纬度, 也可以是基站号。

对于 GPS 数据和基站数据表示的用户轨迹序列进行预处理时，我们在下面三小节中分别依次描述模型的三层输入。

5.2.1 轨迹数据的处理与准备

处理 GPS 数据：对每个用户每天的数据 $Trace_{i,k}$ 进行滤波，目的是减少数据噪声；对每个用户每天的数据按半个小时进行切割，即将用户 u_i 的每天数据 $Trace_{i,k}$ 按时间均分为 48 份，表示为 $Sep_trace_{i,k} = \{Sep_trace_{i,k,1}, \dots, Sep_trace_{i,k,48}\}$ ，其中每一份数据表示为 $Sep_trace_{i,k,s} = \{l_{a_i} | l_{a_i} \in Trace_{i,k} \wedge a_i \in s\}$ ；对 $Sep_trace_{i,k,s}$ 按经纬度计算平均值，并将新的轨迹序列表示为 $Ntrace_{i,k}$, $Ntrace_{i,k} = \{Ntrace_{i,k,1}, \dots, Ntrace_{i,k,48}\}$ ，其中 $Ntrace_{i,k,s} = \frac{\sum(Sep_trace_{i,k,s})}{len(Sep_trace_{i,k,s})}$ ；其中 $sum(A)$ 表示对序列 A 中的元素求和， $len(A)$ 表示序列 A 的长度。将 $Ntrace_i$ 作为用户 u_i 使用第一层算法计算其与全部好友关系强度的输入。

处理基站数据：对每个用户每天的数据按半个小时进行切割，即将用户 u_i 在 k 这一天的数据 $Trace_{i,k}$ 按时间均分为 48 份，表示为 $Sep_trace_{i,k} = \{Sep_trace_{i,k,1}, \dots, Sep_trace_{i,k,48}\}$ ，其中每一份数据表示为 $Sep_trace_{i,k,s} = \{l_{a_i} | l_{a_i} \in Trace_{i,k} \wedge a_i \in s\}$ ；对每半个小时内数据计算依次不重复的基站号序列，即对每一份数据计算其对应的集合 $set(Sep_trace_{i,k,s})$ ，确保基站号不重复；再将每天 48 份数据重新拼成一个序列，目的是对每天轨迹序列降维，否则计算量太大而实

际无法计算，新序列记为 $Ntrace_{i,k}$ 。其中 $Ntrace_{i,k} = \bigcup_{s=1}^{48} set(Sep_trace_{i,k,s})$ ；将 $Ntrace_i$ 作为用户 u_i 使用第一层算法的输入。

5.2.2 语义位置数据的处理与准备

GPS 数据准备：采用上一章中讨论的聚类方法对所有用户的轨迹数据进行聚类，得到全部语义位置表示为 $Loc = \{pl_1, \dots, pl_g\}$ ，其中 g 表示总共的语义位置的个数。通过聚类得到用户 u_i 在 k 这一天的语义位置序列表示为 $Ltrace_{i,k} = \{loc(l_1), loc(l_2), \dots, loc(l_{n_{i,k}})\}$ ，其中 $loc(l_j)$ 表示位置数据记录 l_j 对应的语义位置标号。所有用户的所有语义位置序列表示为 $Ltrace = \{Ltrace_1, \dots, Ltrace_n\}$ ，其中用户 u_i 的全部语义位置序列表示 $Ltrace_i = \{Ltrace_{i,k} | k \in D_i\}$ 。对每个用户每天的数据按半个小时进行切割，即将用户 u_i 的每天数据 $Ltrace_{i,k}$ 按时间均分为 48 份，表示为 $Sep_ltrace_{i,k} = \{Sep_ltrace_{i,k,1}, \dots, Sep_ltrace_{i,k,48}\}$ ，其中每一份数据表示为 $Sep_ltrace_{i,k,s} = \{loc(l_{a_i}) | l_{a_i} \in Trace_{i,k} \wedge a_i \in s\}$ 。在准备 word2vec 模型的输入数据以及对应的模型输入数据时：我们需要首先计算每份数据不重复的语义位置序列，即 $Lsep_ltrace_{i,k,s} = set(Sep_ltrace_{i,k,s})$ ，然后将每天的 48 分数据合并成一个序列得到 $LLtrace$ ， $LLtrace_{i,k} = \bigcup_{s=1}^{48} Lsep_ltrace_{i,k,s}$ 。将 $LLtrace$ 作为 word2vec 模型的输入，训练得到对应模型 $LW2V(M)$ ， M 表示每个语义位置对应的实数值向量的长度。将 $Lsep_ltrace_i$ 作为用户 u_i 在第二层使用 word2vec 模型计算关系强度时的输入。其中 $Lsep_ltrace_{i,k} = \{Lsep_ltrace_{i,k,1}, \dots, Lsep_ltrace_{i,k,48}\}$ 。在准备 LDA 模型的输入数据以及对应的模型输入数据时：在已得到 Sep_ltrace 的基础上，对每份数据计算不重复出现的语义位置，并对每个位置加上时间标记。用户 u_i 在 k 这一天第 s 时间段语义位置序列表示为 $Tltrace_{i,k,s} = \{TT(sl_b) | sl_b \in set(Sep_ltrace_{i,k,s})\}$ ，其中 $TT(sl_b)$ 表示对 sl_b 添加时间标记，表示该语义位置在该时间段出现。 $set(A)$ 表示计算序列 A 对应的集合，即 A 中无重复元素。将 $Tltrace_i$ 作为用户 u_i 在第二层算法使用 LDA 模型计算关系强度时的输入。将 $Tltrace_{i,k}$ 中的 48 份数据合并成一个序列 $LTltrace$ ，其中 $LTltrace_{i,k} = \bigcup_{s=1}^{48} Tltrace_{i,k,s}$ 。将 $LTltrace$ 作为 LDA 模型的输入，训练得到对应的 LDA 主题模型 $LLDA(K)$ ， K 表示主题的个数。

基站数据准备：将每一个基站视为一个物理位置，即 $Ltrace=Trace$ 。其余处理与 GPS 处理完全相同。

5.2.3 语义标签数据的处理与准备

GPS 数据准备：对前文得到的 Loc 中每一个语义位置采用上一章中讨论的方法标记其语义标签，标语义标签后用户 u_i 第 k 天的语义标签序列表示为 $Strace_{i,k} = \{Label(ll_b) | ll_b \in ltrace_{i,k}\}$ ，其中 $Label(ll_b)$ 表示 ll_b 对应的语义标签。所有用户的所有语义标签序列表示为 $Strace = \{Strace_1, \dots, Strace_n\}$ ，其中用户 u_i 的

全部语义位置序列表示 $S\text{trace}_i = \{S\text{trace}_{i,k} | k \in D_i\}$ 。对每个用户每天的数据按半个小时进行切割，即将用户 u_i 的每天数据 $S\text{trace}_{i,k}$ 按时间均分为 48 份，表示为 $Sep_strace_{i,k} = \{Sep_strace_{i,k,1}, \dots, Sep_strace_{i,k,48}\}$ ，其中每一份数据表示为 $Sep_strace_{i,k,s} = \{Label(l_{a_i}) | l_{a_i} \in L\text{trace}_{i,k} \wedge a_i \in s\}$ 。在准备 word2vec 模型的输入数据以及对应的模型输入数据时：我们需要首先计算每份数据不重复的语义标签序列，即 $S\text{sep_strace}_{i,k,s} = set(Sep_strace_{i,k,s})$ ，然后将每天的 48 份数据合并成一个序列得到 $S\text{Ltrace}$ ， $S\text{Ltrace}_{i,k} = \bigcup_{s=1}^{48} S\text{sep_strace}_{i,k,s}$ 。将 $S\text{Ltrace}$ 作为 word2vec 模型的输入，训练得到对应模型 $SW2V(M)$ ， M 表示每个语义位置对应的实数值向量的长度。将 $S\text{sep_strace}_i$ 作为用户 u_i 在第三层使用 word2vec 模型计算关系强度时的输入。其中 $S\text{sep_strace}_{i,k} = \{S\text{sep_strace}_{i,k,1}, \dots, S\text{sep_strace}_{i,k,48}\}$ 。在准备 LDA 模型的输入数据以及对应的模型输入数据时：在已得到 Sep_strace 的基础上，对每份数据计算不重复出现的语义位置，并对每个位置加上时间标记。用户 u_i 在 k 这一天第 s 时间段物理位置序列表示为 $T\text{trace}_{i,k,s} = \{TT(sl_b) | sl_b \in set(Sep_strace_{i,k,s})\}$ ，其中 $TT(sl_b)$ 表示对 sl_b 添加时间标记，表示该语义位置在该时间段出现。 $set(A)$ 表示计算序列 A 对应的集合，即 A 中无重复元素。将 $T\text{trace}_i$ 作为用户 u_i 在第三层算法使用 LDA 模型计算关系强度时的输入。将 $T\text{trace}_{i,k}$ 中的 48 份数据合并成一个序列 $S\text{Ttrace}$ ，其中 $S\text{Ttrace}_{i,k} = \bigcup_{s=1}^{48} T\text{trace}_{i,k,s}$ 。将 $S\text{Ttrace}$ 作为 LDA 模型的输入，训练得到对应的 LDA 主题模型 $SLDA(K)$ ， K 表示主题的个数。

基站数据准备：计算每一个基站对应的语义标签，其余处理与 GPS 数据处理完全相同。

准备好模型各个层次的输入数据后，在下一节我们将详细描述如何使用输入数据计算用户之间的关系强度。

5.3 关系强度计算

上一节我们描述了如何准备模型对应的三层输入数据，这一节我们将分别描述基于轨迹数据的关系强度计算方法和基于主题模型的关系强度计算方法。

5.3.1 基于原始轨迹数据的关系强度计算

我们计算每一个用户 u_i 与其每一个朋友 $u_k (u_k \in F_i)$ 之间的关系强度，并对 F_i 中的每一个朋友，按照其与 u_i 的关系强度大小按降序排列，使此序列中任意两个朋友与 u_i 的关系强弱顺序尽可能与实际情况一致。

基于 DTW 及序列熵值加权计算用户之间的关系强度。对用户 u_i 的每一个好友 u_k ，利用上一小节得到的 $N\text{trace}_i$ 和 $N\text{trace}_k$ 计算其轨迹序列相似度。 $N\text{trace}_{i,a}$ 表示用户 i 在 a 这一天的数据，其中 $a \in D_i$ ， $N\text{trace}_{k,b}$ 表示用户 k 在 b

这一天的数据，其中 $b \in D_k$ 。 $S(i, j)$ 表示若 $a = b$ 则取值为 1，否则取值为 0。 $DTW(Ntrace_{i,a}, Ntrace_{k,b})$ 表示用户 u_i 在 a 这一天的轨迹和用户 u_k 在 b 这一天的轨迹的相似度， $Entropy(Ntrace_{i,a})$ 表示用户 u_i 在 a 这一天的轨迹序列的熵值。则用户 u_i 和用户 u_k 的基于轨迹序列的关系强度计算方法见公式 5.1。DTW 计算的是距离，距离越小相似度越大，即该公式值越小，两个用户关系强度越强。

$$Ent_{DTW}(u_i, u_k) = \frac{1}{\sum_{a \in D_i, b \in D_k} S(a, b)} \sum_{a \in D_i, b \in D_k} S(a, b) \frac{DTW(Ntrace_{i,a}, Ntrace_{k,b})}{Entropy(Ntrace_{i,a})} \quad (5.1)$$

5.3.2 基于主题模型的关系强度计算

LDA 模型对应的关系强度计算方法： $Tltrace_i$ 表示用户 u_i 根据上一小节得到的语义位置序列， $Tltrace_k$ 表示用户 u_k 根据上一小节得到的语义位置序列。 $T(a, p, b, q)$ 表示若用户 u_i 在 a 这一天第 p 个时间段和用户 u_k 在 b 这一天第 q 个时间段数据均存在则为 1，否则为 0。 $LLDA(K).inf(Tltrace_{i,a,p})$ 表示对 $Tltrace_{i,a,p}$ 推断得到的主题分布，通常表示为 K 维的向量，其中 K 表示主题的个数。基于用户语义位置的行为模式的关系强度计算方法见公式 5.2，其中 \cos 表示余弦相似度。

$$\begin{aligned} LocLDA(u_i, u_k) = & \frac{1}{\sum_{a \in D_i, b \in D_k} S(a, b)} \sum_{a \in D_i, b \in D_k} S(a, b) \frac{1}{\sum_{p=q=1}^{48} T(a, p, b, q)} \\ & \sum_{p=q=1}^{48} T(a, p, b, q) * \cos(LLDA(K).inf(Tltrace_{i,a,p}), LLDA(K).inf(Tltrace_{k,b,q})) \end{aligned} \quad (5.2)$$

基于用户语义标签的行为模式的关系强度计算公式与基于语义位置的关系强度计算公式相似，见公式 5.3。

$$\begin{aligned} SemLDA(u_i, u_k) = & \frac{1}{\sum_{a \in D_i, b \in D_k} S(a, b)} \sum_{a \in D_i, b \in D_k} S(a, b) \frac{1}{\sum_{p=q=1}^{48} T(a, p, b, q)} \\ & \sum_{p=q=1}^{48} T(a, p, b, q) * \cos(SLDA(K).inf(Tstrace_{i,a,p}), SLDA(K).inf(Tstrace_{k,b,q})) \end{aligned} \quad (5.3)$$

word2vec 模型对应的关系强度计算方法： $Lsep_strace_i$ 表示用户 u_i 根据上一小节得到的语义位置序列， $Lsep_strace_k$ 表示用户 u_k 根据上一小节得到的语义位置序列。 $T(a, p, b, q)$ 表示若用户 u_i 在 a 这一天第 p 个时间段和用户 u_k 在 b 这一天第 q 个时间段数据均存在则为 1，否则为 0。 $DTW(Lsep_strace_{i,a,p}, Lsep_strace_{k,b,q})$ 表示 $Lsep_strace_{i,a,p}$ 和 $Lsep_strace_{k,b,q}$ 之间的 DTW 距离。计算 DTW 距离时需要知道两个语义位置之间的距离，我们用这两个语义位置对应的实数值向量之间的

余弦距离作为这两个语义位置之间的距离。即由用户语义位置的行为模式得到的关系强度计算方法见公式5.4。

$$LocW2V(u_i, u_k) = \frac{1}{\sum_{a \in D_i, b \in D_k} S(a, b)} \sum_{a \in D_i, b \in D_k} S(a, b) \frac{1}{\sum_{p=1}^{48} T(a, p, b, q)} \sum_{p=1}^{48} T(a, p, b, q) * DTW(Lsep_strace_{i,a,p}, Lsep_strace_{k,b,q}) \quad (5.4)$$

基于用户语义标签的行为模式的关系强度计算公式与基于语义位置的关系强度计算公式相似，见公式5.5。

$$SemW2V(u_i, u_k) = \frac{1}{\sum_{a \in D_i, b \in D_k} S(a, b)} \sum_{a \in D_i, b \in D_k} S(a, b) \frac{1}{\sum_{p=1}^{48} T(a, p, b, q)} \sum_{p=1}^{48} T(a, p, b, q) * DTW(Ssep_strace_{i,a,p}, Ssep_strace_{k,b,q}) \quad (5.5)$$

我们更关注的是用户和好友 A 的关系强度大于或小于用户与好友 B 的关系强度。因此我们实际计算结果为用户与其全部好友按关系强度降序排列得到的好友序列。

5.3.3 结果投票

对于用户 u_i ，我们对其全部好友 F_i 中的每一个朋友 u_k 使用 $EntDTW(u_i, u_k)$ 计算用户 u_i 和用户 u_k 之间的关系强度，并对 F_i 中的每一个朋友按照计算得到的关系强度降序排列得到 $E_i = \{u_{d_1}, \dots, u_{d_{f_i}}\}$ ，其中 $EntDTW(u_i, u_{d_a}) > EntDTW(u_i, u_{d_b})$ 如果 $a < b$ 。在此基础上，我们使用 $LocLDA(u_i, u_k)$ 或者 $LocW2V(u_i, u_k)$ 计算用户 u_i 和用户 u_k 之间的关系强度，并对 F_i 中的每一个朋友按照计算得到的关系强度降序排列得到 $L_i = \{u_{l_1}, \dots, u_{l_{f_i}}\}$ ，其中 $LocLDA(u_i, u_{l_a}) > LocLDA(u_i, u_{l_b})$ 或者 $LocW2V(u_i, u_{l_a}) > LocW2V(u_i, u_{l_b})$ 如果 $a < b$ 。最后我们使用 $SemLDA(u_i, u_k)$ 或者 $SemW2V(u_i, u_k)$ 计算用户 u_i 和用户 u_k 之间的关系强度，并对 F_i 中的每一个朋友按照计算得到的关系强度降序排列得到 $S_i = \{u_{s_1}, \dots, u_{s_{f_i}}\}$ ，其中 $SemLDA(u_i, u_{s_a}) > SemLDA(u_i, u_{s_b})$ 或者 $SemW2V(u_i, u_{s_a}) > SemW2V(u_i, u_{s_b})$ 如果 $a < b$ 。我们采用集成学习的思想对三个层次的计算结果 E_i 、 L_i 、 S_i 进行投票，投票规则为：对于与用户 u_i 关系第 k 强的好友 u_{v_k} ($k \leq 1$ 且 $k \ll f_i$)，我们使用三个层次对应的方法分别计算得到 u_{d_k} 、 u_{l_k} 和 u_{s_k} ，若这三个用户都不相同，则我们认为 $u_{v_k} = u_{d_k}$ ，若某个用户比如 $u_{l_k} = u_{s_k}$ 出现两次及以上，我们认为 $u_{v_k} = u_{l_k}$ 。以 $V_i = \{u_{v_1}, \dots, u_{v_{f_i}}\}$ 作为投票的最终结果。

5.4 小结

本章就如何使用轨迹数据度量用户之间的关系强度进行了深入讨论，首先描述了URSHV的计算方法，该方法能同时处理GPS数据和基站数据，并使用轨迹数据计算用户之间的关系强度；其次我们从GPS数据和基站数据两方面描述了如何准备URSHV的输入数据；最后我们从基于轨迹数据计算用户关系强度和基于用户行为模式计算用户关系强度两方面详细描述了我们如何使用轨迹数据度量用户之间的关系强度。下一章我们将主要描述实验用到的数据集，评估方法以及在数据集上的实验结果。

第六章 数据集、评估方法及实验结果

上一章我们首先概括描述了 URSHV 层级模型；然后描述了如何准备数据作为模型的输入；最后从基于原始轨迹数据的用户关系强度计算、基于主题模型的用户关系强度计算以及结果投票三方面重点描述了基于轨迹数据的用户关系强度度量模型。本章我们将描述如何在真实数据集上对第四章提出的模型进行验证以及对实验结果进行分析。

6.1 数据集

我们采用真实场景下采集的数据作为验证数据集。数据集由 MIT 媒体实验室在 2004-2005 年主持的 RealityMining 项目收集整理得到。RealityMining 项目追踪了 94 个使用安装预装软件的手机的用户，这些预装软件能够记录并发送用户数据，比如：通话记录、近似 5 米范围内的蓝牙设备、基站塔编号、应用使用以及手机状态。该项目追踪观察了包括学生和来自同一个研究机构的两个课题组的职员总共九个月对手机的使用情况。与此同时，该项目收集了每个志愿者提供的关系数据比如谁和谁是朋友等。

每个志愿者使用 Nokia6600 在后台运行一个称为 ContextLog 的程序采集数据。在该项目中期，研究者组织了一次在线调查问卷，106 个志愿者中共有 94 个人完成了该调查问卷。调查问卷内容见表 6.1。除此调查问卷外，采集的数据有每个志愿者手机的蓝牙 MAC 地址、每个志愿者开始参与该项目的日期、每个志愿者隶属的机构、每个志愿者隶属的研究小组、每个志愿者收集的 IMEI、每个志愿者的邻居、每个志愿者自己告知的工作时间、每个志愿者是否有一个规律的工作计划、每个志愿者自己告知的常去的聚集地、每个志愿者是否有一个可预言的日程安排、每个志愿者是不是把手机忘在家里或工作的地方、每个志愿者手机电量是不是经常耗光、每个志愿者生病频率、每个志愿者最近是否生病、每个志愿者是否经常出去旅游、给每个志愿者提供通话服务的运营商、每个用户每个月买东西花费的时间、每个志愿者发短信的频率、每个志愿者是否经常被描述给其他人、每个治愈者对他所处团体的评价、每个志愿者的通信时间记录、每个志愿者收集充电记录、每个志愿者收集使用日期记录、每个志愿者手机采集数据的记录时间、每个志愿者开机关机时间记录、每个志愿者的轨迹数据记录（由基站号、区域号以及时间戳构成）、用户经过的唯一的位置（由基站号和区域号表示）、每个志愿者周围的蓝牙设备名称、每个志愿者周围的蓝牙设备的 MAC 地址、每个志愿者扫描周围蓝牙设备的时间、基站号及区域号对应的位置语义标签、每个志愿者使用应用的开始时间及使用时长、每个志愿者手机每天记录数据的时长、

每个志愿者家对应的基站号和区域号托等。基站号及区域号与对应的语义标签见表6.2。

表 6.1 调查问卷^[1]

问题及答案选项

(1)Have you travelled recently?

1 Very often - more than a week/month 2 Often - week/month 3 Sometimes - several days/month 4 Rarely - several days/term 5 Never

(2)Do you own a car?

1 Yes 2 No

(3)How many miles to you live from MIT?

1. less than 1 2. 1-3 3. 4-10 4. more than 10

(4)How do you daily commute to MIT?

1. By foot 2. By bike 3. By T/bus 4. By car

(5)How much has your social network evolved since the start of Fall term?

1. A lot 2. Somewhat 3. Slightly 4. None

(6)Have you been sick recently?

1. Yes, in the last week 2. Yes, in the last two weeks 3. Yes, in the last month 4. No

(7)How long into the term did it take for your social circle to become what it is today?

1. Still evolving 2. 2 months into term 3. 1 month into term 4. Several weeks into term 5. First couple of days here

(8)I use my phone:

1. exclusively for work/school related matters 2. primarily for work/school related matters, but occasionally for personal/social use

3. equally for work/school and for personal/social use 4. primarily for personal /social use 5. exclusively for personal/social use

(9)How often do you send text messages?

1. Several times / day 2. once / day 3. once / week 4. once / month 5. never

(10)The majority of my daily work communication is done through: (you can select more than one) face-face discussion

1. Yes NaN. No

(11)The majority of my daily work communication is done through: (you can select
续下页

续表 - 调查问卷

问题及答案选项

more than one) email

2. Yes NaN. No

(12)The majority of my daily work communication is done through: (you can select more than one) phone

3. Yes NaN. No

(13)The majority of my daily work communication is done through: (you can select more than one) text-messaging

4. Yes NaN. No

(14)The majority of my daily personal communication is done through: (you can select more than one) face-face discussion

1. Yes NaN. No

(15)The majority of my daily personal communication is done through: (you can select more than one) email

2. Yes NaN. No

(16)The majority of my daily personal communication is done through: (you can select more than one) phone

3. Yes NaN. No

(17)The majority of my daily personal communication is done through: (you can select more than one) text-messaging

4. Yes NaN. No

(18)I am satisfied with my experience at MIT thus far I am satisfied with my current social circle

1 – Strongly Agree 2, 3, 4, 5,6, 7 – Strongly Disagree

(19)I am satisfied with my current social circle

1 – Strongly Agree 2, 3, 4, 5,6, 7 – Strongly Disagree

(20)I feel I have learned a lot this semester

1 – Strongly Agree 2, 3, 4, 5,6, 7 – Strongly Disagree

(21)I am satisfied with the content and direction of my classes and research this semester

1 – Strongly Agree 2, 3, 4, 5,6, 7 – Strongly Disagree

(22)I am satisfied with the support I received from my circle of friends

续下页

续表 - 调查问卷

问题及答案选项

1 – Strongly Agree 2, 3, 4, 5, 6, 7 – Strongly Disagree

(23) I am satisfied with the level of support I have received from the other members in my Media Lab research group/Sloan core team.

1 – Strongly Agree 2, 3, 4, 5, 6, 7 – Strongly Disagree

(24) I am satisfied with the quality of our group meetings

1 – Strongly Agree 2, 3, 4, 5, 6, 7 – Strongly Disagree

(25) I am satisfied with how my research group interacts on a personal level

1 – Strongly Agree 2, 3, 4, 5, 6, 7 – Strongly Disagree

我们对每个志愿者每天采集的基站编号的个数进行统计，发现所有志愿者总共在连续 374 天采集了数据，采集了基站数据的志愿者共有 88 人。图6.1是一个 88*374 的图像，每一个像素点表示一个志愿者在某一天采集数据，颜色越黑表明用户采集的基站数据条数越多。



图 6.1 志愿者采集基站数据可视化

该数据集提供了志愿者之间的朋友关系，提供朋友关系的志愿者共 94 人，其中有 6 个人没有轨迹数据，我们剔除掉这 6 个人后，对剩余 86 人的关系进行可视化。图6.2是一个 172*172 的图像，每相邻 4 个像素点若全部为黑色表示一个志愿者和另一个志愿者是朋友关系，否则不是。

在对数据集的分析过程中，我们发现朋友关系信息表中存在如下问题：1) 部分用户自己和自己是好朋友，另外一部分用户自己和自己不是好朋友；2) 某用户和另一个用户是好朋友，另一个用户和该用户不是好朋友。我们认为用户之间的好友关系应该满足反自反和对称，即自己和自己不是好友，如果用户 A 和用户 B 是好朋友，则用户 B 和用户 A 是好朋友。经过这样处理后，我们得到好友数大于 1 的用户共有 34 个，若用户好友数为 1，则使用模型计算得到的关系强弱顺序与实际必定一致，故剔除这部分用户。为此，在后面的实验中，我们使用这 34 个用户及其全部朋友的数据来对 URSHV 模型进行验证。

表 6.2 基站区域号与对应的语义标签

基站号	区域号	语义标签
5119	40811	T-Mobile Media lab 1
5119	40332	TMO Tech sq 2
5123	40763	TMO MIT / Ashdown 3
5119	40342	TMO Ashdown 4
5119	40801	T-Mobile East campus / hyatt 5
5119	40342	T-Mobile Inf corr 6
5119	40802	T-Mobile Tang 7
5131	43861	T-Mobile Tang 8
5119	40793	T-Mobile Mit 9
24127	132	AT&T Wirel 1-115
24127	131	AT&T Wirel 1-115
24127	2421	AT&T Wirel 2-103/ ML / End Inf cor
24127	2353	AT&T Wirel Build 3
24127	2833	AT&T Wirel Student center
24127	111	AT&T Wirel ML / Mass Ave/ Infinite
24127	182	AT&T Wirel Mass ave bridge 310 smoots New house
24127	2832	AT&T Wirel ML
24127	113	AT&T Wirel Ml
24127	2422	AT&T Wirel Ml
24127	2833	AT&T Wirel Ml
24127	112	AT&T Wirel Ml
24127	2413	AT&T Wirel Ml
24127	133	AT&T Wirel Ml
24127	2433	AT&T Wirel Ml
24123	261	AT&T Wirel Ml
24127	2832	AT&T Wirel Medical
24127	182	AT&T Wirel Mass ave bridge 310 smoots

该数据集中采集的位置信息是基站信息，虽然基站定位方式的精确度比 GPS 定位方式低，但更有利于用户隐私的保护，这也是我们选择该数据集进行实验的主要原因之一。

6.2 评估方法

上一节我们主要描述了验证我们算法需要用到的真实数据集，但是数据集中并未给出志愿者之间关系强度的数值或者大小关系，因此需要我们自己构造志愿

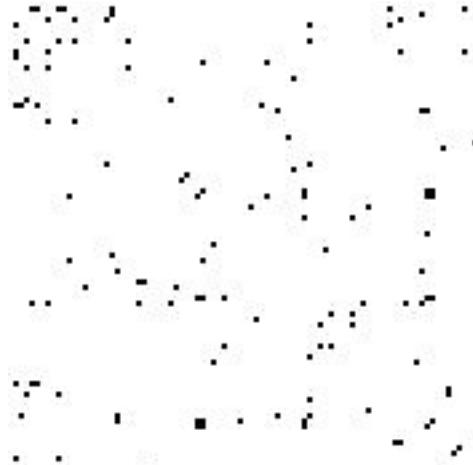


图 6.2 朋友关系可视化

者之间的关系强度作为真实结果，且目前信息检索方面的评估方法不太适合本课题，我们自己提出了一种评估方法作为对我们自己提出的模型的性能的评价。

6.2.1 构造真实结果

根据上文提到的社会心理学一些研究成果，态度、兴趣、价值观、背景和人格等方面更相似的人关系更亲密，尤其是对生活在一起的一个群体来说，如果在这些方面类似并且对某些问题的看法相似，则其关系可能就更加紧密。在现实生活中，通常通过问卷调查方式来获得这些方面的信息，问卷调查结果是这些方面的一种真实体现和反映，因此，我们可以认为问卷调查结果越相似的用户关系越亲密，为此，我们根据上一节描述数据集中问卷调查回答结果的相似性作为朋友之间真实的关系强度。

经过对上一节描述的数据集中的问卷调查的仔细分析，我们发现问卷调查中的所有问题基本上可以分为两类：第一类问题可以用“是”或“否”来回答，另一类问题答案多选，但是每个选项按顺序呈现强度增强、次数增加或者次数减少。为了计算朋友之间的真实的关系强度，针对这两类问题，我们采用不同的评分方法。针对第一类问题当中的每一个问题，如果两个朋友的答案相同，则评分为 1，否则评分为 0；针对第二类问题当中的每一个问题，如果两个朋友的答案越接近，则评分越高，并且将评分归一化到 0-1 之间，使得每个问题在总的关系强度评分中占有相同的权重。在完成对所有问题评分基础上，对所有评分进行累加求和，以此作为两个朋友之间的关系强度。依次对每个用户及其所有朋友按上述方法计算其与每个朋友之间的关系强度，并对其所有朋友的评分按降序排列，得到一个用户与其所有朋友之间的关系强度序列，以此序列作为该用户与其朋友之间真实的关系强度。真实结果见表 6.3。在此基础上，使用 URSHV 模型计算出来

的用户之间关系强度序列与真实的关系强度序列进行对比，从而验证 URSHV 模型的有效性。

6.2.2 评估方法

通过前面的描述，我们可以知道，经过投票之后得到的用户之间的关系强度是该用户的全部好友按照与该用户的关系强度由强到弱排列的一个用户序列，而我们上一小节计算得到的用户之间的关系强度也是该用户的全部好友按照与该用户的关系强度由强到弱排列的一个用户序列，所以我们度量方法最关键的问题是如何度量两个有完全相同元素组成的有序序列，而这两个序列仅有的差别在于所有元素的排列可能不同。我们这个问题看起来很像一个信息检索问题，就是一个结果的排序问题，但是主要区别在于，信息检索对应的问题有很多无关的结果，这样我们只需要计算排在前面的正确的结果就可以得到准确率；而对本课题而言，所有结果都是准确的，只是应该按照一定的顺序。这个原因使得我们通过深入分析发现信息检索相关的一些度量方法不满足我们度量的要求，我们通过查阅相关资料和文献，发现逆序对数是度量两个有序序列是否一致很合理的一个指标，因此下面将主要描述如果使用逆序对数度量两个有序序列的一致性。

为了度量使用 URSHV 模型计算出来的用户与朋友之间关系强度序列 V_i 与真实的关系强度序列 G_i 的一致性，我们参考文献 [42]，提出一种基于逆序对数的有序序列一致性度量方法。设 A 为一个有 N 个数字的有序集 ($N > 1$)，且所有数字均不相同，如果存在正整数 i, j ，使得 $1 \leq i < j \leq N$ ，而 $A[i] > A[j]$ ，则称 $\langle A[i], A[j] \rangle$ 为 A 的一个逆序对。 A 中全部的逆序对的个数称为逆序对数。我们把序列 G_i 作为有序集，来计算序列 V_i 的逆序对数。设该用户共有 f_i 个好友，若逆序对数为 0，说明实验结果与实际结果完全一致，若逆序对数为 $\frac{f_i * (f_i - 1)}{2}$ ，则说明实验结果恰好是实际结果的逆序。因此，我们提出的有序序列一致性度量公式见公式6.1。其中 f_i 为用户 u_i 的全部好友的个数， k_i 为 V_i 相对于 G_i 的逆序对数。根据该公式我们可以发现，若实验结果序列的逆序对数为 0，则评分为 1，若实验结果与实际结果完全相反，则评分为 0。对每个用户可计算得到一个一致性评分，在此基础上，对所有用户的一致性评分取平均值，以此作为对模型对朋友关系强度度量好坏程度的度量，见公式6.2。

$$score(u_i) = 1 - \frac{k_i}{f_i * (f_i - 1)/2} \quad (6.1)$$

$$Score = \frac{1}{n} \sum_{i=1}^n score(u_i) \quad (6.2)$$

表 6.3 志愿者和其全部好友 (按关系强度递减排列)

志愿者	朋友 (按关系强度递减排列)
1	9, 19, 85, 71, 10, 4, 5
2	77, 19
3	18, 12, 7, 73
4	71, 1, 56
7	12, 22, 9, 3, 56
9	1, 85, 7, 73
11	48, 36
12	22, 7, 3
18	3, 30
19	1, 47, 2, 5
20	77, 50, 78
22	12, 7
30	18, 56
35	79, 55, 78, 36
36	55, 79, 35, 48, 78, 11
38	67, 45
40	64, 55
48	11, 36
50	77, 20
52	25, 24
53	31, 14
55	79, 36, 35, 78, 40
56	74, 77, 7, 66, 30, 4, 24
58	60, 64
60	58, 64
64	40, 60, 58
67	38, 76
71	1, 4, 5
73	82, 3, 9
77	2, 50, 20, 56
78	43, 35, 79, 55, 20, 36
79	35, 55, 36, 78
82	73, 72
85	1, 9

6.3 实验结果与分析

实验环境为 windows 7 64 位, 4 核, 3.2GHz 主频, 8G 内存, 使用 Python 编码实现。

为了使用第三章提到的基于原始轨迹的用户关系强度度量方法, 即对基站数据使用 DTW 方法时, 首先要确定任意基站之间的距离, 在此基础上使用扩展 DTW 方法计算用户之间的物理距离。欧式距离是最常见的一种度量方法, 对于 GPS 形式的轨迹数据我们就可以使用欧式距离来度量, 但是基站号只是不同基站之间为了区分生成的一个标号, 并无实际物理意义, 因此无法直接使用欧式距离, 所以我们需要采用一些方法使用基站号来定义两个基站之间的距离。

我们采取如下方法来定义基站之间的距离, 我们把每天用户手机连接过的基站视为一条基站序列, 对于基站 A 和 B, 我们从所有用户所有天的基站序列中找到同时出现 A 和 B 的序列, 计算每个序列中 A 和 B 中间不同的基站号的个数, 取最小值加一作为基站 A 和基站 B 之间的距离。例如, 假设找到全部同时出现 A 和 B 的序列有 ACDEEB、ADCCB 以及 AECFDEB, 则第一个序列计算得到 A 和 B 的距离为 4, 第二个序列计算得到 A 和 B 的距离为 3, 第三个序列计算得到 A 和 B 之间的距离 5, A 和 B 之间的距离取所有距离的最小值, 即 A 和 B 之间的距离为 3。若通过上述方法能够计算出两个基站之间的距离, 则称为这两个基站之间的距离存在。若 A 和 B 从未在同一个基站序列中出现过, 则定义 A 和 B 之间的距离为所有两个基站距离存在且最大的距离的 K 倍, K 为一个正实数参数, 在后面实验中我们能够看到该参数对实验结果的影响。如果对任意两个基站都从所有用户所有天的基站序列中找出同时出现这两个基站的序列, 然后按照上文所述的方法计算这两个基站之间的距离, 则其时间复杂度非常大, 因此, 我们通过对每个基站号建立倒排索引来减少计算量。倒排索引是指对每个基站号, 我们可以找到它在哪个用户那一天的轨迹数据中哪个位置出现。这样对于计算两个基站号之间的距离, 我们可以依次通过查找是否有相同用户, 是否在同一天, 以及同一天的位置来计算距离, 最后取最小值。使用倒排索引, 整个数据集只需要遍历一遍。如果不使用倒排索引, 本文使用数据集中不同的基站区域号总共有 30991 个, 则需要计算的基站距离共有 480205545 个, 若对全部数据遍历四亿多次, 可以想象时间复杂度将会特别大。

实验 1: 基于轨迹相似性计算用户之间的关系强度通过上面的处理方法, 可以计算出任意两个基站之间的距离, 因而就可以使用 DTW 方法来计算每一个用户 u_i 与其所有朋友 F_i 中每个人之间的关系强度, 进而得到每个用户与其所有朋友之间的关系强度序列, 记为 $W_{0,i}$ 。将该序列与 G_i 进行对比, 并按公式6.1对两者

的一致性进行评分，进而对所有用户使用公式6.2计算最终的一致性评分，验证结果的有效性。与此同时，一方面，第二章描述 DTW 算法时指出可以使用三种正则化方法对 DTW 计算结果进行优化处理来提升算法的效果，为此，我们使用这三种方法对 DTW 计算结果进行优化来获得每一个用户与其所有朋友之间的关系强度，进而得到优化后的每个用户与其所有朋友之间的关系强度序列，记为 $W_{1,i}$ 、 $W_{2,i}$ 以及 $W_{3,i}$ 。将 $W_{1,i}$ 、 $W_{2,i}$ 以及 $W_{3,i}$ 与 G_i 进行对比，并按公式6.1对两者的一致性进行评分，进而对所有用户使用公式6.2计算最终的一致性评分。另一方面，前面提到，如果两个基站 A 和 B 从未在同一个基站序列中出现过，则定义 A 和 B 之间的距离为所有两个基站之间距离最大值的 K 倍， K 为一个正实数参数， K 的设置对两个关系强度序列的一致性评分具有一定影响，图6.3描述了参数 K 的不同设置对 $W_{1,i}$ 、 $W_{2,i}$ 以及 $W_{3,i}$ 分别和 G_i 一致性评分的影响情况。观察6.3可以发现，当 K 为 2.5 时，通过 DTW 计算方法得到的 $W_{0,i}$ 与 G_i 更加接近一致。通过对经过三种正则化方法优化后的 DTW 计算结果，可以发现，通过使用 DTW 结果除以最优序列长度这种优化方法，得到的 $W_{3,i}$ 与 G_i 更加接近一致。不进行任何优化的 DTW 方法计算得到的用户好友序列见表6.4，使用最优序列长度归一化 DTW 距离并使用序列熵值加权得到的用户好友列表见表6.5。

在使用 DTW 及其经三种优化方法获得 $W_{0,i}$ 、 $W_{1,i}$ 、 $W_{2,i}$ 及 $W_{3,i}$ 的基础上，我们对每个用户每天的轨迹序列进行熵值加权，进而得到每个用户与其所有朋友之间的关系强度序列 E_i ，再使用公式6.1对 E_i 与 G_i 的一致性进行评分，进而对所有用户使用公式6.2计算最终的一致性评分，验证其有效性。图6.4描述了加权前后计算得到的 E_i 与 G_i 对应的全部用户的一致性评分结果。经验证，对于不同的 K 值，使用熵值加权后得到的一致性评分均好于不加权得到的一致性评分，图6.4 中仅列出当 $K = 2.5$ 的实验结果。通过对实验结果的进一步分析，我们发现对于编辑距离，使用熵值加权后计算得到的用户与其所有朋友关系强度序列与 G_i 更加一致，因此我们可以认为使用熵值加权的确能够更好的度量用户之间的关系强度。

实验 2：基于语义位置用户行为模式相似性计算用户之间的关系强度

为了进一步基于语义位置的相似性来度量用户与其所有朋友之间的关系强度，我们将每天每个用户其手机连接的所有基站号加上时间标记，例如 ‘5119.40332_24’ 表示用户在 11:30 到 12:00 期间（最后 2 位表示时间段）连接过基站 5119.40332。在此基础上，我们将每个经过这种方法处理后的基站号视为一个单词，用户每天连接过的基站号序列视为一个句子，每个用户连接过的全部基站号序列视为文档，使用所有用户的全部文档对 LDA 模型进行训练。在进行 LDA 模型训练时，首先需要确定主题的个数，主题个数是 LDA 模型的一个参数，主题个数不同，实验结果亦不相同。在计算关系强度的过程中，我们使用 LDA 模

表 6.4 无优化 DTW 方法得到好友列表

用户编号	真实关系强度对应好友列表	DTW 关系强度对应好友列表
1	9, 19, 85, 71, 10, 4, 5	4, 85, 71, 19, 5, 9, 10
2	77, 19	77, 19
3	18, 12, 7, 73	12, 7, 73, 18
4	71, 1, 56	1, 56, 71
7	12, 22, 9, 3, 56	12, 56, 22, 3, 9
9	1, 85, 7, 73	1, 7, 73, 85
11	48, 36	36, 48
12	22, 7, 3	7, 22, 3
18	3, 30	30, 3
19	1, 47, 2, 5	47, 1, 5, 2
20	77, 50, 78	77, 78, 50
22	12, 7	12, 7
30	18, 56	56, 18
35	79, 55, 78, 36	79, 36, 55, 78
36	55, 79, 35, 48, 78, 11	55, 79, 11, 78, 48, 35
38	67, 45	67, 45
40	64, 55	55, 64
48	11, 36	36, 11
50	77, 20	77, 20
52	25, 24	25, 24
53	31, 14	14, 31
55	79, 36, 35, 78, 40	79, 36, 78, 35, 40
56	74, 77, 7, 66, 30, 4, 24	74, 66, 7, 30, 77, 4, 24
58	60, 64	60, 64
60	58, 64	58, 64
64	40, 60, 58	60, 58, 40
67	38, 76	76, 38
71	1, 4, 5	1, 5, 4
73	82, 3, 9	3, 82, 9
77	2, 50, 20, 56	2, 20, 50, 56
78	43, 35, 79, 55, 20, 36	20, 36, 55, 79, 35, 43
79	35, 55, 36, 78	35, 55, 36, 78
82	73, 72	73, 72
85	1, 9	1, 9

表 6.5 熵值加权最优序列长度归一化 DTW 方法得到好友列表

用户编号	真实关系强度对应好友列表	优化 DTW 关系强度对应好友列表
1	9, 19, 85, 71, 10, 4, 5	4, 71, 85, 19, 5, 9, 10
2	77, 19	77, 19
3	18, 12, 7, 73	12, 18, 7, 73
4	71, 1, 56	1, 56, 71
7	12, 22, 9, 3, 56	12, 22, 56, 3, 9
9	1, 85, 7, 73	1, 7, 85, 73
11	48, 36	36, 48
12	22, 7, 3	7, 22, 3
18	3, 30	30, 3
19	1, 47, 2, 5	47, 1, 2, 5
20	77, 50, 78	77, 78, 50
22	12, 7	12, 7
30	18, 56	18, 56
35	79, 55, 78, 36	79, 36, 55, 78
36	55, 79, 35, 48, 78, 11	48, 55, 79, 35, 11, 78
38	67, 45	67, 45
40	64, 55	55, 64
48	11, 36	36, 11
50	77, 20	77, 20
52	25, 24	25, 24
53	31, 14	14, 31
55	79, 36, 35, 78, 40	79, 36, 78, 35, 40
56	74, 77, 7, 66, 30, 4, 24	74, 66, 7, 30, 77, 4, 24
58	60, 64	60, 64
60	58, 64	58, 64
64	40, 60, 58	60, 58, 40
67	38, 76	76, 38
71	1, 4, 5	1, 5, 4
73	82, 3, 9	3, 82, 9
77	2, 50, 20, 56	20, 2, 50, 56
78	43, 35, 79, 55, 20, 36	20, 79, 36, 55, 43, 35
79	35, 55, 36, 78	35, 55, 36, 78
82	73, 72	73, 72
85	1, 9	1, 9

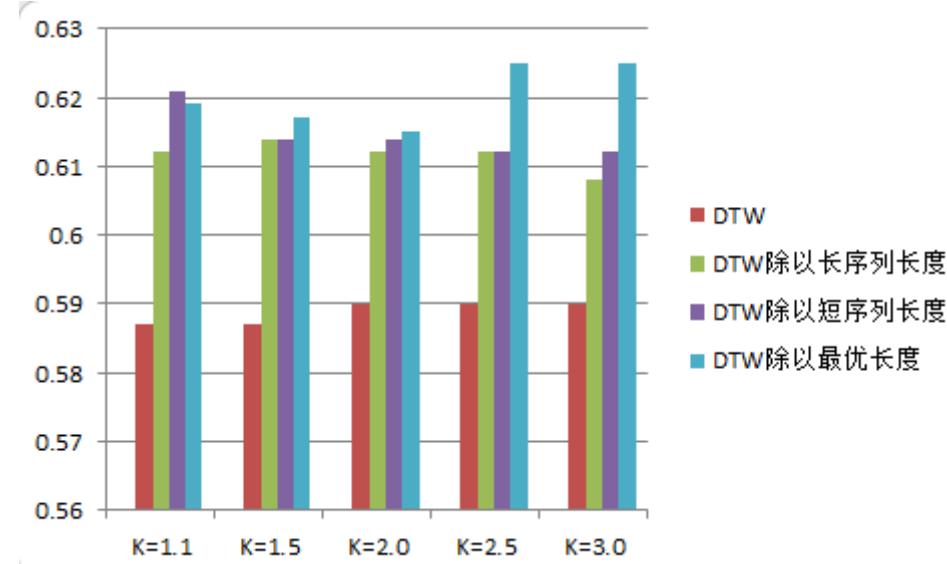


图 6.3 DTW 实验结果

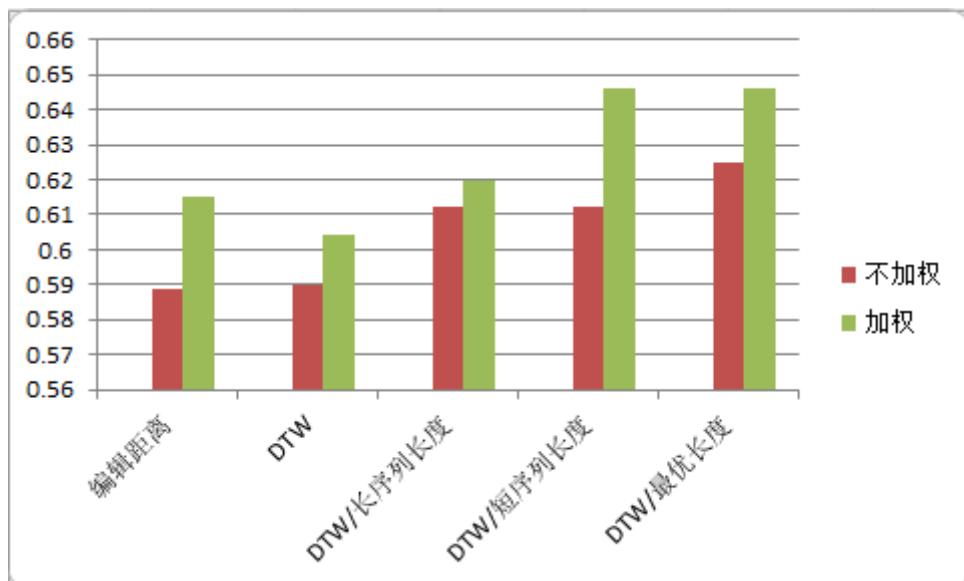


图 6.4 加权前后实验结果对比

型进行推断，因为推断过程进行随机初始化，从而使得 LDA 模型的每次执行结果不一定完全相同，因此，在实验中，针对每个不同的参数值（即主题个数）执行 10 次，并将每次计算获得的 L_i 与 G_i 进行一致性评分，对所有用户按公式6.2 计算最终的一致性评分。进而取这 10 个一致性评分的中位数作为该参数对应的一致性评分，如图6.5所示。

对图6.5进行分析，可以发现对于不同的主题个数有两个峰值：当主题个数为 50 时，一致性评分为 65.6%；当主题个数为 90 时，一致性评分为 66.2%。若主题个数太少，则区别能力太小，两个用户不管是非常相似还是比较相似都拥有相同

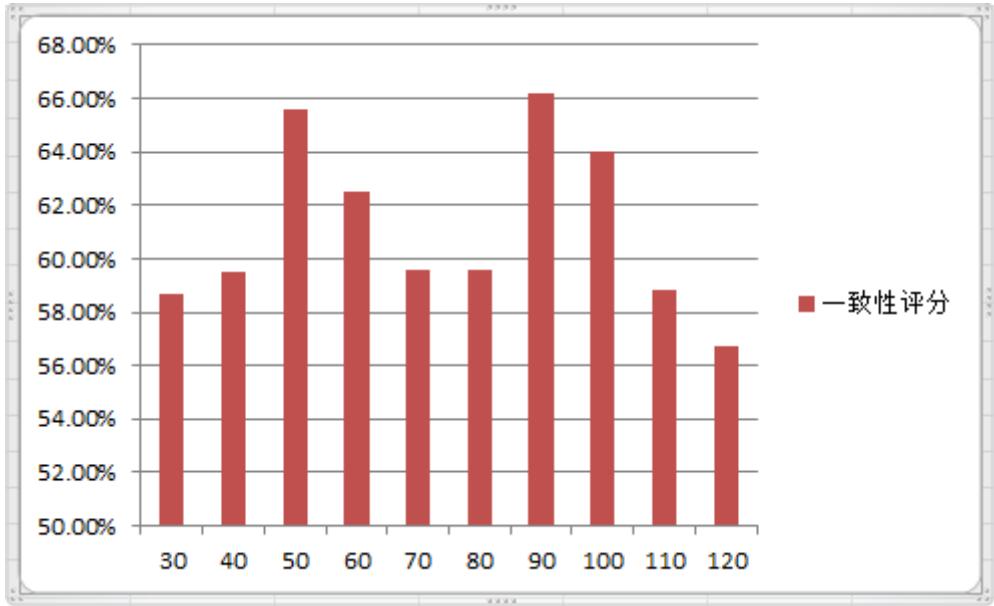


图 6.5 基于语义位置实验结果

的行为模式，则因为行为模式完全相同，因而无法区分这两个用户是非常相似还是比较相似。若主题个数太多，区别能力也将降低，每个用户分别对应不同的行为模式，即使两个用户实际上非常相似，当时因为行为模式不同，导致计算结果表明两个用户不相似。有两个峰值有可能是因为主题其实是一个层级概念，在某个抽象层次上可能主题数在 50 个左右，在另一个抽象层次上，主题数可能在 90 个左右。50 个主题对应的 LDA 模型计算得到的好友序列见表 6.6。

实验 3：基于语义标签用户行为模式相似性计算用户之间的关系强度

本章第一节我们描述数据集时说到该数据集提供了基站号和区域号对应的位置的语义标签，包括实验室以及每个用户的家庭住址对应的基站号和区域号，例如 5123.40811 对应 Media lab。为了进一步基于语义位置的相似性来度量用户与其所有朋友之间的关系强度，我们将基站号转换成对应的语义标签，形成一个基站号与语义标签相对应的映射表，如果一个基站号没有对应的语义标签，则其映射 Unknown。在此基础上，对每个语义标签加上时间标记，例如 ‘Media lab_27’ 表示用户在下午 2:00 到 2:30 期间（最后 2 位表示时间段）在 Media lab 出现过。对所有语义标签加上时间标记后，我们将每个带时间标记的语义标签视为单词，每天的语义标签序列视为句子，每个用户所有语义标签序列视为文档，使用所有用户的全部文档对 LDA 模型进行训练，其实验过程与上面的基于物理位置的实验过程一样，并将每次计算获得的 S_i 与 G_i 进行一致性评分，对所有用户按公式 6.2 计算最终的一致性评分。图 6.6 描述了在主题个数取不同值时所对应的一致性评分结果。

表 6.6 基于语义位置行为模式关系强度度量方法得到好友列表

用户编号	真实关系强度对应好友列表	基于语义位置行为模式相似度得到好友列表
1	9, 19, 85, 71, 10, 4, 5	85, 5, 19, 9, 10, 71, 4
2	77, 19	77, 19
3	18, 12, 7, 73	12, 18, 7, 73
4	71, 1, 56	1, 71, 56
7	12, 22, 9, 3, 56	12, 22, 56, 3, 9
9	1, 85, 7, 73	1, 85, 7, 73
11	48, 36	36, 48
12	22, 7, 3	7, 22, 3
18	3, 30	30, 3
19	1, 47, 2, 5	5, 1, 2, 47
20	77, 50, 78	77, 78, 50
22	12, 7	12, 7
30	18, 56	56, 18
35	79, 55, 78, 36	36, 78, 55, 79
36	55, 79, 35, 48, 78, 11	79, 55, 11, 78, 35, 48
38	67, 45	67, 45
40	64, 55	64, 55
48	11, 36	11, 36
50	77, 20	77, 20
52	25, 24	25, 24
53	31, 14	31, 14
55	79, 36, 35, 78, 40	79, 36, 78, 40, 35
56	74, 77, 7, 66, 30, 4, 24	66, 30, 74, 77, 7, 24, 4
58	60, 64	60, 64
60	58, 64	64, 58
64	40, 60, 58	60, 40, 58
67	38, 76	76, 38
71	1, 4, 5	1, 5, 4
73	82, 3, 9	82, 3, 9
77	2, 50, 20, 56	2, 20, 56, 50
78	43, 35, 79, 55, 20, 36	20, 79, 43, 55, 36, 35
79	35, 55, 36, 78	36, 55, 78, 35
82	73, 72	73, 72
85	1, 9	1, 9

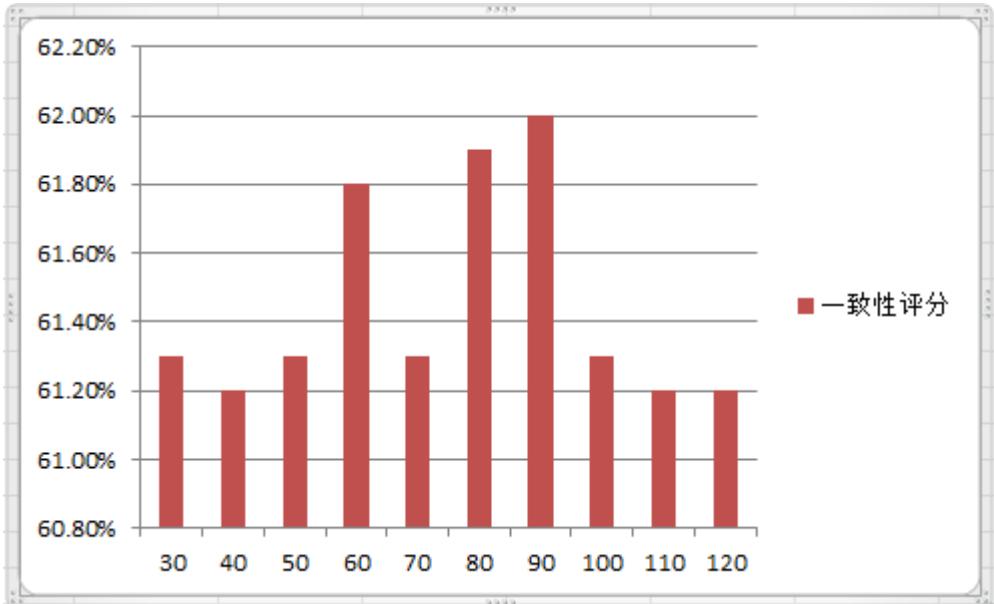


图 6.6 基于语义标签实验结果

对图6.6进行分析，不同的参数值（主题个数）对结果影响不大，原因可能是实验的对象主要是学校教员和学生，大家在日常生活当中的基于语义位置的行为模式非常类似，因而对不同的参数值（主题个数）不敏感。

语义标签有实际含义，以主题个数 75 为例，通过观察 LDA 模型学习到的主题，发现该模型学到了 3 个主题，如表6.7所示，主题 1 表示的是晚上在实验室或教室，主题 2 表示早上和晚上在家，主题 3 表示的上午在实验室。60 个主题对应的 LDA 模型计算得到的好友序列见表6.8。

表 6.7 LDA 模型学习到的主题

主题 1	主题 2	主题 3
Tech sq_47, Tech sq_46	home_14, home_15	Media lab_17, Media lab_16
Tech sq_40, Tech sq_38	home_8, home_6	Media lab_20, Media lab_18
Tech sq_39, Tech sq_42	home_0, home_44	Media lab_19, Tech sq_17

实验 4：对计算结果进行投票

实验 1、实验 2 和实验 3 分别描述了层级模型 URSHV 每一层的实验结果，在此基础上，我们使用前面描述的投票规则对三层实验结果进行投票，得到 V_i ，对三层结果投票的实验结果见图6.7。通过实验结果我们可以发现，使用投票方法后，我们可以更好的度量用户之间的关系强度，投票后得到的用户好友列表见表6.9。

表 6.8 基于语义标签行为模式关系强度度量方法得到好友列表

用户编号	真实关系强度对应好友列表	基于语义标签行为模式相似度得到好友列表
1	9, 19, 85, 71, 10, 4, 5	5, 9, 85, 19, 10, 71, 4
2	77, 19	19, 77
3	18, 12, 7, 73	18, 12, 7, 73
4	71, 1, 56	1, 71, 56
7	12, 22, 9, 3, 56	3, 56, 12, 22, 9
9	1, 85, 7, 73	73, 1, 85, 7
11	48, 36	48, 36
12	22, 7, 3	22, 3, 7
18	3, 30	3, 30
19	1, 47, 2, 5	5, 47, 1, 2
20	77, 50, 78	78, 77, 50
22	12, 7	12, 7
30	18, 56	18, 56
35	79, 55, 78, 36	78, 36, 55, 79
36	55, 79, 35, 48, 78, 11	55, 79, 11, 35, 48, 78
38	67, 45	67, 45
40	64, 55	64, 55
48	11, 36	11, 36
50	77, 20	20, 77
52	25, 24	25, 24
53	31, 14	31, 14
55	79, 36, 35, 78, 40	36, 79, 78, 40, 35
56	74, 77, 7, 66, 30, 4, 24	77, 66, 7, 30, 74, 24, 4
58	60, 64	64, 60
60	58, 64	64, 58
64	40, 60, 58	60, 58, 40
67	38, 76	76, 38
71	1, 4, 5	1, 5, 4
73	82, 3, 9	9, 82, 3
77	2, 50, 20, 56	20, 56, 2, 50
78	43, 35, 79, 55, 20, 36	35, 20, 43, 55, 79, 36
79	35, 55, 36, 78	36, 55, 78, 35
82	73, 72	73, 72
85	1, 9	1, 9

表 6.9 三层结果投票得到好友列表

用户编号	真实关系强度对应好友列表	三层结果投票得到好友列表
1	9, 19, 85, 71, 10, 4, 5	71, 85, 19, 10, 9, 5, 4
2	77, 19	19, 77
3	18, 12, 7, 73	18, 12, 7, 73
4	71, 1, 56	1, 71, 56
7	12, 22, 9, 3, 56	12, 22, 56, 3, 9
9	1, 85, 7, 73	1, 7, 85, 73
11	48, 36	48, 36
12	22, 7, 3	7, 22, 3
18	3, 30	3, 30
19	1, 47, 2, 5	5, 1, 2, 47
20	77, 50, 78	77, 78, 50
22	12, 7	12, 7
30	18, 56	18, 56
35	79, 55, 78, 36	79, 36, 55, 78
36	55, 79, 35, 48, 78, 11	79, 55, 11, 35, 48, 78
38	67, 45	67, 45
40	64, 55	55, 64
48	11, 36	11, 36
50	77, 20	20, 77
52	25, 24	25, 24
53	31, 14	31, 14
55	79, 36, 35, 78, 40	79, 36, 78, 40, 35
56	74, 77, 7, 66, 30, 4, 24	74, 77, 7, 30, 66, 24, 4
58	60, 64	64, 60
60	58, 64	64, 58
64	40, 60, 58	60, 58, 40
67	38, 76	76, 38
71	1, 4, 5	1, 5, 4
73	82, 3, 9	3, 82, 9
77	2, 50, 20, 56	20, 2, 50, 56
78	43, 35, 79, 55, 20, 36	20, 79, 36, 55, 43, 35
79	35, 55, 36, 78	36, 55, 78, 35
82	73, 72	73, 72
85	1, 9	1, 9

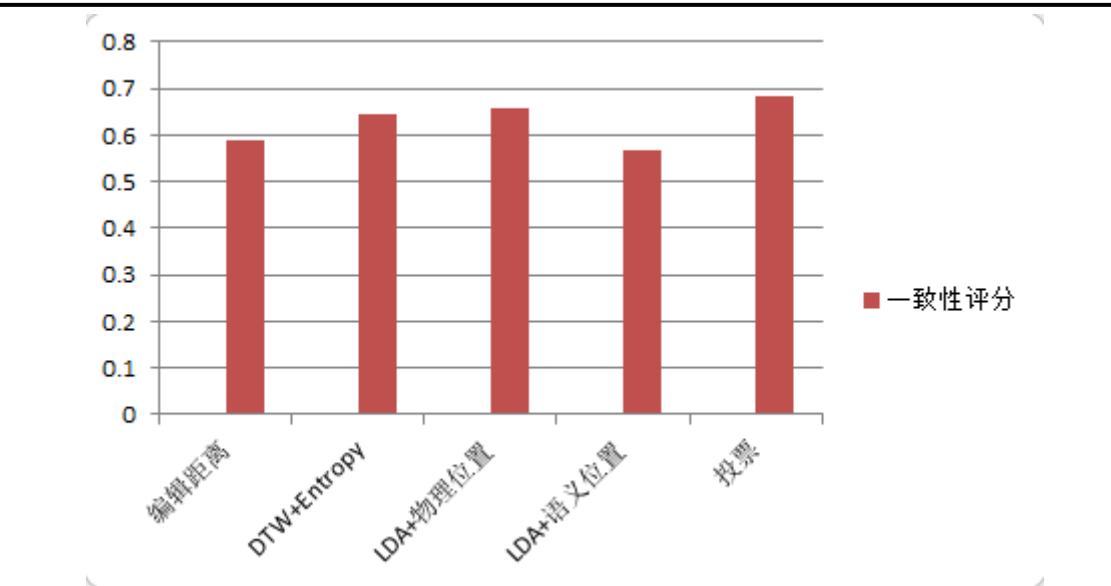


图 6.7 投票结果

6.4 小结

本章我们主要描述了验证我们模型使用的数据集，如何使用数据集构造真实结果，设计适用本课题问题的评估方法以及展示了实验演过并进行了深入分析。

第七章 结束语

7.1 工作总结

随着硬件的迅速发展，智能手机得以嵌入更多的传感器，且拥有更大的内存，更快的处理器，使得我们可以利用智能手机研究好多以前无法解决的问题。通常情况下，手机都会随身携带，从而手机可以基本完整的记录我们每天的生活轨迹，而生活轨迹又能很大程度上反映人和人之间在真实世界的交互，进而使得使用轨迹数据来度量人和人之间的关系强度成为可能。以前的工作只考虑真实世界人和人的交互次数，实际上，使用手机采集的轨迹数据我们能够得到更多的信息，比如用户基于轨迹的行为模式。因此，我们尝试从更多方面去考虑轨迹数据和用户之间关系强度的关系。本课题针对如何度量日常生活中人们之间的关系强度问题展开研究，提出了一个既可以对 GPS 数据进行处理又可以对基站数据进行处理，从日常轨迹、物理位置以及语义位置三个层次度量人们之间关系强度的层级模型 URSHV。概括起来，主要研究内容和贡献如下：

(1) GPS 数据相较于基站数据更杂乱，因此需要许多额外的处理，我们首先研究了对 GPS 数据的一些额外的处理。原始 GPS 数据采样得到结果有较大误差，且采集数据存在大量用户日常活动在路上行进的点，而我们课题只需要考虑用户停留在宿舍、实验室等语义位置相关的点，故需要对 GPS 数据进行降噪并剔除路上的点。在此基础上，我们需要通过一些方法来发现与 GPS 原始数据对应的如宿舍、实验室等语义位置，进而标记每个语义位置对应的语义标签。在本课题中，我们通过实验各种滤波算法，发现分段卡尔曼滤波具有更好的降噪效果；通过对采集的 GPS 数据进行进一步分析，我们发现路上点的密度远小于用户处于语义位置时的点的密度，因此我们采用基于密度的异常点剔除方法，且该方法可以自动学习参数；当前该领域用来发现语义位置的聚类算法存在一些问题，比如需要预先知道类别的个数或者对参数比较敏感，我们采用最新提出的一个基于密度的聚类算法来发现语义位置，该方法对参数更鲁棒，且不需要预先知道类别个数；在得到语义位置的基础上，我们需要通过一些方法标记语义位置对应的语义标签，目前常用的方法是人工手动标注，我们发现可以通过反地理编码，语义标签推断以及输入自动补全来减少用户和语义标签标注系统的交互。

(2) 我们使用原始轨迹数据的相似度，基于语义位置的用户行为模式的相似度以及基于语义标签的用户行为模式的相似度三方面来度量用户之间的关系强度。如何度量原始轨迹数据的相似度、如何度量用户模式之间的相似度以及如何对三层结果进行融合就是本课题最关键的问题。首先，在计算原始轨迹数据的相

似度时，我们发现使用编辑距离计算得到的相似度效果不是很理想，而 DTW 距离更倾向于序列长度较长的序列。因此，我们对 DTW 计算得到的距离使用三种方法归一化。并且我们发现用户每天活动的多样性不同使得该天轨迹数据的相似度对最终的相似度贡献不同，因此，我们使用用户每天轨迹序列的熵值对用户每天的相似度加权。其次，在计算用户行为模式时，我们发现 LDA 主题模型可以很好的用来发现用户基于轨迹的行为模式，且该模型的推断方法能够帮助我们很好的度量行为模式之间的相似度。最后，在得到三个层次的用户关系强度计算结果后，我们使用集成学习的思想对三个结果进行投票，并且以投票结果作为最终的关系强度。

(3) 以前的工作基于仿真数据集进行验证，真实数据集还是存在一些问题，如何对真实数据集进行处理，构造真实结果，以及如何针对我们的问题提供相应的评估方法以及模型中的各个参数对实验结果究竟有什么影响也是本课题急需解决掉一个重要问题。我们使用第五章第一节提到的数据集，对其朋友关系进行处理，使得该关系满足反自反和对称，用朋友之间调查问卷的相似度作为用户之间真实的关系强度。我们对用户关系强度的度量结果其实是该用户全部好友按与该用户关系强度亲密程度降序排列对应的好友序列，因此我们针对有序序列提出基于逆序对数的一致性评分评估标准来评价我们模型的实验结果。最后我们通过实验证明了各个参数对模型实验结果的影响，并且对结果进行了深入分析。

7.2 工作展望

论文针对基于轨迹数据的用户关系强度度量问题展开研究，在对相关技术研究基础上，提出了一个既可以对 GPS 数据进行处理又可以对基站数据进行处理，从日常轨迹、物理位置以及语义位置三个层次度量人们之间关系强度的层级模型 URSHV。虽然取得了一定的结果，但是仍然存在许多问题需要进一步研究和完善。现将这些问题总结如下：

(1) 基于 DTW 的关系强度度量方法虽然能得到一个比较好的度量结果，但是该算法具有比较大的时间复杂度。下一步工作尝试对数据进行一定的优化，使得该算法计算时消耗更少的时间。

(2) 我们只使用了原始轨迹数据的相似度和基于轨迹的行为模式的相似度两方面来度量用户之间的关系强度，根据轨迹数据，我们其实能够得到更多的信息。下一步工作尝试深入理解轨迹数据以及考虑从更多的方面来使用轨迹数据，使得我们对关系强度的度量更加全面。

(3) 虽然轨迹数据和我们在真实世界的交互密切相关。但是，通话记录，短信，蓝牙交互，社交网络交互，这些信息同样能够反映用户之间的关系强度。下

一步工作尝试采集更多的手机传感器数据，分别研究如何基于单个传感器数据度量用户关系强度以及如何综合使用这些传感器数据度量用户之间的关系强度。

致 谢

在本文完成和硕士生涯结束之际，我谨向所有给予我指导、关心、支持和帮助的老师、领导、同学和亲人致以衷心的感谢！

衷心感谢我的导师史殿习教授！感谢史老师对我的无私关怀、精心指导和严格要求。在两年多的硕士学习生活中，史老师在百般繁忙之际仍不忘抽出时间关心我的课题进展，找我聊人生、聊理想。不仅对我的课题提出很多很宝贵的建设性意见，而且对我将来人生的发展方向以及职业规划也提出很多至关重要的建议。我本身不是一个很勤奋的人，史老师也未严格要求每天呆在实验室的时间，但是每次有事找史老师时，史老师都在办公室看论文，史老师对移动感知领域论文了解的广度和深度，我望尘莫及，每次看到老师刻苦的身影，暗暗下定决心，一定要多看论文。史老师严谨的治学精神和精益求精的工作作风在不断的鞭笞着我，让我不断前行。在课题方面，我没有做到史老师希望的那么优秀，辜负了史老师对我的期望，在以后的日子里，我会更加努力，做更好的工作，做更好的自己，在此谨向他表示最衷心的感谢和最诚挚的敬意。

衷心感谢尹刚老师、丁博老师、刘慧老师，感谢你们在我课题的开题阶段给我的宝贵的建议和支持，使我更加明确了研究方向和思路，且为后续课题研究进展提供了很多现在看来确实很有远见的指导，衷心感谢窦勇老师和王晓东老师在预审阶段对我论文撰写提出的珍贵意见，使得该论文能够顺利完成。同时也感谢你们在生活上和学习上对我的帮助。

感谢何炫辰学长、李永谋学长、丁涛杰学长、陈富霞学姐和金星学姐，感谢你们在生活和学习上对我的帮助，和何炫辰学长的每次聊天都能使我烦躁的内心平静好多，每次学术上的问题李永谋学长都不厌其烦的帮我解决，陈富霞学姐给了我很多生活上的经验，受用至今。感谢同门好友吴渊、李寒、陈茜、周荣、谭杰夫、樊泽栋。感谢吴渊一直陪我去五楼实验室打乒乓球，经常陪我去东门吃夜宵；感谢李寒经常带我出去玩，看外面的世界；感谢陈茜帮我报账，提供零食当夜宵；感谢周荣给我平时无聊的生活带来乐趣。非常感谢各位同门好友在学习和生活上给我提供的帮助，因为你们使得平时波澜不惊的生活充满了色彩，非常庆幸、非常感谢！感谢王峰、赵邦辉、陈晓鹏、莫晓赟、李中秋、刘帆、童哲航、颜丙政、魏菁、成瑶瑶学弟学妹，和你们一起讨论学术问题，交流人生经验，我自己也受益匪浅。你们都是富有才华的研究人才，祝你们人生之路丰富多彩。感

谢同一个实验室的张飞、王东升，刘冰珣、古崇明经常打扰你们找你们聊天，你们没有怨言还给了我很多学术和生活的建议。

感谢朱涛政委、孙友佳政委和郑永辉政委。我们是科大第一届地方生，很多规矩都不懂，感谢你们在这两年半中给予我的帮助。感谢室友许名广、伍名、谢飞，感谢对面宿舍孙洪雷、吴平杰、吴茂永，在与你们一起度过的快乐的两年半生活中，感谢你们在学习和生活中给予我的帮助。

感谢学院八队的所有同学，与你们在一起的两年半时光是我人生最宝贵的一笔财富。感谢两年以来悉心指导我的每一位老师和前辈，你们的辛勤汗水让我在成长道路上跨步前进。

感谢 NudtPaper，它的存在让我的论文写作轻松自在了许多，让我的论文格式规整漂亮了许多。

最后，深深感谢生我养我的父母，你们的支持是我前进的最大动力，愿你们健康长寿！

参考文献

- [1] Eagle N, Pentland A. Reality mining: sensing complex social systems [J]. Personal and ubiquitous computing. 2006, 10 (4): 255–268.
- [2] Rachuri K K, Musolesi M, Mascolo C, et al. EmotionSense: a mobile phones based adaptive platform for experimental social psychology research [C]. In Proceedings of the 12th ACM international conference on Ubiquitous computing. 2010: 281–290.
- [3] Miluzzo E, Lane N D, Eisenman S B, et al. CenceMe—injecting sensing presence into social networking applications [M] // Miluzzo E, Lane N D, Eisenman S B, et al. Smart Sensing and Context. Springer, 2007: 2007: 1–28.
- [4] Dong W, Lepri B, Pentland A S. Modeling the co-evolution of behaviors and social relationships using mobile phone data [C]. In Proceedings of the 10th International Conference on Mobile and Ubiquitous Multimedia. 2011: 134–143.
- [5] Thiagarajan A, Ravindranath L, LaCurts K, et al. VTrack: accurate, energy-aware road traffic delay estimation using mobile phones [C]. In Proceedings of the 7th ACM Conference on Embedded Networked Sensor Systems. 2009: 85–98.
- [6] Kanjo E. NoiseSPY: a real-time mobile phone platform for urban noise monitoring and mapping [J]. Mobile Networks and Applications. 2010, 15 (4): 562–574.
- [7] Aharony N, Pan W, Ip C, et al. Social fMRI: Investigating and shaping social mechanisms in the real world [J]. Pervasive and Mobile Computing. 2011, 7 (6): 643–659.
- [8] Wang R, Chen F, Chen Z, et al. StudentLife: assessing mental health, academic performance and behavioral trends of college students using smartphones [C]. In Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing. 2014: 3–14.
- [9] Stopczynski A, Sekara V, Sapiezynski P, et al. Measuring large-scale social networks with high resolution [J]. PloS one. 2014, 9 (4): e95978.
- [10] Granovetter M S. The strength of weak ties [J]. American journal of sociology. 1973: 1360–1380.
- [11] Burt R S. Structural holes: The social structure of competition [M]. Harvard university press, 2009.
- [12] Carruthers P. The illusion of conscious will [J]. Synthese. 2007, 159 (2): 197–213.

- [13] Burrows R, Nettleton S, Pleace N, et al. Virtual community care? Social policy and the emergence of computer mediated social support [J]. *Information, Communication & Society*. 2000, 3 (1): 95–121.
- [14] Coles A J, Wing M G, Molyneux P, et al. Monoclonal antibody treatment exposes three mechanisms underlying the clinical course of multiple sclerosis [J]. *Annals of neurology*. 1999, 46 (3): 296–304.
- [15] Petrőczi A, Nepusz T, Bazsó F. Measuring tie-strength in virtual social networks [J]. *Connections*. 2007, 27 (2): 39–52.
- [16] Pentland A, Eagle N, Lazer D. Inferring social network structure using mobile phone data [J]. *Proceedings of the National Academy of Sciences (PNAS)*. 2009, 106 (36): 15274–15278.
- [17] Mtibaa A, Chaintreau A, LeBrun J, et al. Are you moved by your social network application? [C]. In *Proceedings of the first workshop on Online social networks*. 2008: 67–72.
- [18] Crandall D, Cosley D, Huttenlocher D, et al. Feedback effects between similarity and social influence in online communities [C]. In *Proceedings of the 14th ACM SIGKDD international conference on Knowledge discovery and data mining*. 2008: 160–168.
- [19] Ma C, Cao J, Yang L, et al. Effective social relationship measurement based on user trajectory analysis [J]. *Journal of Ambient Intelligence and Humanized Computing*. 2014, 5 (1): 39–50.
- [20] Rodriguez A, Laio A. Clustering by fast search and find of density peaks [J]. *Science*. 2014, 344 (6191): 1492–1496.
- [21] Kalman R E. A new approach to linear filtering and prediction problems [J]. *Journal of Fluids Engineering*. 1960, 82 (1): 35–45.
- [22] Pang-Ning T, Steinbach M, Kumar V, et al. Introduction to data mining [C]. In *Library of Congress*. 2006: 74.
- [23] MacQueen J, et al. Some methods for classification and analysis of multivariate observations [C]. In *Proceedings of the fifth Berkeley symposium on mathematical statistics and probability*. 1967: 281–297.
- [24] Zhou C, Frankowski D, Ludford P, et al. Discovering personally meaningful places: An interactive clustering approach [J]. *ACM Transactions on Information Systems (TOIS)*. 2007, 25 (3): 12.

- [25] Festinger L. Leon Festinger [J]. Selective Exposure Theory. 1977: 14.
- [26] Zajonc R B. Attitudinal effects of mere exposure. [J]. Journal of personality and social psychology. 1968, 9 (2p2): 1.
- [27] Levenshtein V I. Binary codes capable of correcting deletions, insertions, and reversals [C]. In Soviet physics doklady. 1966: 707–710.
- [28] Chen L, Özsu M T, Oria V. Robust and fast similarity search for moving object trajectories [C]. In Proceedings of the 2005 ACM SIGMOD international conference on Management of data. 2005: 491–502.
- [29] Chen L, Ng R. On the marriage of l_p -norms and edit distance [C]. In Proceedings of the Thirtieth international conference on Very large data bases-Volume 30. 2004: 792–803.
- [30] Itakura F, Umezaki T. Distance measure for speech recognition based on the smoothed group delay spectrum [C]. In Acoustics, Speech, and Signal Processing, IEEE International Conference on ICASSP'87. 1987: 1257–1260.
- [31] Berndt D J, Clifford J. Using Dynamic Time Warping to Find Patterns in Time Series. [C]. In KDD workshop. 1994: 359–370.
- [32] Ratanamahatana C A, Keogh E. Everything you know about dynamic time warping is wrong [C]. In Third Workshop on Mining Temporal and Sequential Data. 2004.
- [33] Cover T M, Thomas J A. Elements of information theory [M]. John Wiley & Sons, 2012.
- [34] Kontoyiannis I, Algoet P H, Suhov Y M, et al. Nonparametric entropy estimation for stationary processes and random fields, with applications to English text [J]. Information Theory, IEEE Transactions on. 1998, 44 (3): 1319–1327.
- [35] McInerney J, Stein S, Rogers A, et al. Breaking the habit: Measuring and predicting departures from routine in individual human mobility [J]. Pervasive and Mobile Computing. 2013, 9 (6): 808–822.
- [36] Singelis T M. The measurement of independent and interdependent self-construals [J]. Personality and Social Psychology Bulletin. 1994, 20 (5): 580–591.
- [37] Farrahi K, Gatica-Perez D. What did you do today?: discovering daily routines from large-scale mobile data [C]. In Proceedings of the 16th ACM international conference on Multimedia. 2008: 849–852.
- [38] Blei D M, Ng A Y, Jordan M I. Latent dirichlet allocation [J]. the Journal of machine Learning research. 2003, 3: 993–1022.

- [39] Mikolov G, Chen K, Dean J. word2vec (2013).
- [40] peghoty. word2vec. <http://www.cnblogs.com/peghoty/p/3857839.html>. 2014.
- [41] Rawassizadeh R, Tomitsch M, Wac K, et al. UbiqLog: a generic mobile phone-based life-log framework [J]. Personal and ubiquitous computing. 2013, 17 (4): 621–637.
- [42] wiki. Inversion. [http://en.wikipedia.org/w/index.php?title=Inversion_\(discrete_mathematics\)&oldid=650315847](http://en.wikipedia.org/w/index.php?title=Inversion_(discrete_mathematics)&oldid=650315847). 2014.

作者在学期间取得的学术成果

发表的学术论文

- [1] Ruosong Yang, Dianxi Shi. SASLL: A System Annotating Semantic Label of Location. The 7th International Symposium on UbiCom Frontiers Innovative Research, Systems and Technologies.(EI 检索)
- [2] Dianxi Shi, Ruosong Yang. Measuring User Relationship Strength Using a Model Based on Hierarchical Voting. 2016 PerCom. (已投稿)

